

Evaluación del comportamiento de agentes con
memoria RAG
en el análisis *run-to-failure* de maquinaria rotativa

Autor: pendiente

Curso académico: pendiente

Resumen

Este Trabajo Fin de Máster estudia el comportamiento de agentes basados en modelos de lenguaje locales durante el análisis de señales industriales de vibración. El escenario principal es la monitorización *run-to-failure* de rodamientos: los agentes deben formular hipótesis, seleccionar configuraciones, interpretar resultados y revisar sus decisiones a partir de evidencia temporal. Para que ese razonamiento pueda evaluarse, la propuesta combina un supervisor jerárquico, decisiones validadas mediante contratos estrictos y ejecutores deterministas que realizan las transformaciones sobre los datos.

La aportación diferencial es un ciclo de memoria RAG supervisada. Cada decisión puede producir un episodio trazable y un candidato de memoria; antes de volver a utilizarse, los recuerdos se filtran por agente, dataset, rol, veredicto y compatibilidad metodológica. El sistema registra qué recuerdos se recuperan, cuáles llegan al agente y cómo este los cita, adapta o rechaza. El índice vectorial es intercambiable y reconstruible; los contratos y artefactos persistidos constituyen la fuente auditable. El almacenamiento JSON exacto actúa como referencia reproducible y Qdrant queda como implementación opcional.

La implementación se ha validado como sistema mediante CWRU y pilotos sintéticos, y se ha ejecutado un primer baseline causal sobre las 984 adquisiciones oficiales de NASA IMS Set 2. El protocolo fija, antes del modelado, 197 snapshots de baseline, 98 de calibración y 689 de monitorización; calibra el umbral sin etiquetas futuras y evalúa persistencia después de agregar las ventanas de cada adquisición. Esta ejecución aporta evidencia descriptiva de una trayectoria real, pero no valida un onset físico ni permite publicar métricas binarias sin *ground truth*. Un piloto pareado con PCA e Isolation Forest recuperó un único recuerdo incompatible, que no fue citado ni utilizado; las métricas permanecieron invariantes. Este resultado negativo revela que la disponibilidad del motor no compensa un corpus irrelevante y no demuestra un beneficio del RAG. El contraste definitivo requiere réplicas con un corpus pertinente congelado y una comparación controlada de modelos de lenguaje. La evaluación determinista previa no autorizó nuevas generaciones al no disponer aún de trazas experimentales completas, cobertura multi-dataset y resultados de las perturbaciones definidas.

Palabras clave: sistemas multiagente, modelos de lenguaje, memoria RAG, mantenimiento predictivo, run-to-failure, detección de anomalías, señales de vibración.

Abstract

This Master’s Thesis studies the behaviour of local language-model agents when analysing industrial vibration signals. Its main scenario is bearing run-to-failure monitoring: agents formulate hypotheses, select configurations, interpret results and revise their decisions using temporal evidence. A hierarchical supervisor coordinates the workflow, strict contracts validate agent decisions, and deterministic executors perform all data transformations.

The distinctive contribution is a supervised RAG memory cycle. Decisions may produce traceable episodes and memory candidates; before reuse, records are filtered by agent, dataset, role, verdict and methodological compatibility. The system records which memories are retrieved, which ones reach the agent, and how the agent cites, adapts or rejects them. The vector index is interchangeable and rebuildable; persisted contracts and artefacts remain the auditable source of evidence. Exact JSON search is the reproducible baseline, while Qdrant is an optional implementation.

The implementation has been validated as a system with CWRU and synthetic pilots, and a first causal baseline has been run on the 984 official NASA IMS Set 2 acquisitions. Before modelling, the protocol fixes 197 baseline, 98 calibration and 689 monitoring snapshots; it calibrates the threshold without future labels and evaluates persistence only after aggregating each acquisition’s windows. This run provides descriptive evidence from a real trajectory, but it neither validates a physical onset nor supports binary metrics without ground truth. In a paired PCA and Isolation Forest pilot, the retriever returned one incompatible record; agents neither cited nor used it, and the metrics remained unchanged. This negative result shows that an available retrieval engine cannot compensate for an irrelevant corpus and does not demonstrate a RAG benefit. Definitive evidence requires replicated ablations with a relevant frozen corpus and a controlled comparison of language models. The deterministic pre-generation assessment did not authorise new generations because complete experimental traces, multi-dataset coverage and perturbation results were not yet available.

Keywords: multi-agent systems, language models, RAG memory, predictive maintenance, run-to-failure, anomaly detection, vibration signals.

Índice general

1. Introducción	1
1.1. Contexto y motivación	1
1.2. Planteamiento del problema	1
1.3. Preguntas de investigación	2
1.4. Objetivos	2
1.4.1. Objetivo general	2
1.4.2. Objetivos específicos	2
1.5. Aportaciones del trabajo	3
1.6. Alcance y limitaciones	3
1.7. Estructura del documento	4
2. Estado del arte	5
2.1. Mantenimiento predictivo y escenarios <i>run-to-failure</i>	5
2.2. Señales de maquinaria rotativa e indicadores de salud	6
2.3. Familias de detección de anomalías	6
2.4. Sistemas multiagente con modelos de lenguaje	7
2.5. Memoria RAG para episodios de decisión	8
2.6. Observabilidad y evaluación del comportamiento agéntico	9
2.7. Datasets públicos de referencia	10
2.8. Síntesis crítica y brecha de investigación	10
3. Arquitectura del sistema	12
3.1. Alcance y objetivos arquitectónicos	12
3.2. Vista lógica del sistema	12
3.3. Arquitectura híbrida de dos ritmos	13
3.4. Orquestación jerárquica mediante LangGraph	14
3.5. Frontera entre agente y ejecutor	15
3.6. Estado ligero y artefactos	15
3.7. Contratos y semántica de las decisiones	15
3.7.1. Contrato común de hipótesis	16
3.7.2. Propuesta, restricción y ejecución	17
3.8. Trazabilidad y procedencia	17
3.9. Arquitectura del subsistema de memoria RAG	18
3.9.1. Recuperación y control de calidad	18
3.9.2. Uso, captura y gobierno	19
3.10. Observabilidad	19
3.11. Fronteras de seguridad y tolerancia a fallos	19
3.12. Invariantes arquitectónicos	20

4. Metodología	21
4.1. Enfoque de investigación	21
4.2. Preguntas e hipótesis de trabajo	21
4.3. Fuentes de evidencia y alcance inferencial	22
4.4. Unidades de análisis	23
4.5. Protocolo <i>run-to-failure</i> por snapshot	23
4.5.1. Preparación y procedencia	23
4.5.2. Procesamiento jerárquico de la señal	23
4.5.3. Partición temporal y prevención de fuga	24
4.5.4. Modelos y papel de los agentes	24
4.5.5. Replay causal y ramas de política	24
4.6. Observación del comportamiento de los agentes	25
4.7. Ciclo experimental de memoria RAG	26
4.7.1. Evidencia canónica e índice derivado	26
4.7.2. Captura, promoción y recuperación	26
4.7.3. Control de calidad y fidelidad	27
4.8. Diseño de ablaciones de memoria	27
4.9. Métricas de evaluación	28
4.9.1. Métricas del comportamiento de los agentes	28
4.9.2. Métricas de recuperación y uso de memoria	29
4.9.3. Métricas PHM y <i>run-to-failure</i>	29
4.10. Comparación posterior de modelos Qwen	30
4.11. Reproducibilidad y análisis	30
4.12. Amenazas a la validez	30
4.13. Estado de aplicación de la metodología	31
5. Implementación	32
5.1. Alcance del capítulo	32
5.2. Principios de implementación	32
5.3. Orquestación multiagente	33
5.3.1. Grafo con supervisor jerárquico	33
5.3.2. Separación entre agente y ejecutor	34
5.3.3. Estado compartido y artefactos	34
5.4. Contratos y trazabilidad de las decisiones	34
5.4.1. Validación estructurada	34
5.4.2. Eventos observables	35
5.4.3. Propuesta del agente y decisión del protocolo	36
5.5. Adaptadores de datos y procedencia	36
5.5.1. Frontera común de entrada	36
5.5.2. Procedencia oficial, sintética y desconocida	37
5.6. Pipeline determinista de señal	37
5.6.1. Manifiesto y perfilado	37
5.6.2. Limpieza y estructuración	38
5.6.3. Modelado y evaluación	38
5.6.4. Flujo <i>run-to-failure</i> implementado	38
5.7. Agentes locales y herramientas seguras	39
5.7.1. Proveedor local	39
5.7.2. Herramientas de observación	39

5.8.	Implementación del ciclo de memoria RAG	40
5.8.1.	Evidencia canónica y representaciones	40
5.8.2.	Captura y candidato pendiente	41
5.8.3.	Cola de revisión y gobierno	41
5.8.4.	Backends e índice vectorial	41
5.8.5.	Compatibilidad de embeddings	42
5.8.6.	Consulta, filtros y sobre-recuperación	42
5.8.7.	Control de calidad previo al prompt	43
5.8.8.	Uso declarado y auditoría	44
5.9.	Generación y verificación de informes	44
5.10.	Persistencia y aplicación local	45
5.10.1.	Instantáneas y paquetes de evidencia	45
5.10.2.	API	45
5.10.3.	Primer replay causal de monitorización	46
5.10.4.	Puente causal entre trigger y revisión multiagente	46
5.10.5.	Gate repetido y publicación de fiabilidad	48
5.10.6.	Síntesis consultiva de recomendaciones de política	49
5.10.7.	Interfaz de usuario	50
5.10.8.	Despliegue reproducible	53
5.11.	Seguridad y reproducibilidad	53
5.12.	Cobertura funcional	55
6.	Diseño experimental y pruebas realizadas	56
6.1.	Propósito y alcance	56
6.2.	Pruebas de ingeniería ya ejecutadas	56
6.2.1.	CWRU como baseline secundario	56
6.2.2.	Pilotos NASA IMS-like sintéticos	58
6.2.3.	Verificación del replay determinista	58
6.2.4.	Gate determinista de activación P3	59
6.2.5.	Protocolo de revisión causal de un trigger P3	59
6.2.6.	Gate repetido sobre los cuatro contextos P3	60
6.2.7.	Verificación focal de la síntesis consultiva multirol	60
6.2.8.	Integración de agentes y memoria RAG	61
6.2.9.	Piloto pareado sobre la trayectoria oficial	61
6.3.	Preparación del caso NASA IMS real	62
6.4.	Puerta de preparación previa al benchmark pesado con Qwen	63
6.5.	Protocolo congelado para el benchmark principal	63
6.5.1.	Caso, vistas y partición temporal	63
6.5.2.	Reducción de ventanas a snapshots	64
6.5.3.	Regímenes de decisión	65
6.6.	Factores, controles y réplicas	65
6.6.1.	Factores experimentales	65
6.6.2.	Variables de control	66
6.6.3.	Unidades y número de repeticiones	66
6.7.	Variables de respuesta	67
6.7.1.	Conducta de los agentes	67
6.7.2.	Recuperación y uso de memoria	68
6.7.3.	Resultados <i>run-to-failure</i>	68

6.8.	Prevención de contaminación experimental	69
6.9.	Artefactos y criterios de validez	69
6.10.	Plan de análisis	70
7.	Resultados	72
7.1.	Alcance de la evidencia disponible	72
7.2.	Resultado previo: preparación del caso NASA IMS real	73
7.3.	H1: decisiones de los agentes válidas, ejecutables y auditables	73
7.3.1.	Resultado de verificación	73
7.3.2.	Estado de H1	77
7.4.	H2: relevancia y fidelidad del ciclo de memoria RAG	79
7.4.1.	Resultado de verificación	79
7.4.2.	Estado de H2	80
7.5.	H3: influencia observable y utilidad de la memoria	81
7.5.1.	Resultado de verificación	81
7.5.2.	Estado de H3	81
7.6.	H4: evaluación temporal a nivel de snapshot	82
7.6.1.	Agregación jerárquica verificada	82
7.6.2.	Baseline causal sobre NASA IMS Set 2 oficial	82
7.6.3.	Paridad entre cálculo batch y replay incremental	84
7.6.4.	Activación determinista P3 sobre el replay NASA	84
7.6.5.	Revisión causal multiagente de un trigger P3	85
7.6.6.	Gate repetido de fiabilidad sobre los triggers P3	85
7.6.7.	Estado de H4	88
7.7.	Resultados secundarios por fuente de datos	88
7.7.1.	Pilotos NASA IMS-like sintéticos	88
7.7.2.	CWRU como referencia secundaria	88
7.8.	Síntesis de las hipótesis	88
7.9.	Resultados que no pueden afirmarse	89
7.10.	Amenazas observadas en la evidencia actual	90
7.11.	Alcance de los resultados	90
8.	Conclusiones	91
8.1.	Síntesis del trabajo	91
8.2.	Contribuciones alcanzadas	92
8.2.1.	Instrumento multiagente trazable	92
8.2.2.	Memoria RAG gobernada y auditable	93
8.2.3.	Procedencia explícita de datos y recuerdos	94
8.2.4.	Evaluación jerárquica <i>run-to-failure</i>	94
8.3.	Estado de las hipótesis	94
8.4.	Limitaciones	95
8.5.	Trabajo futuro	96
8.5.1.	Ampliaciones posteriores	97
8.6.	Conclusión final	98

Índice de figuras

5.1.	Vista web del replay histórico NASA IMS Set 2 una vez procesados los 689 ticks de monitorización. El panel separa el canal modelado de los canales de telemetría, conserva la evolución temporal y declara el alcance P0 sin Qwen, RAG ni activación agentiva.	51
5.2.	Oficina tridimensional sobre el runtime persistido de una ejecución CW-RU. Al seleccionar el estructurador se muestra su hipótesis, la observación esperada, el criterio de refutación y las evidencias declaradas. El estado permanece pendiente de contraste y las líneas se identifican como rutas del supervisor, no como relaciones causales inferidas.	52
7.1.	Fiabilidad por punto de entrada con el contrato común de hipótesis. Las 45 observaciones de la repetición final fueron válidas en el primer intento lógico tras normalización conservadora. La figura no representa una tasa universal ni una valoración de la corrección científica de las hipótesis.	76
7.2.	Captura directa de la auditoría de una ejecución completa CWRU bajo el contrato común. La vista separa las 18 decisiones registradas en el intento lógico 1 de segundas llamadas, respaldos y superposiciones, y presenta para los siete roles su hipótesis, decisión observable, procedencia y enlace causal al ejecutor cuando existe. También mantiene visibles los límites de la evidencia y que las hipótesis continúan pendientes de contraste independiente.	78
7.3.	Captura directa del diagnóstico de preparación del corpus RAG. El backend configurado puede estar operativo y, simultáneamente, el benchmark permanecer bloqueado por falta de recuerdos oficiales, cobertura entre datasets y agentes, revisión de candidatos y manifiesto congelado.	79
7.4.	Captura directa de la ejecución causal PCA sobre NASA IMS Set 2. El eje superior representa $\log_{10}(score/umbral)$ para conservar visibles las fases iniciales ante los valores extremos terminales; el panel inferior muestra el indicador de salud y los episodios agregados por snapshot. La primera alerta persistente no es un onset físico confirmado.	83
7.5.	Gate repetido V3 de revisión multiagente sobre los cuatro contextos P3 y tres sesiones. Las barras, la matriz y las coberturas representan resultados contractuales publicados; no constituyen una medida de veracidad física ni de rendimiento industrial.	87

Índice de tablas

2.1. Lectura comparada de familias de detección de anomalías.	7
3.1. Significado de las representaciones de una decisión.	17
4.1. Taxonomía de las fuentes de evidencia del trabajo.	22
4.2. Condiciones previstas para la ablación de memoria.	27
5.1. Responsabilidades principales de la implementación.	33
6.1. Estado y alcance de las familias experimentales.	57
6.2. Factores del diseño experimental congelado.	65
6.3. Unidades de análisis y política de repeticiones.	67
6.4. Operacionalización de las hipótesis.	67
6.5. Contenido mínimo del paquete de evidencia experimental.	70
7.1. Resultados de las baterías completas del gate repetido P3.	86

Capítulo 1

Introducción

1.1. Contexto y motivación

El mantenimiento predictivo busca reconocer cambios de comportamiento antes de que una avería obligue a detener un activo. En maquinaria rotativa, las señales de vibración permiten observar fenómenos como impactos, desalineación, desbalanceo o degradación de rodamientos. Sin embargo, transformar esas señales en una decisión útil no consiste únicamente en entrenar un detector. También es necesario justificar cómo se prepararon los datos, por qué se eligió un modelo, qué evidencia respalda una alerta y qué limitaciones tiene el resultado.

Los modelos de lenguaje ofrecen una forma flexible de interpretar esa evidencia y coordinar tareas especializadas. Su uso plantea, a la vez, una dificultad metodológica: si el agente responde en texto libre o ejecuta directamente las transformaciones, resulta difícil separar razonamiento, cálculo y error. Este trabajo adopta una separación explícita. Los agentes proponen decisiones estructuradas; los ejecutores deterministas procesan las señales; y todos los pasos relevantes dejan artefactos que pueden revisarse después.

El interés principal no es, por tanto, obtener una única métrica de detección, sino observar si agentes locales relativamente pequeños son capaces de formular hipótesis razonables, utilizar herramientas, revisar resultados y aprender de experiencias anteriores sin perder reproducibilidad.

1.2. Planteamiento del problema

El problema se aborda desde dos escenarios complementarios. CWRU Bearing Data Center proporciona un benchmark etiquetado y acotado que permite comprobar el pipeline y mantener una referencia de regresión [3]. El escenario de investigación principal es NASA IMS Bearing, donde una secuencia de adquisiciones describe la evolución del activo hasta el final del ensayo [14]. En este segundo caso, el objetivo no debe reducirse a clasificar ventanas aisladas: interesa estudiar la tendencia del indicador de salud, la persistencia de las alertas, su tasa antes de monitorización y su posición retrospectiva respecto al final registrado.

Sobre ambos escenarios se incorpora una memoria RAG. Un recuerdo puede ayudar a repetir una decisión útil, advertir sobre un fallo anterior o señalar que una estrategia no es comparable con el caso actual. El riesgo es que una memoria irrelevante, incorrecta o autorreferencial condicione decisiones posteriores. Por ello, recuperar el fragmento

más próximo no es suficiente: el ciclo necesita gobierno, filtrado, citas verificables y evaluación de su efecto.

1.3. Preguntas de investigación

El trabajo se organiza alrededor de las siguientes preguntas:

- PI1:** ¿Pueden agentes basados en modelos de lenguaje locales formular y justificar decisiones técnicas útiles dentro de contratos estrictos, delegando el cálculo en ejecutores reproducibles?
- PI2:** ¿Cómo cambia su razonamiento cuando reciben memoria de decisiones anteriores, y pueden citar, adaptar o rechazar esa memoria de forma trazable?
- PI3:** ¿Qué mecanismos de filtrado y promoción reducen la reutilización de recuerdos incompatibles, no validados o perjudiciales?
- PI4:** ¿Cómo se comporta el sistema en un problema *run-to-failure*, donde la unidad longitudinal es la secuencia de snapshots y las métricas operacionales difieren de una clasificación binaria?
- PI5:** Una vez fijado el protocolo experimental, ¿qué diferencias aparecen entre Qwen 3.5 y Qwen 3 bajo las mismas entradas, herramientas, contratos y condiciones de memoria?

La última pregunta se plantea como comparación posterior. No se deben atribuir diferencias al modelo mientras cambien simultáneamente el dataset, la política temporal o el corpus de memoria.

1.4. Objetivos

1.4.1. Objetivo general

Diseñar y evaluar una plataforma híbrida y auditable para monitorización industrial *run-to-failure*. La propuesta combina un observador determinista frecuente con supervisión multiagente periódica o dirigida por eventos, de modo que los agentes puedan diseñar y auditar políticas de detección antes de un eventual despliegue industrial. El estudio presta especial atención a sus hipótesis y al efecto de una memoria RAG gobernada sobre las decisiones.

1.4.2. Objetivos específicos

1. Coordinar agentes especializados mediante un supervisor jerárquico y representar sus decisiones con esquemas estructurados.
2. Separar el razonamiento generativo de los ejecutores que transforman datos, entrenan modelos y calculan métricas.
3. Mantener trazabilidad de entradas, configuraciones, decisiones, resultados, revisiones y artefactos.

4. Implementar un ciclo de memoria que distinga captura, validación, promoción, recuperación, uso y auditoría.
5. Evaluar la relevancia de la memoria y la fidelidad de las citas, además de su posible efecto sobre configuraciones y resultados.
6. Definir una metodología temporal para NASA IMS que separe ventanas intra-snapshot de observaciones longitudinales por snapshot.
7. Implementar un replay histórico causal que permita ensayar la separación entre monitorización determinista y revisión multiagente sin presentar la simulación como adquisición industrial en tiempo real.
8. Comparar baselines interpretables y modelos de anomalías bajo un mismo protocolo temporal.
9. Preparar una comparación controlada entre Qwen 3.5 y Qwen 3.

1.5. Aportaciones del trabajo

Las aportaciones del trabajo se agrupan en cuatro bloques. En primer lugar, una arquitectura híbrida que mantiene el cálculo frecuente en ejecutores deterministas y hace observable la revisión periódica de los agentes sin permitirles ejecutar código arbitrario. En segundo lugar, un ciclo RAG orientado a episodios de decisión y no solo a documentos: conserva alternativas, evidencia, resultado y condiciones de reutilización. En tercer lugar, un protocolo de evaluación que separa calidad de recuperación, fidelidad de uso, cambio de comportamiento y resultado operacional. Finalmente, una aplicación del enfoque al seguimiento *run-to-failure* de rodamientos mediante replay histórico causal.

1.6. Alcance y limitaciones

El sistema se ejecuta localmente y emplea modelos disponibles mediante Ollama. Los agentes no modifican directamente los datos ni generan código para ejecutarlo. La arquitectura contempla distintos datasets y backends de memoria, pero el estudio no pretende resolver despliegue multiusuario, adquisición continua de planta, planificación distribuida o seguridad productiva. La vista de monitorización reproduce una trayectoria histórica con un reloj acelerado; su semejanza visual con una consola en vivo no acredita latencia, disponibilidad ni integración con sensores industriales.

La evidencia actual debe interpretarse con cautela. CWRU valida el flujo etiquetado y los pilotos sintéticos sirven como pruebas de integración. Sobre NASA IMS Set 2 oficial se dispone ya de un baseline PCA causal que recorre sus 984 snapshots con partición 20/10/70, calibración separada y evaluación longitudinal agregada por adquisición. La vista de decisión oculta a limpiador, estructurador y modelador los campos retrospectivos. Esta única trayectoria permite estudiar el mecanismo y describir la evolución del score, pero no aporta etiquetas continuas de degradación, un onset físico oficial ni evidencia de generalización. Aún es necesario congelar el corpus de memoria y ejecutar ablaciones agénticas con réplicas.

1.7. Estructura del documento

El capítulo 2 revisa mantenimiento predictivo, agentes y memoria RAG. El capítulo 3 presenta la arquitectura y los contratos. El capítulo 4 define la metodología de evaluación agéntica, de memoria y *run-to-failure*. El capítulo 5 resume las decisiones de implementación relevantes, sin reproducir la estructura interna del repositorio. Los capítulos 6 y 7 describen el diseño experimental y los resultados, separando pilotos sintéticos de evidencia real. El capítulo 8 recoge conclusiones, limitaciones y trabajo futuro.

Capítulo 2

Estado del arte

2.1. Mantenimiento predictivo y escenarios *run-to-failure*

La monitorización de condición persigue describir el estado de un activo a partir de observaciones obtenidas durante su funcionamiento. Se sitúa entre el mantenimiento preventivo, que programa intervenciones según tiempo o uso, y el mantenimiento predictivo, que intenta anticipar una pérdida de prestaciones a partir de la evolución observada. En este contexto, el término *Prognostics and Health Management* (PHM) engloba la adquisición de señales, la detección de cambios, la interpretación del estado de salud y, cuando la evidencia lo permite, la estimación de su evolución futura [7, 9].

Conviene distinguir cuatro tareas relacionadas. La **detección de anomalías** determina si una observación se aparta del comportamiento considerado normal. El **diagnóstico** intenta atribuir ese cambio a un modo de fallo. El **pronóstico** estima cómo evolucionará la degradación. Finalmente, la predicción de vida útil remanente trata de cuantificar el tiempo o uso hasta un criterio de fin de vida. Una puntuación de anomalía no resuelve por sí sola las tres tareas restantes: puede señalar un cambio sin identificar su causa ni proporcionar una estimación calibrada del tiempo hasta fallo.

Los experimentos *run-to-failure* son especialmente útiles para estudiar esta diferencia. En ellos, un activo se observa repetidamente desde un estado inicial hasta el final registrado del ensayo. La unidad científica deja de ser una muestra aislada y pasa a ser una trayectoria ordenada. El interés no reside únicamente en separar observaciones normales y anómalas, sino también en saber cuándo aparece un cambio persistente, cuántas falsas alarmas se producen antes de él y con qué anticipación se detecta respecto al evento final.

Esta estructura longitudinal impone cautelas metodológicas. Las observaciones próximas en el tiempo no son independientes; las ventanas extraídas de una misma adquisición comparten señal y condiciones de operación; y una partición aleatoria puede trasladar información futura al entrenamiento. Por ello, el orden temporal, la unidad de agregación y la separación entre ajuste, calibración y evaluación son componentes del problema, no meros detalles de implementación. La existencia de recursos específicos para evaluar sistemas pronósticos también refleja que las métricas de clasificación convencional no cubren por sí solas este escenario [20, 13].

2.2. Señales de maquinaria rotativa e indicadores de salud

En rodamientos, motores y otros sistemas rotativos, la vibración ofrece una medida indirecta de impactos, resonancias, desbalanceo, desalineación y cambios en la transmisión mecánica. La señal cruda contiene información temporal y espectral, pero también ruido, transitorios y variaciones debidas al régimen de operación. El significado de una desviación depende, por tanto, del sensor, la frecuencia de muestreo, la carga, la velocidad y la posición del canal [19, 9].

El procesamiento suele dividir cada adquisición en ventanas y representar cada una mediante estadísticos o descriptores de frecuencia. Medidas como energía, valor cuadrático medio, curtosis, factor de cresta o contenido en bandas permiten reducir una señal extensa a variables comparables. Esta reducción facilita el uso de detectores tabulares, aunque puede ocultar patrones localizados. Los modelos que trabajan directamente con secuencias conservan más estructura, a cambio de requerir más datos, capacidad de cómputo y decisiones de diseño.

En un ensayo longitudinal es importante no confundir las ventanas internas con observaciones independientes del deterioro. Varias ventanas pertenecientes al mismo *snapshot* describen una única captura temporal. Sus puntuaciones pueden resumirse mediante una medida central, percentiles y proporción de alertas, conservando así información sobre la distribución interna sin inflar artificialmente la duración de una racha.

Un **indicador de salud** transforma la evidencia multivariable en una trayectoria interpretable. Un indicador útil debería permanecer estable durante el régimen nominal, reaccionar de forma consistente ante la degradación y evitar oscilaciones que generen alarmas espurias. Monotonicidad, fuerza de tendencia, robustez frente al ruido y diferencia entre los tramos inicial y final son propiedades complementarias; ninguna garantiza por separado que el indicador tenga valor pronóstico. Además, normalizar una curva conociendo su valor final puede ser legítimo para un análisis retrospectivo, pero no para una decisión en línea que solo debe utilizar información disponible hasta el instante actual.

La interpretación causal exige separar esas dos perspectivas. Una vista *online* reproduce lo que habría conocido el sistema en cada instante. La vista retrospectiva incorpora el desenlace una vez cerrada la decisión y permite calcular anticipación u otras métricas referidas al final del ensayo. Mezclarlas favorece conclusiones optimistas y dificulta determinar qué información guio realmente al agente o al detector.

2.3. Familias de detección de anomalías

Cuando las etiquetas de fallo son escasas o inexistentes, es habitual aprender una representación del comportamiento nominal y puntuar después su desviación. Las familias consideradas en este trabajo cubren supuestos diferentes y sirven como referencias comparables, no como una jerarquía universal de rendimiento.

PCA ofrece un baseline interpretable cuando la normalidad puede aproximarse por un subespacio lineal. Isolation Forest utiliza particiones aleatorias y resulta atractivo por su coste moderado y su capacidad para trabajar sin una densidad paramétrica explícita. One-Class SVM modela una frontera de soporte nominal y puede representar

Tabla 2.1: Lectura comparada de familias de detección de anomalías.

Familia	Principio de puntuación	Cautela principal
PCA por reconstrucción	Distancia entre una observación y su reconstrucción en un subespacio de menor dimensión	Puede representar mal relaciones no lineales y depende del escalado de las variables
Isolation Forest	Facilidad con la que una observación queda aislada mediante particiones aleatorias	Su puntuación depende de la muestra de referencia y no explica por sí sola el origen físico de la desviación
One-Class SVM	Separación del soporte nominal mediante una frontera en un espacio transformado	Es sensible al escalado y a hiperparámetros que controlan la forma de la frontera
Local Outlier Factor	Diferencia entre la densidad local de una observación y la de su vecindad	La noción de vecindad puede degradarse con alta dimensión o cambios de régimen
Autoencoder	Error entre la entrada y una reconstrucción aprendida por una red neuronal	Puede reconstruir también patrones no deseados y requiere mayor control de entrenamiento y capacidad

límites no lineales. Local Outlier Factor compara densidades locales y detecta observaciones extrañas respecto a su entorno. Los autoencoders, por su parte, aprenden una función de reconstrucción flexible y emplean el residuo como puntuación [11, 21, 1].

La comparación entre estas familias requiere algo más que aplicar sus valores por defecto. Debe fijar la misma evidencia nominal, impedir fuga temporal, calibrar los umbrales sin consultar el tramo evaluado y mantener constante la unidad de análisis. Un resultado por ventana puede ser útil para entrenar el detector, mientras que persistencia, inicio de degradación y anticipación deben calcularse sobre la secuencia agregada de adquisiciones.

Tampoco existe equivalencia automática entre complejidad y calidad. Un modelo neuronal puede capturar relaciones que un baseline lineal no representa, pero introduce variabilidad de entrenamiento y más grados de libertad. En un estudio centrado en el comportamiento de agentes, disponer de alternativas cerradas y reproducibles es especialmente importante: permite atribuir al agente la selección y su justificación, sin confundirlas con cambios no controlados del procedimiento numérico.

2.4. Sistemas multiagente con modelos de lenguaje

Un sistema multiagente distribuye una tarea entre componentes con responsabilidades diferenciadas. En un pipeline de datos industriales, esta separación puede asignar a distintos agentes el análisis del perfil, la preparación temporal, la selección de modelo, la evaluación y la redacción. Un supervisor coordina el tránsito entre esas responsabilidades y conserva el estado compartido necesario para relacionar cada decisión con su evidencia.

La incorporación de modelos de lenguaje aporta flexibilidad para formular hipótesis y relacionar evidencia heterogénea, pero no convierte sus respuestas en cálculos verificables. El texto libre puede contener campos ausentes, acciones no soportadas o

justificaciones desconectadas de los datos. Por ello, una arquitectura auditable diferencia tres funciones. Esta combinación de razonamiento y acciones externas se relaciona con el patrón estudiado por ReAct, mientras que AgentBench muestra la necesidad de evaluar la actuación en entornos interactivos y no solo la respuesta final [25, 12]:

1. el agente interpreta un expediente y propone una decisión;
2. un contrato estructurado comprueba que la propuesta sea completa y pertenezca al espacio de acciones permitido;
3. una herramienta determinista ejecuta la transformación y calcula el resultado que después podrá interpretar el agente.

Esta separación limita la autonomía operativa, pero mejora la atribución. Si una transformación falla, puede determinarse si la causa fue una hipótesis inadecuada, una propuesta inválida, un guardarraíl o un error del ejecutor. Del mismo modo, una decisión sintácticamente válida no se considera necesariamente correcta: debe contrastarse con la evidencia disponible y con el resultado de la acción elegida.

El uso de herramientas también cambia el objeto de evaluación. No basta con comprobar que el agente produzca una respuesta plausible. Interesa saber si seleccionó la herramienta adecuada, si sus argumentos coinciden con la entrada validada, si incorporó el resultado real y si revisó su hipótesis cuando la evidencia la contradijo. En entornos industriales, esta observabilidad es más defendible que conceder al modelo capacidad para generar y ejecutar código arbitrario.

2.5. Memoria RAG para episodios de decisión

La generación aumentada por recuperación, o RAG, añade al contexto del modelo fragmentos seleccionados desde una colección externa. En su aplicación más habitual, esos fragmentos proceden de documentos. En un sistema multiagente también pueden representar **episodios de decisión**: el contexto observado, la hipótesis, las alternativas, la acción elegida, la evidencia posterior y las condiciones bajo las cuales la experiencia podría reutilizarse [10, 22].

Esta memoria externa no debe confundirse con el estado transitorio del grafo ni con el historial completo de una conversación. Su propósito es recuperar experiencia potencialmente pertinente entre ejecuciones. Para ello, el ciclo completo comprende al menos captura, validación, promoción, indexación, recuperación, uso y auditoría. La captura automática conserva trazabilidad, pero no debería otorgar por sí misma autoridad para reutilizar un episodio.

La similitud semántica es solo una señal de relevancia. Dos recuerdos pueden usar vocabulario próximo y, sin embargo, corresponder a datasets, sensores, agentes, tareas o procedencias incompatibles. Los metadatos permiten aplicar restricciones previas por rol, dominio, fuente de datos, estado de revisión y condiciones de reutilización. Después de recuperar candidatos, un control de calidad puede excluir recuerdos demasiado genéricos, contradictorios o carentes de evidencia suficiente. La variación de resultados entre dominios observada en BEIR respalda el uso de baselines y juicios de relevancia específicos, en lugar de asumir un recuperador universalmente superior [23].

Los principales riesgos no se limitan a una recuperación vacía:

Irrelevancia. Un recuerdo semánticamente próximo puede no ser aplicable al contexto técnico presente.

Contaminación. Evidencia sintética, no verificada o perteneciente al tramo de evaluación puede introducir información que el agente no debería conocer.

Obsolescencia. Una experiencia útil bajo un contrato o una política anterior puede dejar de ser compatible tras un cambio metodológico.

Autoreforzo. Si los resúmenes del propio uso de memoria se convierten de nuevo en recuerdos reutilizables, una afirmación puede adquirir prominencia por repetición y no por nueva evidencia.

Autoridad indebida. La presencia de un fragmento recuperado puede hacer que el agente lo siga aunque contradiga el expediente actual.

Por estas razones, el índice vectorial debe entenderse como una vista derivada y reconstruible, mientras que el episodio validado conserva el contenido y el gobierno canónicos. La elección entre una base vectorial especializada, una extensión vectorial de una base relacional o una búsqueda exacta afecta a la operación y a la escalabilidad, pero no resuelve por sí sola la relevancia ni la calidad del recuerdo. Presentar un backend concreto como universalmente superior confundiría una decisión de ingeniería con una conclusión científica.

La evaluación de la memoria necesita, al menos, tres niveles. El primero mide si se recuperó evidencia compatible. El segundo comprueba si el agente la citó, adaptó o rechazó con fidelidad. El tercero observa si su presencia modificó la hipótesis, la configuración o la revisión posterior, y si ese cambio resultó beneficioso, neutro o perjudicial. Una mejora de similitud no implica necesariamente una mejora de decisión. RAGTruth aporta además evidencia de que disponer de contexto recuperado no elimina las respuestas no fieles, por lo que retrieval y anclaje deben medirse por separado [16].

2.6. Observabilidad y evaluación del comportamiento agéntico

El objetivo de observar agentes no exige almacenar razonamientos privados ni tratar una explicación extensa como verdad interna. Resulta más sólido registrar salidas conductuales verificables: el expediente recibido, la hipótesis declarada, las alternativas consideradas, la acción propuesta, las herramientas consultadas, las referencias utilizadas, la confianza expresada y el resultado determinista posterior.

Esta traza permite separar varios conceptos que con frecuencia se agregan bajo la etiqueta de éxito. La **validez contractual** indica que la salida cumple el esquema. La **ejecutabilidad** confirma que la acción pertenece al repertorio disponible. El **anclaje en evidencia** comprueba que las afirmaciones y citas se corresponden con el expediente o los recuerdos. La **capacidad de revisión** observa si el agente modifica su postura ante un resultado contrario. Finalmente, la **utilidad operacional** se valora con las métricas reproducibles del problema industrial.

Benchmarks de agentes y trabajos con memoria episódica refuerzan dos cautelas: la conducta debe evaluarse en interacción con el entorno y una reflexión textual solo adquiere valor cuando se vincula con feedback y desempeño posterior [12, 22]. En

este TFM esa idea se traslada a herramientas deterministas y resultados industriales auditables.

También deben distinguirse los fallos del agente de los del sistema que lo rodea. Una corrección automática de formato, un rechazo por guardarraíl, una indisponibilidad del proveedor y una decisión determinista de respaldo tienen significados diferentes. Si todos se registran como una respuesta válida del modelo, se sobreestima su participación real y se pierde la posibilidad de diagnosticar el proceso.

Los estudios comparativos requieren condiciones controladas. Una ablación con y sin memoria mantiene constantes el expediente, las herramientas, el modelo y el presupuesto de generación. Una comparación entre modelos de lenguaje fija además los contratos, prompts y corpus recuperable. Las réplicas permiten observar variabilidad, mientras que una evaluación humana ciega puede valorar corrección, suficiencia, coherencia y seguridad sin conocer la condición experimental. Estas medidas no sustituyen las métricas del detector; responden a una pregunta diferente sobre cómo se produjo la decisión.

2.7. Datasets públicos de referencia

Los benchmarks públicos cumplen papeles distintos y no deben tratarse como evidencia intercambiable. CWRU Bearing Data Center reúne señales de referencia y fallos inducidos en rodamientos bajo condiciones documentadas [3, 4, 2]. Su estructura etiquetada resulta apropiada para comprobar clasificación de fallos, compatibilidad del pipeline y comportamiento de modelos sobre clases conocidas. No representa, sin embargo, una trayectoria natural de degradación completa.

NASA IMS Bearings proporciona secuencias de vibración adquiridas durante ensayos de rodamientos hasta el final registrado y constituye la referencia principal para el análisis longitudinal de este trabajo [19, 14, 15, 5]. Su valor metodológico reside en el orden de los *snapshots* y en la posibilidad de estudiar cambios sostenidos. La interpretación exige conservar activo, canal, marca temporal y ensayo, además de documentar cualquier etiqueta derivada que no forme parte de la fuente oficial.

XJTU-SY y el reto pronóstico IEEE PHM 2012 constituyen referencias adicionales de datasets de degradación de rodamientos [24, 6]. Permiten situar NASA IMS dentro de una familia más amplia de ensayos *run-to-failure*, con condiciones y protocolos propios. Su existencia no autoriza a trasladar umbrales, etiquetas o conclusiones entre colecciones sin una validación específica.

La procedencia es parte de la validez experimental. Una señal generada para probar la integración puede reproducir dimensiones o tendencias plausibles, pero no se convierte por ello en evidencia del dataset oficial. Del mismo modo, una etiqueta temporal construida por el investigador debe diferenciarse de un modo de fallo documentado por la fuente. Esta distinción afecta al entrenamiento, a la presentación de resultados y a los recuerdos que puedan promoverse para futuras decisiones.

2.8. Síntesis crítica y brecha de investigación

La literatura y los recursos revisados delimitan tres líneas que habitualmente se estudian por separado. PHM se centra en transformar señales en indicadores, alertas y pronósticos; los sistemas agénticos se ocupan de coordinar decisiones y herramientas; y

RAG aporta contexto externo recuperable. La intersección de las tres plantea preguntas que no quedan resueltas al optimizar únicamente un detector o un índice vectorial.

En particular, persiste la necesidad de estudiar si un agente formula hipótesis técnicamente defendibles, cómo reacciona a evidencia calculada por herramientas y cuándo una experiencia recuperada mejora o perjudica su decisión. En un escenario *run-to-failure*, esta evaluación debe respetar causalidad, procedencia y dependencia temporal. De lo contrario, una memoria contaminada o una agregación incorrecta puede parecer una mejora del razonamiento cuando en realidad introduce información futura o pseudorreplicación.

Este TFM se posiciona en esa intersección. Propone estudiar agentes especializados que deciden dentro de contratos, delegan el cálculo en ejecutores reproducibles y utilizan una memoria de episodios gobernada. El caso principal es el seguimiento longitudinal de maquinaria rotativa; el objeto de observación es tanto la calidad operacional del pipeline como la conducta verificable del agente ante evidencia, herramientas y recuerdos. Esta formulación define el problema de investigación, pero no anticipa resultados.

La revisión reúne fuentes primarias y revisiones académicas para los tres bloques, además de las fuentes oficiales que sostienen la procedencia de los datasets. Aun así, la literatura localizada no proporciona un protocolo ya establecido para evaluar conjuntamente agentes locales, memoria episódica gobernada y una trayectoria industrial *run-to-failure*. Esa ausencia justifica tratar la intersección como brecha de investigación, pero no permite presentar la arquitectura propuesta como superior antes de ejecutar sus ablaciones y contrastes.

Capítulo 3

Arquitectura del sistema

3.1. Alcance y objetivos arquitectónicos

La arquitectura define cómo se distribuyen las responsabilidades, qué información puede atravesar cada frontera y qué evidencias deben conservarse. No prescribe el protocolo experimental, que se desarrolla en el capítulo 4, ni describe los detalles concretos de construcción, tratados en el capítulo 5. Su función es proporcionar una estructura estable para estudiar el comportamiento de los agentes sin confundir razonamiento generativo, cálculo numérico y gobierno de la evidencia.

El diseño persigue cinco propiedades principales:

1. **Auditabilidad:** toda decisión relevante debe poder relacionarse con la evidencia recibida, la propuesta emitida y la acción finalmente ejecutada.
2. **Reproducibilidad:** las transformaciones de datos y el cálculo de métricas deben repetirse a partir de configuraciones validadas, sin depender de texto libre producido por un modelo de lenguaje.
3. **Seguridad por reducción de capacidades:** los agentes eligen entre operaciones declaradas, pero no escriben ni ejecutan código arbitrario sobre los datos.
4. **Modularidad:** la orquestación, los ejecutores, la persistencia y el backend vectorial se relacionan mediante contratos, de modo que puedan evolucionar sin cambiar el significado científico de una ejecución.
5. **Comparabilidad experimental:** la arquitectura distingue las elecciones del agente de las restricciones impuestas por el protocolo y conserva ambas de forma explícita.

Estas propiedades son especialmente importantes en el escenario *run-to-failure*. La secuencia temporal, la procedencia del conjunto y la granularidad de las observaciones condicionan cualquier interpretación. Por ello, no se consideran metadatos accesorios, sino parte del contexto que acompaña a las decisiones y a la memoria.

3.2. Vista lógica del sistema

La solución se organiza alrededor de dos flujos relacionados. El **flujo de control** coordina agentes, validaciones y transiciones. El **flujo de datos** transforma señales

mediante operaciones deterministas y produce artefactos verificables. Un plano transversal de evidencia conserva el estado, las decisiones, los resultados y la memoria.

De forma resumida, la relación entre estos elementos es:

evidencia de entrada $\longrightarrow$ propuesta del agente $\longrightarrow$ configuración efectiva
 $\longrightarrow$ ejecución determinista $\longrightarrow$ resultado auditable.

La flecha representa una relación de dependencia, no una cesión automática de control. Entre cada elemento existe una validación. Una propuesta puede ser rechazada, reparada o limitada antes de convertirse en configuración efectiva; un resultado fallido se registra como tal y no se sustituye por una narración plausible.

Desde el punto de vista lógico pueden distinguirse cuatro responsabilidades:

Orquestación. Mantiene el progreso del proceso y decide qué rol puede actuar a continuación.

Razonamiento. Formula hipótesis, propone configuraciones e interpreta evidencia dentro de contratos cerrados.

Ejecución. Lee artefactos, aplica operaciones previamente implementadas y devuelve resultados estructurados.

Evidencia y memoria. Persiste el historial canónico, permite recuperar experiencias compatibles y registra su gobierno posterior.

Esta separación evita que la interfaz de usuario, el almacenamiento o una base vectorial se conviertan en propietarios de la lógica científica. Cualquiera de estas piezas puede sustituirse mientras se mantengan los contratos y la semántica de los artefactos.

3.3. Arquitectura híbrida de dos ritmos

La propuesta distingue dos ritmos de actuación. El **bucle determinista** consume cada observación, aplica una preparación y un modelo congelados, calcula el score, lo contrasta con el umbral y actualiza el estado de salud. Este bucle no necesita una llamada al modelo de lenguaje y representa la parte que, tras una validación externa, podría ejecutarse con alta frecuencia en una instalación. El **bucle multiagente** se activa con menor frecuencia, mediante un calendario o un evento persistente, y recibe un expediente causal resumido. Su responsabilidad es formular hipótesis, interpretar el episodio y proponer mantener o revisar una política; no sustituir el scoring de cada observación.

La relación conceptual es:

observaciones $\longrightarrow$ scoring determinista frecuente $\longrightarrow$ estado y eventos,
evento o calendario $\longrightarrow$ revisión multiagente $\longrightarrow$ propuesta auditable.

Para evitar que ambas responsabilidades se confundan, la política de *scoring* y la política de activación de agentes tienen identidad y huella independientes. Cada

observación cita la versión del detector que la produjo; cada evento cita la regla de activación que lo emitió. Una propuesta agéntica no se aplica retroactivamente y requiere validación estructural, causal y, cuando corresponda, revisión humana.

La evaluación contempla dos ramas sobre el mismo historial. En la rama **congelada**, modelo, umbral y política permanecen fijos y las propuestas de los agentes se registran sin modificar la trayectoria. Esta rama actúa como referencia científica. En la rama **adaptativa exploratoria**, una propuesta validada podría entrar en vigor solo para observaciones posteriores y crear una nueva versión de política. Compararlas permite distinguir qué habría ocurrido sin adaptación de lo que ocurre al aplicar una propuesta; no convierte el replay histórico en un despliegue prospectivo ni demuestra por sí solo mejora industrial.

3.4. Orquestación jerárquica mediante LangGraph

El flujo se representa como un grafo de estados coordinado por un supervisor jerárquico mediante LangGraph [8]. El supervisor observa una vista resumida del estado, comprueba el progreso alcanzado y selecciona una transición de un conjunto finito. Tras una decisión especializada o una ejecución, el control vuelve al supervisor. Esta topología permite hacer explícitas la continuación, el reintento, la revisión humana y la terminación.

El supervisor no sustituye las precondiciones del sistema. Que solicite una transición no implica que esta pueda ejecutarse: el nodo receptor valida que existan las entradas necesarias, que la etapa sea admisible y que la configuración cumpla su contrato. Así se evita que una respuesta generativa salte pasos obligatorios o introduzca una operación no contemplada.

Los roles especializados corresponden a responsabilidades técnicas, no a procesos autónomos con acceso irrestricto:

- el **limpiador** interpreta el perfil de calidad y propone una preparación de la señal;
- el **estructurador** plantea la representación temporal, las variables y la política de partición;
- el **modelador** propone una familia de detector y sus parámetros dentro del catálogo permitido;
- el **evaluador** interpreta métricas, limitaciones y criterios de aceptación;
- el **redactor** compone un informe técnico a partir de evidencia validada;
- el **verificador** contrasta afirmaciones del informe con la evidencia disponible.

La revisión humana constituye otra transición explícita. Se reserva para decisiones costosas, excepcionales o con efecto sobre el gobierno de la memoria. No funciona como una corrección informal fuera del sistema: su decisión, autoría y justificación forman parte de la traza.

La arquitectura no adopta un enjambre de agentes que negocian libremente. La jerarquía y el estado compartido limitan qué información consume cada rol y qué salida puede producir. Esta decisión reduce interacciones difíciles de reproducir y facilita atribuir una propuesta a su autor.

3.5. Frontera entre agente y ejecutor

Cada etapa que requiere criterio se divide en una parte generativa y otra determinista. El agente recibe un expediente compacto: contexto del problema, resúmenes estadísticos, opciones soportadas, recuerdos admitidos y advertencias. Su salida principal es una propuesta estructurada. El ejecutor recibe únicamente la configuración ya validada, realiza el cálculo y devuelve referencias a los artefactos, métricas y errores producidos.

Esta frontera mantiene una asignación de responsabilidades inequívoca. Una hipótesis, una preferencia entre alternativas o una interpretación pertenece al agente. La lectura de señales, el ajuste de un modelo, la calibración de un umbral y el cálculo de métricas pertenecen a los ejecutores. En consecuencia, una explicación no puede reemplazar un resultado computado, y una variación numérica no se atribuye al agente sin reconstruir antes qué configuración llegó a ejecutarse.

Los ejecutores solo exponen operaciones conocidas y comprobables. No evalúan código generado durante la ejecución ni conceden acceso general al sistema de archivos. Cuando se ofrecen herramientas de observación a un agente, estas son de solo lectura, están vinculadas a su rol y devuelven resultados acotados. La misma regla se aplica a las políticas de respaldo: si una salida generativa no es válida y se emplea una decisión determinista, la causa y la autoría del respaldo deben quedar diferenciadas.

3.6. Estado ligero y artefactos

El estado compartido actúa como contrato de coordinación. Contiene el contexto del proyecto, el progreso del grafo, las configuraciones vigentes, resúmenes, métricas, aprobaciones, errores y referencias a artefactos. No incorpora señales completas, matrices de ventanas ni modelos entrenados. Estos objetos permanecen fuera del estado y se accede a ellos mediante referencias controladas.

Mantener un estado ligero ofrece tres ventajas. En primer lugar, facilita su serialización y revisión. En segundo lugar, evita duplicar objetos voluminosos al atravesar nodos del grafo. Finalmente, obliga a declarar de forma explícita qué artefacto produce cada ejecutor y qué consumidor puede utilizarlo.

Una referencia de artefacto identifica al menos su tipo lógico, origen, productor y metadatos de integridad. El estado conserva la relación entre artefactos, pero no utiliza rutas locales como explicación académica ni como identidad científica. Para una comparación reproducible importan el contenido, la versión de los contratos y la configuración, no la ubicación concreta de un fichero en una máquina.

El contexto acompaña al estado durante todo el flujo e incluye las dimensiones que modifican el significado de una decisión: conjunto de datos, activo, ensayo, unidad temporal, perfil de supervisión, procedencia y fuente de las etiquetas. De este modo, una clasificación supervisada por ventana y una trayectoria longitudinal no se presentan como problemas equivalentes.

3.7. Contratos y semántica de las decisiones

Las fronteras de la arquitectura utilizan objetos estructurados con tipos y campos declarados. Se distinguen cuatro familias conceptuales de contrato:

1. **contexto y estado**, que describen la ejecución y su progreso;
2. **propuestas**, que contienen hipótesis, alternativas, justificación, confianza, evidencia y configuración sugerida;
3. **resultados de ejecución**, que contienen estado, métricas, artefactos y errores;
4. **eventos y registros de evidencia**, que relacionan decisiones, recuperaciones de memoria, revisiones y transiciones.

La validación se aplica en varios niveles. La validación sintáctica comprueba que la salida pueda interpretarse como el objeto esperado. La validación semántica examina coherencia entre campos y contexto. La validación de ejecutabilidad confirma que la operación existe, que sus parámetros están dentro de los límites y que se cumplen sus precondiciones. Superar el primer nivel no implica superar los dos restantes.

Los contratos rechazan campos inesperados y hacen explícita la ausencia de un valor. Esta política reduce la ambigüedad y evita que una explicación en texto libre introduzca instrucciones laterales. Los errores también son objetos del sistema: incluyen etapa, categoría y detalle suficiente para decidir si el flujo debe reintentarse, solicitar revisión o finalizar.

3.7.1. Contrato común de hipótesis

Para que el comportamiento pueda compararse entre roles, toda decisión nueva de un agente incorpora una hipótesis operativa con la misma estructura. Esta hipótesis no es una transcripción del razonamiento interno, sino una afirmación comunicable que puede someterse a contraste. El contrato identifica su tipo, enunciado y ámbito; fija qué evidencia estaba disponible al decidir; declara qué observación se espera y qué resultado la refutaría; y conserva referencias de evidencia, riesgos y supuestos. La justificación, la confianza, las alternativas y la acción permanecen como dimensiones distintas de la decisión: una explicación extensa o una confianza alta no sustituyen un criterio de refutación.

La semántica concreta depende de la responsabilidad del rol:

Supervisor. Plantea si el estado contiene los prerequisites para la transición propuesta o para el cierre del flujo.

Limpiador. Plantea si la preparación reducirá defectos observados sin destruir continuidad ni señal útil.

Estructurador. Plantea si ventanas, variables y particiones producirán una representación informativa sin fuga temporal o entre grupos.

Modelador. Plantea el comportamiento esperado del detector sobre datos no utilizados para su ajuste, dentro del perfil de supervisión vigente.

Evalúador. Plantea si la evidencia cerrada satisface los criterios del veredicto operativo y sus límites de interpretación.

Redactor. Plantea si el informe puede comunicar resultados y limitaciones sin añadir afirmaciones no respaldadas. Cuando revisa el informe, la hipótesis se refiere a la eficacia de las correcciones, no se introduce un octavo rol.

Verificador. Plantea si el estado asignado al informe es coherente con el catálogo cerrado de evidencias.

El bloque se formula antes de conocer el resultado que debe contrastarlo. En particular, que un ejecutor finalice correctamente solo acredita que la acción se materializó; no confirma la hipótesis del agente. Una valoración posterior deberá enlazar observaciones independientes y clasificarla como apoyada, refutada o inconclusa. Mientras ese contraste no exista, su estado correcto es *pendiente de contraste*. Las decisiones históricas que no conservaron este bloque continúan identificadas como incompletas y no se reconstruyen a partir de su justificación textual.

3.7.2. Propuesta, restricción y ejecución

La propuesta del agente y la configuración ejecutada se conservan por separado. Entre ambas puede actuar una restricción metodológica, un guardarraíl, una reparación validada o una política de respaldo. La traza debe mostrar qué campos se modificaron y por qué.

Tabla 3.1: Significado de las representaciones de una decisión.

Representación	Pregunta que responde	Autoridad
Propuesta del agente	¿Qué hipótesis y acción sugirió el rol generativo?	Agente especializado
Resolución del protocolo	¿Qué restricciones, correcciones o sustituciones se aplicaron?	Contratos, guardarraíles y protocolo experimental
Configuración efectiva	¿Qué parámetros recibió el ejecutor?	Orquestación validada
Resultado observado	¿Qué produjo realmente la operación?	Ejecutor determinista

Esta distinción es necesaria para evaluar la influencia de la memoria. Un recuerdo puede modificar una propuesta, pero no el resultado operacional si el protocolo fija después la configuración. Inversamente, una corrección del sistema no demuestra que el agente hubiera formulado por sí mismo la decisión ejecutada.

3.8. Trazabilidad y procedencia

La trazabilidad se concibe como una cadena de evidencia y no como una colección de mensajes de registro. Para cada resultado debe poder reconstruirse la relación:

datos y procedencia $\longrightarrow$ perfil y contexto
 $\longrightarrow$ propuesta $\longrightarrow$ configuración efectiva
 $\longrightarrow$ artefactos y métricas $\longrightarrow$ evaluación.

Cada elemento conserva identidad propia y referencias al anterior. Esta relación permite determinar qué evidencia estaba disponible en el momento de la decisión y evita reconstrucciones retrospectivas que incorporen información futura.

La procedencia de los datos se representa como *oficial*, *sintética* o *desconocida*. Se mantiene separada de la fuente y granularidad de las etiquetas: un conjunto oficial

puede emplear etiquetas proxy derivadas del tiempo, mientras que una señal sintética puede disponer de una verdad de generación exacta. Ambas dimensiones se propagan al manifiesto, las decisiones, los resultados, los informes y los episodios de memoria.

Las afirmaciones del informe técnico deben derivarse de un catálogo de evidencias. El redactor puede organizar e interpretar la información, pero el verificador impide atribuir a una fuente oficial un resultado cuya procedencia sea sintética o no verificada. Esta frontera protege tanto la reproducibilidad como el alcance inferencial del trabajo.

3.9. Arquitectura del subsistema de memoria RAG

La memoria RAG reutiliza episodios de decisión, no fragmentos aislados de texto. Un episodio relaciona contexto, alternativas, acción elegida, evidencia, resultado, limitaciones y condiciones de reutilización. Esta estructura permite recuperar no solo recomendaciones positivas, sino también advertencias, casos frontera y decisiones que no deberían repetirse.

El subsistema separa dos planos. La **evidencia canónica** está formada por objetos estructurados y auditables: episodios, candidatos, decisiones de gobierno y auditorías. El **índice de recuperación** es una representación derivada de esa evidencia. Puede reconstruirse sin alterar el historial ni el significado de los recuerdos.

La separación permite utilizar una representación JSON con búsqueda exacta como referencia reproducible y Qdrant como índice filtrable opcional. El resto de la arquitectura no depende de las particularidades de ninguno de los dos. Un backend alternativo, como pgvector, puede incorporarse detrás del mismo contrato, pero la elección tecnológica no constituye por sí misma una conclusión científica sobre la calidad de la memoria.

3.9.1. Recuperación y control de calidad

La consulta de memoria sigue una secuencia controlada:

consulta estructurada $\longrightarrow$ filtrado de elegibilidad $\longrightarrow$ recuperación vectorial
 $\longrightarrow$ control de calidad $\longrightarrow$ contexto efectivo.

La elegibilidad considera el agente destinatario, el conjunto de datos, la procedencia, el perfil experimental, el rol del recuerdo, su veredicto y su estado de gobierno. Los recuerdos oficiales y sintéticos incompatibles no se mezclan. La metodología compartida puede reutilizarse entre conjuntos cuando su contrato lo declara y no contiene una afirmación empírica específica.

La similitud semántica ordena candidatos compatibles, pero no decide por sí sola qué recibe el agente. El recuperador solicita más elementos que el presupuesto final para compensar los descartes posteriores. El control de calidad clasifica cada recuerdo como apto, utilizable con cautela o excluido, y solo el contexto efectivo atraviesa la frontera del prompt. Los ejemplos negativos y las advertencias se presentan con orientación preventiva, no como recomendaciones positivas.

El espacio vectorial también forma parte del contrato. Proveedor, modelo, versión y dimensión del embedding deben ser compatibles con el índice consultado. Un cambio de representación exige reconstrucción explícita y no puede mezclar silenciosamente vectores distintos.

3.9.2. Uso, captura y gobierno

El agente referencia los recuerdos del contexto efectivo mediante identificadores y declara si los sigue, adapta, contradice, rechaza o ignora. La auditoría compara esta declaración con lo que fue recuperado y con la configuración que finalmente se ejecutó. Por tanto, una cita no se interpreta automáticamente como influencia ni una influencia como mejora.

Después de una decisión puede capturarse un nuevo episodio y destilarse un candidato. El candidato nace como no reutilizable: observar una experiencia no equivale a validarla. Esta regla evita que el sistema transforme sus propias salidas en conocimiento aceptado mediante un ciclo de autorrefuerzo.

La promoción, exclusión, restauración o retirada de un recuerdo requieren una decisión de gobierno persistente. Las decisiones humanas conservan revisor, motivo y vínculo exacto con la evidencia revisada. Una promoción deja de ser válida si cambia el objeto de origen. Una retirada mantiene una marca auditable para impedir que una reconstrucción del índice reintroduzca el recuerdo. Las auditorías de uso son evidencia para evaluar el sistema, pero no se convierten ellas mismas en recuerdos reutilizables.

El ciclo completo queda así separado en captura, revisión, indexación, recuperación, control de calidad, uso declarado, resultado y nueva auditoría. Cada transición conserva su evidencia y ninguna promoción se deriva únicamente de proximidad vectorial o de una ejecución aislada.

3.10. Observabilidad

La observabilidad tiene como objetivo evaluar conductas comunicables y efectos verificables. No pretende registrar una cadena de pensamiento privada. Para cada intervención nueva del agente conserva el bloque común de hipótesis, la evidencia consultada, las alternativas, la acción propuesta, la confianza y las limitaciones reconocidas.

La traza de ejecución añade transiciones del grafo, validaciones, herramientas consultadas, configuración efectiva, artefactos, métricas, errores y revisiones. La traza RAG distingue el conjunto elegible, los resultados del recuperador, los descartes del control de calidad, el contexto efectivo, las citas del agente y la influencia sobre propuesta y ejecución.

Estas tres perspectivas permiten responder preguntas diferentes: qué quiso hacer el agente, qué autorizó el sistema y qué ocurrió finalmente. La interfaz de observación consume esa evidencia, pero no la modifica ni se convierte en fuente canónica. Sus representaciones bidimensional y tridimensional comparten el mismo objeto semántico: muestran el rol, la hipótesis, la observación esperada, el criterio de refutación, la evidencia enlazada, la acción y el estado de contraste. La vista espacial añade contexto sobre transiciones y relaciones verificadas, pero no infiere causalidad por la mera proximidad de eventos. Del mismo modo, solo presenta uso de memoria o de herramientas cuando existe una observación estructurada que lo acredita.

3.11. Fronteras de seguridad y tolerancia a fallos

La principal frontera de confianza separa el contenido generado de las operaciones con efectos. Todo objeto producido por un agente se considera no confiable hasta que supera su contrato y las comprobaciones de ejecutabilidad. Los ejecutores operan con

funciones declaradas, entradas acotadas y destinos controlados. Las herramientas de observación limitan rol, propósito y ámbito de los datos consultables.

La persistencia y la recuperación aplican defensa en profundidad. Los filtros del índice reducen el conjunto candidato y el control local vuelve a validar los registros antes de construir el contexto. La evidencia canónica permite reconstruir un índice dañado o incompatible. La indisponibilidad del backend vectorial puede tratarse como un fallo explícito o mediante el backend de referencia, siempre que la condición utilizada quede registrada y no se mezclen resultados experimentales de configuraciones distintas.

Los fallos se propagan como estados estructurados. Un reintento tiene un límite y conserva sus causas; una política de respaldo queda marcada como tal; una revisión humana no sobrescribe la evidencia previa. El sistema favorece el fallo visible frente a continuar con una configuración ambigua o con procedencia contradictoria.

3.12. Invariantes arquitectónicos

Las decisiones anteriores se resumen en los siguientes invariantes:

- ningún agente transforma directamente las señales ni ejecuta código generado durante el flujo;
- toda acción con efectos procede de una configuración validada y queda vinculada a su propuesta, restricciones y resultado;
- el estado compartido contiene referencias y resúmenes, no los datos completos;
- la procedencia y la fuente de etiquetas permanecen diferenciadas y se propagan de extremo a extremo;
- la evidencia canónica no depende del índice vectorial y puede reconstruirlo;
- ningún candidato de memoria se reutiliza por el mero hecho de haber sido capturado;
- la observabilidad conserva explicaciones declaradas y hechos verificables, no inferencias sobre razonamiento interno;
- las restricciones del protocolo tienen prioridad sobre una propuesta generativa y su intervención queda registrada.

Estos invariantes delimitan el espacio en el que se evalúan posteriormente los agentes y la memoria. El capítulo metodológico define cómo medir su comportamiento; el capítulo de implementación muestra cómo se materializan estas fronteras sin cambiar su significado.

Capítulo 4

Metodología

4.1. Enfoque de investigación

Este trabajo adopta un diseño experimental orientado a estudiar el comportamiento de agentes basados en modelos de lenguaje dentro de un sistema industrial trazable. El objetivo científico no es comparar bases vectoriales ni maximizar de forma aislada una métrica de clasificación. Se pretende observar cómo los agentes formulan hipótesis, seleccionan acciones, utilizan evidencia recuperada, revisan decisiones y reconocen limitaciones en un escenario de degradación *run-to-failure*.

La arquitectura se utiliza como instrumento de investigación. Los agentes producen decisiones estructuradas y los ejecutores deterministas realizan el cálculo, la transformación de datos y el entrenamiento de modelos. Esta separación permite atribuir al agente la hipótesis y la elección, pero no una operación numérica que en realidad haya sido programada. También permite repetir una misma configuración sin depender de código generado dinámicamente.

El estudio combina tres niveles de evaluación: la calidad de las decisiones de los agentes, el funcionamiento y efecto de la memoria RAG, y la utilidad de las decisiones en el seguimiento temporal del activo. Los tres niveles se analizan por separado antes de relacionarlos. Una recuperación técnicamente correcta no implica que el agente haya usado bien el recuerdo, y una decisión bien justificada no implica necesariamente una mejora del detector.

4.2. Preguntas e hipótesis de trabajo

Las preguntas de investigación formuladas en la introducción se operacionalizan mediante las siguientes hipótesis:

- H1.** Los agentes locales pueden convertir un expediente técnico en una decisión válida y ejecutable dentro de los contratos definidos, dejando una justificación, una hipótesis y referencias de evidencia auditables.
- H2.** El filtrado por metadatos y el control de calidad previo a la inyección aumentan la relevancia y la fidelidad de las citas respecto a una recuperación sin ese control, y reducen la exposición a recuerdos incompatibles o inseguros.
- H3.** La memoria filtrada puede modificar de forma observable las hipótesis, alternativas, configuraciones o revisiones del agente frente a la condición sin memoria. El

cambio se considerará beneficioso solo si la auditoría y las métricas posteriores lo respaldan.

- H4.** Evaluar la alerta algorítmica persistente, su intervalo retrospectivo hasta el final registrado y la tasa de alertas previa a monitorización a nivel de snapshot, en lugar de tratar ventanas solapadas como observaciones longitudinales independientes, produce una interpretación temporal más conservadora y evita pseudorreproducción.

La comparación entre Qwen 3.5 y Qwen 3 se considera una pregunta experimental posterior, no una conclusión disponible. Solo se abordará después de congelar el dataset, los contratos, los prompts, las herramientas, el corpus de memoria y el protocolo temporal. De este modo, una diferencia observada podrá asociarse al modelo con menos factores de confusión.

4.3. Fuentes de evidencia y alcance inferencial

Se establecen tres categorías de datos con funciones distintas. Esta separación es obligatoria tanto en los planes experimentales como en tablas, figuras e informes.

Tabla 4.1: Taxonomía de las fuentes de evidencia del trabajo.

Fuente	Función metodológica	Unidad principal	Alcance de las conclusiones
NASA IMS real	Escenario empírico principal <i>run-to-failure</i>	Snapshot y trayectoria del activo	Evidencia sobre las trayectorias analizadas, sin generalización automática a planta
CWRU	Benchmark secundario y prueba de regresión del pipeline	Fichero y ventana etiquetada	Validación del flujo binario y de compatibilidad, no de degradación longitudinal
NASA IMS-like sintético	Piloto de integración y comportamiento de los agentes	Snapshot generado y trayectoria sintética	Contratos, trazabilidad y ejecución; nunca evidencia empírica sobre NASA IMS real

NASA IMS real constituye la fuente principal [14, 15]. Su trayectoria se ha procesado con el protocolo causal definido en este capítulo; quedan pendientes las comparaciones agénticas, las réplicas y la validación externa. CWRU se mantiene como referencia secundaria etiquetada [3, 4, 2]. Los pilotos sintéticos ya disponibles permiten comprobar el sistema, pero no se mezclarán con los resultados del dataset oficial ni se denominarán resultados NASA sin el calificativo explícito de sintéticos.

Toda ejecución deberá declarar la procedencia, la variante del dataset, la unidad temporal empleada y la fuente de las etiquetas. Una etiqueta creada por una política temporal o por un generador sintético no se tratará como *ground truth* oficial. Esta regla también se aplica a los recuerdos: una experiencia sintética podrá ser útil como advertencia metodológica, pero no como evidencia directa de comportamiento de una señal NASA real.

4.4. Unidades de análisis

El diseño distingue cuatro unidades relacionadas, pero no intercambiables:

1. La **ventana intra-snapshot** es un segmento de señal utilizado para extraer características o producir un score. Varias ventanas de una misma adquisición comparten contexto y no son réplicas longitudinales independientes.
2. El **snapshot** es la observación temporal básica del activo. Los scores de sus ventanas se agregan antes de calcular persistencia, alertas y evolución de salud.
3. La **trayectoria del activo** es la secuencia cronológica de snapshots hasta el final registrado del ensayo. Es la unidad principal para las métricas *run-to-failure*.
4. El **episodio de decisión** es la unidad de análisis del comportamiento de un agente. Reúne contexto, hipótesis, alternativas, acción elegida, evidencia, memoria consultada, efecto esperado y resultado observado.

Una ejecución completa agrupa estas unidades y proporciona su identificador experimental, pero no sustituye a las réplicas. Si varias decisiones proceden de la misma trayectoria o del mismo corpus de memoria, esa dependencia se conservará al analizar los resultados.

4.5. Protocolo *run-to-failure* por snapshot

4.5.1. Preparación y procedencia

El protocolo temporal definitivo comienza con la extracción y validación del dataset oficial. La configuración de referencia utiliza NASA IMS Set 2, Bearing 1 y el primer canal, manteniendo un caso monocanal comparable con la capacidad actual. Antes de procesar la señal se verifican el número y orden de snapshots, sus marcas temporales, la frecuencia de muestreo, los canales y el evento final documentado.

Cada registro conserva su procedencia como oficial, sintética o no verificada, separada de la fuente de sus etiquetas. La procedencia acompaña al manifiesto, las decisiones, las métricas y los candidatos de memoria. Una discrepancia entre procedencia y descripción del informe constituye un fallo de validación.

4.5.2. Procesamiento jerárquico de la señal

La señal de cada snapshot puede dividirse en ventanas para extraer características y aplicar los detectores. Sin embargo, la evolución temporal se construye después de agregar esas ventanas. La política fijada para el estudio emplea la mediana del score como medida central, conserva el percentil 90, la media y la desviación, y calcula la proporción de ventanas en alerta. Una captura se considera alertada cuando dicha proporción alcanza 0,5. Así se conserva información sobre eventos breves sin convertir el solapamiento intra-snapshot en persistencia temporal artificial.

La secuencia agregada respeta el orden y los intervalos reales entre adquisiciones. Los gaps temporales se registran y una racha de alertas no puede atravesar un intervalo no observado sin una regla declarada. El indicador de salud se calcula de forma causal: en cada instante solo puede depender de la evidencia disponible hasta ese snapshot.

4.5.3. Partición temporal y prevención de fuga

La trayectoria se divide conceptualmente en tres bloques:

- **baseline de entrenamiento**, reservado para aprender el comportamiento nominal y ajustar los modelos que lo requieran;
- **calibración**, utilizado para fijar umbrales y políticas de aviso sin consultar el tramo final;
- **monitorización**, procesado en orden temporal como evaluación fuera del ajuste.

Se mantienen dos vistas de la misma ejecución. La vista *online blind* es la única disponible para los agentes durante la decisión: excluye tiempo hasta fallo, vida relativa, modo de fallo y cualquier información futura. La vista retrospectiva incorpora el evento final únicamente después de cerrar la decisión, para situar las alertas respecto al final registrado y evaluar la hipótesis. Ese intervalo retrospectivo no se interpreta como RUL, como tiempo prospectivo restante ni como validación de un onset físico.

Los snapshots de monitorización no se usarán para recalibrar el umbral, generar reintentos ni alimentar la memoria durante la familia experimental en la que se evalúan. Los episodios derivados de esa evidencia podrán considerarse para un corpus posterior, pero no retroalimentarán su propia prueba. Cuando solo exista una trayectoria, los resultados se describirán como estudio de caso temporal y no como estimación de generalización entre activos.

4.5.4. Modelos y papel de los agentes

Los ejecutores ofrecen un conjunto cerrado de familias comparables, entre ellas PCA por error de reconstrucción, Isolation Forest, One-Class SVM y autoencoder denso. Los hiperparámetros permitidos y el presupuesto de cálculo se fijan en el plan experimental. El agente modelador selecciona una alternativa y justifica su hipótesis a partir del expediente disponible; no diseña código ni modifica el conjunto de modelos durante una réplica.

El evaluador recibe métricas reproducibles y emite una valoración estructurada. Las herramientas pueden calcular readiness, alertas e indicadores de salud, pero no aprueban por sí solas una ejecución ni sustituyen la interpretación del agente. La vida útil remanente (*Remaining Useful Life*, RUL) no se comunica como estimada mientras no exista un protocolo específico y evidencia suficiente.

4.5.5. Replay causal y ramas de política

El funcionamiento híbrido se estudia mediante replay cronológico. Un tick corresponde a una adquisición NASA IMS completa y sincronizada; al cerrarlo se conservan su timestamp, el hash de la entrada, la versión de scoring y los estados calculados. En el instante t solo pueden utilizarse la observación actual, el prefijo anterior y los parámetros ajustados con baseline y calibración. Truncar o modificar cualquier sufijo posterior a t no debe cambiar la salida de ese tick. Esta propiedad define aquí la causalidad operativa; no se presenta como inferencia causal estadística.

La primera rama mantiene detector, escalado, umbral y reglas de salud congelados. Las revisiones multiagente son consultivas y sus propuestas no alteran los scores de

la trayectoria. Una segunda rama, reservada a la experimentación adaptativa, podría aplicar una propuesta validada desde el tick posterior a su aprobación. Cada cambio deberá crear una política inmutable con versión nueva y segmentar los resultados; nunca recalculará el pasado. Ambas ramas parten del mismo historial y la congelada se conserva como control. Los resultados de la rama adaptativa serán descriptivos, porque cada versión observa una fase temporal diferente de la degradación.

Dentro de la rama congelada se distinguen dos políticas de activación. P0 es el observador determinista sin revisiones. P3 conserva exactamente el mismo scoring, pero emite expedientes de revisión al confirmar condiciones predefinidas. Por tanto, P0/P3 no son las ramas congelada/adaptativa: son dos formas de decidir cuándo solicitar supervisión dentro del mismo benchmark congelado.

Para P3 se fija antes del replay un presupuesto máximo de $B = 7$ solicitudes variables, una persistencia de entrada $K = 3$ snapshots, una recuperación de $R = 1$ snapshot y un *cooldown* de 51.600 segundos de tiempo fuente. Estos valores no se recalculan a partir de la longitud ni de los scores del sufijo observado. Una entrada en estado crítico, una pérdida de continuidad y la confirmación de una alerta persistente pueden generar un expediente; el cierre de sesión es fijo y queda fuera de B .

Sea s el primer snapshot alertado de una racha y c el snapshot en el que se observa por primera vez K alertas consecutivas. La condición persistente solo puede emitirse después de cerrar c , aunque el ledger conserve s para medir el retraso de confirmación. Ambos son instantes algorítmicos: ninguno se interpreta como inicio físico del defecto. Un hueco temporal abre un segmento y reinicia la candidatura. La precedencia, el rearme, el presupuesto y la deduplicación son deterministas; en este incremento P3 no invoca todavía al modelo de lenguaje ni consulta memoria RAG.

4.6. Observación del comportamiento de los agentes

El comportamiento se observa mediante campos declarados, no mediante una cadena de pensamiento privada. Para cada decisión relevante se conservan:

- la pregunta y el expediente técnico que recibe el agente;
- la hipótesis formulada y el efecto esperado;
- las alternativas consideradas y la acción seleccionada;
- las herramientas declaradas y, por separado, las observaciones de herramienta realmente ejecutadas y las referencias de evidencia utilizadas;
- la confianza declarada y las limitaciones reconocidas;
- los recuerdos recibidos y la relación declarada con cada uno;
- la configuración realmente ejecutada y el resultado calculado;
- la decisión de mantener, revisar o detener la estrategia.

La observación separa tres desenlaces. Una **decisión válida** cumple el contrato; una **decisión ejecutable** corresponde además a una acción soportada; y una **decisión respaldada** obtiene evidencia posterior coherente con su hipótesis. La validez sintáctica no se interpretará como calidad técnica.

Las violaciones reparables del contrato se registran como correcciones de guardarrail. Los fallos del proveedor, de conexión o de salida irrecuperable se registran aparte como mecanismos técnicos de respaldo. Esta distinción evita atribuir razonamiento a una decisión determinista de respaldo y permite medir cuánto participó realmente el modelo de lenguaje.

Cuando se realice evaluación humana, el revisor recibirá la hipótesis, la evidencia declarada, la acción y el resultado, pero no conocerá la condición de memoria ni el modelo siempre que el material pueda anonimizarse. La valoración considerará corrección, suficiencia, coherencia, seguridad y utilidad. Si participan varios revisores, se informará también su acuerdo.

4.7. Ciclo experimental de memoria RAG

4.7.1. Evidencia canónica e índice derivado

Los episodios y candidatos persistidos constituyen la evidencia canónica. El índice vectorial es una representación derivada y reconstruible. El almacenamiento JSON local se utiliza como baseline exacto y reproducible; Qdrant está implementado como índice filtrable opcional y pgvector permanece como alternativa futura detrás del mismo contrato. El motor se fija y verifica antes de cada familia experimental. Esta elección es de ingeniería y no se presenta como aportación científica ni como prueba de superioridad entre backends.

La búsqueda densa exacta será el baseline científico del retrieval. La búsqueda aproximada se evaluará por separado cuando el tamaño del corpus justifique medir latencia y escalabilidad. De este modo, un cambio en el índice no se confundirá con un cambio en la capacidad de razonamiento del agente.

4.7.2. Captura, promoción y recuperación

El ciclo de memoria se define mediante los siguientes estados:

1. La decisión produce automáticamente un episodio y, cuando procede, un candidato de memoria trazable.
2. El candidato nace pendiente y no reutilizable. Capturar una experiencia no equivale a convertirla en conocimiento válido.
3. La evidencia de procedencia, resultado y revisión permite promover el candidato, mantenerlo como cautela o excluirlo.
4. Los recuerdos promovidos se indexan en el backend configurado, con el mismo contenido canónico y metadatos de gobierno.
5. Una consulta recupera candidatos compatibles por agente, dataset, rol, procedencia, perfil de supervisión y estado de reutilización.
6. Un control de calidad determinista clasifica los candidatos antes de construir el contexto efectivo del agente.
7. El agente declara si siguió, adaptó, contradijo, rechazó o ignoró cada recuerdo utilizado.

8. La auditoría compara esa declaración con la acción y el resultado, y genera nueva evidencia sin promoverla automáticamente.

La promoción automática permanece desactivada hasta definir evidencia suficiente. Una ejecución correcta aislada no debe generar una verdad que se refuerce a sí misma. La promoción futura distinguirá validación humana, repetición independiente, evidencia provisional, advertencia reutilizable y contradicción o contaminación experimental.

4.7.3. Control de calidad y fidelidad

El control de calidad aplica criterios de compatibilidad antes de que un recuerdo llegue al prompt. Se comprueban el agente destinatario, el dataset y su procedencia, el perfil experimental, la fuente y granularidad de etiquetas, la frecuencia de muestreo, el alcance de transferencia, la trayectoria y el grupo de evaluación, además del rol del recuerdo, su veredicto, su estado de reutilización, la similitud y las marcas de exclusión o riesgo. En un benchmark, un recuerdo procedente de la misma trayectoria o grupo de evaluación se considera contaminación. Un recuerdo incompatible, inseguro o expresamente excluido no forma parte del contexto efectivo.

El contexto recuperado en bruto, el resultado del control y el contexto efectivo se conservan por separado. El agente solo puede citar identificadores presentes en este último. La validación defensiva se mantiene aunque el backend aplique filtros en servidor, porque el índice no constituye la fuente canónica.

4.8. Diseño de ablaciones de memoria

El efecto de la memoria se estudiará mediante condiciones controladas. La condición principal compara memoria desactivada con memoria filtrada e inyectada. Se añaden condiciones diagnósticas para separar recuperación de influencia:

Tabla 4.2: Condiciones previstas para la ablación de memoria.

Condición	Recuperación	Contexto para el agente	Finalidad
Memoria off	No	No	Baseline de comportamiento sin memoria
Solo retrieval	Sí	No	Evaluar el buscador sin atribuirle influencia sobre la decisión
Memoria filtrada	Sí	Sí, tras control de calidad	Intervención RAG principal
Memoria completa controlada	Sí	Sí, sin el filtrado experimental objeto de ablación	Medir el valor del gate, solo si no expone contenido inseguro

Todas las condiciones compartirán entradas, orden de snapshots, ejecutores, familias de modelo, prompts base, contratos, herramientas, presupuesto de contexto y corpus

congelado. Se registrarán las semillas y los parámetros de muestreo cuando el proveedor permita fijarlos. La condición de memoria completa no anula los guardarrailes de seguridad: los recuerdos inseguros o contaminados seguirán excluidos.

Las comparaciones serán pareadas por entrada y se repetirán para estimar la variabilidad del modelo. Un cambio de configuración, hipótesis o redacción se considerará efecto conductual; solo se calificará como ayuda o perjuicio después de contrastarlo con la auditoría y las métricas operacionales. No se atribuirá causalidad a la memoria si cambia simultáneamente el prompt, el corpus, el modelo de embeddings o una guía determinista.

4.9. Métricas de evaluación

4.9.1. Métricas del comportamiento de los agentes

La participación y calidad del agente se describen mediante:

- tasa de contratos válidos en el primer intento;
- tasa de correcciones de guardarrail y de mecanismos técnicos de respaldo;
- proporción de decisiones válidas, ejecutables y respaldadas;
- calidad de la hipótesis, coherencia numérica y reconocimiento de limitaciones;
- número y diversidad de alternativas consideradas;
- tasa de revisiones útiles, sobrecorrecciones y repeticiones de fallo;
- cambio de confianza y calibración de la confianza frente al resultado;
- acuerdo de la evaluación humana cuando esté disponible.

Estas métricas se calculan por rol y por tipo de decisión. No se combinarán en un único score sin justificar previamente su ponderación.

La fiabilidad del flujo se evalúa antes que la calidad del resultado algorítmico. Se distinguen tres desenlaces: contrato válido al primer intento, contrato corregido por una segunda generación del mismo agente y mecanismo técnico de respaldo. Los dos primeros conservan autoría generativa, aunque la corrección se informa por separado; el tercero no se contabiliza como éxito agéntico. Del mismo modo, una decisión modificada después por una superposición determinista de seguridad se conserva para auditoría, pero no demuestra que el agente haya resuelto autónomamente el caso.

La puerta inicial de ingeniería exige cero respaldos, cero decisiones no agénticas, cero superposiciones de seguridad y trazas completas, además de una tasa mínima del 90 % de validez al primer intento. Se aplica primero a decisiones pequeñas y sin memoria para aislar la conversación con el modelo de los ejecutores y del RAG. Esta puerta no acredita por sí sola el objetivo del 99 %. Con cero fallos, serían necesarias aproximadamente 300 decisiones independientes para situar por debajo del 1 % el límite superior unilateral aproximado al 95 % de la tasa de fallo. Además se informará la fiabilidad del flujo completo: si una ejecución contiene m decisiones y se adopta como aproximación la independencia, una fiabilidad por decisión p produce p^m como probabilidad de terminar sin respaldo.

4.9.2. Métricas de recuperación y uso de memoria

La evaluación RAG separa recuperación, fidelidad, comportamiento y resultado:

- **Recuperación:** hit@k, precision@k, recall@k, MRR, relevancia por rol y tasa de incompatibilidades retiradas por el control de calidad.
- **Fidelidad:** proporción de citas existentes, citas inventadas, recuerdos ignorados y consistencia entre la cita y la influencia declarada.
- **Comportamiento:** cambios de hipótesis, alternativas, configuración, confianza, revisión o rechazo explícito del contexto.
- **Resultado:** tasa de ayuda, tasa de perjuicio, deltas de métricas temporales, latencia de recuperación y coste de contexto.

Las métricas que requieren relevancia conocida se calcularán sobre un conjunto de consultas con juicios de referencia preparados antes de la comparación. Los juicios se realizarán sin conocer el ranking cuando sea posible. El uso de un recuerdo no se considerará correcto solo porque haya sido citado.

4.9.3. Métricas PHM y *run-to-failure*

Las métricas principales se calculan sobre la secuencia de snapshots agregados:

- primer pico y primer aviso algorítmico persistente;
- distancia retrospectiva entre el primer aviso persistente y el final registrado;
- tasa de snapshots alertados en baseline y calibración, declarando que esta última participa en el ajuste del umbral;
- episodios de alerta, picos aislados y racha máxima;
- tendencia temporal del score y correlación de Spearman;
- caída, monotonidad, robustez y volatilidad nominal del indicador de salud;
- trayectorias sin aviso persistente.

Precision, recall, F1, ROC-AUC y PR-AUC se conservan como métricas auxiliares cuando existen etiquetas binarias defendibles. En señales sintéticas o bajo una política proxy deben aparecer identificadas como tales y no sustituyen la evaluación longitudinal. La unidad usada como denominador se declarará siempre; en particular, una tasa temporal no se calculará presentando ventanas solapadas como snapshots independientes.

4.10. Comparación posterior de modelos Qwen

La implementación actual utiliza Qwen 3.5 como modelo de los agentes. La comparación con Qwen 3 se realizará después de cerrar el protocolo temporal y la ablación de memoria. El diseño será factorial, cruzando modelo de agente y condición de memoria, con réplicas pareadas sobre las mismas entradas.

Se mantendrán constantes el corpus y su hash, el modelo de embeddings, el orden de recuperación, los contratos, las herramientas, los ejecutores, el presupuesto de contexto y los criterios de evaluación. Se registrará el identificador exacto de cada modelo y su configuración. Las decisiones se evaluarán a ciegas siempre que sea posible. Hasta ejecutar este diseño, cualquier observación sobre Qwen 3.5 se limita a ese modelo y no permite afirmar ventaja o desventaja respecto a Qwen 3.

4.11. Reproducibilidad y análisis

Cada condición experimental se define mediante un manifiesto versionado que incluye:

- dataset, procedencia, hash y unidad temporal;
- activo, canal, partición y política temporal;
- modelo de agente, parámetros de muestreo y presupuesto de contexto;
- modo de memoria, hash del corpus, embedding y parámetros de retrieval;
- versiones de prompts, contratos, herramientas y ejecutores;
- semillas, límites de reintento y criterios de parada;
- entorno de ejecución y marcas temporales relevantes.

El corpus de memoria se congela durante cada comparación. Reconstruir el índice no cambia la evidencia canónica y debe producir el mismo conjunto de registros. Los artefactos permiten reconstruir la secuencia expediente $\rightarrow$ decisión $\rightarrow$ acción $\rightarrow$ resultado sin depender de rutas locales incluidas en la memoria académica.

Las réplicas se resumirán mediante medidas de tendencia central y dispersión. Cuando el número de unidades independientes sea insuficiente para inferencia estadística, se presentará un estudio descriptivo y no se usarán intervalos o tests que presupongan independencia inexistente. Las comparaciones de memoria y modelo serán pareadas siempre que compartan la misma entrada experimental.

4.12. Amenazas a la validez

Las principales amenazas previstas son:

- **Validez externa:** CWRU y los pilotos sintéticos no representan la complejidad de una planta; una sola trayectoria NASA tampoco permite generalizar entre activos y condiciones.

- **Pseudorreplicación:** las ventanas de un snapshot están correlacionadas. La agregación por snapshot evita contarlas como observaciones longitudinales independientes.
- **Etiquetas proxy:** una frontera temporal construida no equivale a un onset de fallo oficial. Las métricas binarias derivadas se consideran auxiliares.
- **Fuga temporal:** datos del futuro, información de final de vida, recalibración sobre monitorización o memoria creada con el propio test pueden inflar artificialmente el rendimiento.
- **Contaminación de memoria:** recuerdos incompatibles o derivados de la misma evidencia evaluada pueden generar autorrefuerzo. Se mitiga mediante procedencia, corpus congelado, promoción explícita y control de calidad.
- **Confusión experimental:** modificar a la vez prompt, guía, memoria o modelo impide atribuir el cambio a un solo factor.
- **Estocasticidad del LLM:** una única respuesta no caracteriza el modelo. Se requieren réplicas y registro de la configuración.
- **Subjetividad humana:** los juicios sobre hipótesis y relevancia pueden variar. Se mitiga con rúbricas, evaluación ciega y acuerdo entre revisores cuando sea posible.

4.13. Estado de aplicación de la metodología

La infraestructura necesaria para observar el sistema ya dispone de orquestación multiagente, contratos estrictos, ejecutores deterministas, episodios de decisión, candidatos de memoria, recuperación mediante el backend configurado, control de calidad previo al contexto efectivo y auditoría de citas y uso. JSON constituye la fuente operativa reproducible en la implementación verificada; Qdrant permanece integrado como índice vectorial opcional y sustituible, al igual que una futura alternativa con pgvector. La elección definitiva del índice se pospone hasta disponer de un corpus congelado y una comparación equivalente de recuperación. También existe un primer perfil temporal con métricas de degradación, que ha servido para validar la integración con datos piloto.

La procedencia y el inventario de NASA IMS Set 2 están verificados. La política causal versionada fija 197 snapshots de baseline, 98 de calibración y 689 de monitorización mediante una regla 20/10/70; los 983 intervalos observados coinciden con la cadencia esperada de 600 segundos y no introducen cortes. La vista online ciega ya elimina del contexto de los agentes de decisión etiquetas, vida relativa, tiempo hasta el final y metadatos de fallo. La vista retrospectiva se reserva para el evaluador y para artefactos posteriores a las decisiones.

Se ha ejecutado un baseline determinista sobre la trayectoria oficial. Lo que permanece pendiente para responder a las hipótesis agénticas y de memoria es congelar el corpus experimental, definir consultas con juicios de relevancia, realizar ablaciones con réplicas y, posteriormente, comparar Qwen 3.5 con Qwen 3. Los pilotos sintéticos continúan presentándose solo como validación técnica; el baseline oficial se trata como estudio descriptivo de una única trayectoria, no como validación supervisada.

Capítulo 5

Implementación

5.1. Alcance del capítulo

Este capítulo describe la implementación desde sus responsabilidades funcionales. No reproduce la organización interna del repositorio ni la cronología de desarrollo, pues ninguna de las dos constituye una aportación académica. El interés se sitúa en cómo se materializan las decisiones de diseño presentadas en los capítulos anteriores: coordinación multiagente, separación entre razonamiento y cálculo, procedencia de los datos, seguimiento *run-to-failure*, memoria RAG supervisada y auditoría del resultado.

La implementación actual permite ejecutar el flujo completo con distintos orígenes de señal, observar las decisiones de agentes locales y conservar la evidencia generada. También incorpora el ciclo operativo de captura, recuperación y gobierno de memoria. Esto no significa que el estudio esté terminado: el baseline temporal y las vistas causales sobre NASA IMS oficial ya están ejecutados, mientras que las ablaciones de memoria y las réplicas agénticas permanecen pendientes. La reducción de ventanas a snapshots está integrada y validada tanto por casos límite como sobre la trayectoria real.

La distinción entre infraestructura y evidencia experimental es esencial. Un componente puede estar implementado y probado como parte del sistema sin que ello demuestre todavía una hipótesis de investigación. Por ejemplo, Qdrant puede recuperar recuerdos compatibles, pero su efecto sobre la calidad de las decisiones solo podrá establecerse mediante las comparaciones definidas en el capítulo de metodología.

5.2. Principios de implementación

La solución se ha construido alrededor de cinco principios.

1. Los agentes expresan propuestas e interpretaciones mediante contratos cerrados; no ejecutan transformaciones arbitrarias sobre las señales.
2. Los ejecutores realizan el cálculo de forma determinista y devuelven referencias a artefactos, métricas y errores estructurados.
3. El estado compartido permanece ligero y serializable. Las señales, tensores y modelos se conservan como artefactos externos.
4. Las decisiones observables se registran sin pretender capturar una cadena de pensamiento privada del modelo de lenguaje.

5. Los datos y episodios persistidos son la evidencia canónica; los índices, vistas y resúmenes pueden reconstruirse a partir de ella.

Estos principios delimitan con claridad qué parte del resultado procede del agente y cuál procede del software convencional. También permiten repetir una ejecución con la misma configuración aunque el proveedor de lenguaje no esté disponible, y evitan que un texto persuasivo sustituya a una operación verificable.

Tabla 5.1: Responsabilidades principales de la implementación.

Capa	Responsabilidad	Garantía buscada
Agentes	Formular hipótesis, proponer configuraciones, interpretar resultados y decidir la continuación	Decisiones observables y validadas
Ejecutores	Leer artefactos, transformar señales, entrenar modelos y calcular métricas	Reproducibilidad y separación del razonamiento
Servicios de evidencia	Persistir estados, decisiones, episodios, informes y auditorías	Trazabilidad extremo a extremo
Memoria RAG	Capturar, gobernar, recuperar y auditar experiencias	Reutilización controlada, no autorrefuerzo automático
Aplicación	Exponer planificación, ejecución, revisión y consulta	Operación local sin alterar los contratos científicos

5.3. Orquestación multiagente

5.3.1. Grafo con supervisor jerárquico

La coordinación se implementa mediante un grafo de estados. Un supervisor recibe un resumen del estado actual y decide qué nodo debe actuar a continuación. Tras cada decisión o ejecución, el control vuelve al supervisor. Este patrón evita codificar el proceso como una conversación lineal y permite detener, reintentar o redirigir una ejecución de forma explícita.

El recorrido ordinario comprende la creación del manifiesto, el perfilado, la limpieza, la estructuración, el modelado, la evaluación y la generación del informe. Las etapas que requieren criterio incorporan un nodo de agente antes del ejecutor correspondiente. Las etapas puramente mecánicas se resuelven de forma directa. El supervisor solo puede seleccionar nodos declarados en el grafo, de modo que una respuesta del modelo no puede introducir una operación desconocida.

Los roles implementados son:

- el **supervisor**, que interpreta el progreso y selecciona la siguiente transición;
- el **limpiador**, que propone la preparación de la señal a partir del perfil;
- el **estructurador**, que formula una hipótesis sobre ventanas, variables y particiones;
- el **modelador**, que selecciona una familia soportada y explica el efecto esperado;

- el **evaluador**, que interpreta métricas y limitaciones;
- el **redactor**, que organiza el informe técnico de la ejecución;
- el **verificador**, que contrasta el informe con un catálogo cerrado de evidencias.

La decisión del supervisor no sustituye el estado real. Si un agente solicita una etapa para la que faltan prerequisites, los contratos y las validaciones del nodo impiden que la transición se materialice. De forma análoga, el resultado fallido de un ejecutor se incorpora como error estructurado y vuelve al flujo de control, en lugar de ocultarse en un mensaje de consola.

5.3.2. Separación entre agente y ejecutor

Cada pareja de agente y ejecutor representa una frontera de responsabilidad. El agente puede elegir entre operaciones conocidas, justificar su criterio y declarar riesgos. El ejecutor valida la configuración y aplica únicamente funciones previamente implementadas. No se evalúa código generado por el modelo, ni se le concede acceso general al sistema de archivos.

Esta separación es especialmente relevante para estudiar el comportamiento de los agentes. Si el modelador propone una familia de detector, la propuesta se atribuye al agente; el ajuste del modelo, la calibración del umbral y la generación del score se atribuyen al ejecutor. Si una métrica cambia, puede reconstruirse qué decisión alteró la configuración sin confundir esa decisión con el cálculo numérico posterior.

Los agentes pueden disponer de una política determinista de respaldo. Su finalidad es mantener el pipeline operativo ante indisponibilidad del proveedor o una salida inválida persistente. Una decisión de respaldo conserva su causa y no debe contabilizarse como razonamiento producido correctamente por el modelo de lenguaje.

5.3.3. Estado compartido y artefactos

El estado canónico se valida mediante modelos estrictos y se transforma en una representación compatible con el motor del grafo. Contiene identificadores, contexto del proyecto, configuraciones, rutas lógicas de artefactos, métricas, evaluación, mensajes, aprobaciones y errores. No contiene matrices de ventanas, señales completas ni parámetros pesados del modelo.

Esta elección reduce el coste de serialización, permite guardar una instantánea legible y obliga a declarar el productor y consumidor de cada artefacto. Este incluye su tipo, productor, descripción y metadatos para la auditoría.

El contexto del proyecto diferencia el dataset, el perfil de supervisión, la fuente y granularidad de las etiquetas, y la procedencia de los datos. Esta información acompaña las decisiones posteriores. Así, una ejecución binaria etiquetada y una trayectoria con etiquetas temporales proxy no quedan representadas como si fueran el mismo problema.

5.4. Contratos y trazabilidad de las decisiones

5.4.1. Validación estructurada

Las entradas y salidas relevantes se describen mediante contratos Pydantic con campos declarados y tipos cerrados. Los contratos de agentes incluyen, según el rol, un

identificador de decisión, justificación, confianza, configuración, alternativas, efecto esperado, evidencia, herramientas consultadas y limitaciones. Los contratos de ejecutores incluyen estado, mensaje, artefactos, actualizaciones del estado y errores.

Todas las decisiones generadas a partir de la versión actual incorporan además un bloque común de hipótesis. Este bloque contiene el tipo de hipótesis, el enunciado contrastable, el ámbito, el corte de evidencia disponible al decidir, la observación esperada, el criterio de refutación, las referencias que la sustentan, los riesgos y los supuestos. El tipo de decisión diferencia, entre otros casos, el enrutamiento, el modelado inicial y su reintento, la redacción y la revisión. Los validadores de cada rol restringen a su vez la clase de hipótesis admisible: preparación de datos, representación temporal, rendimiento del modelo, aceptación operativa o fidelidad del informe, según corresponda.

La obligatoriedad se aplica en la frontera de generación actual. El campo permanece tolerante a la ausencia al leer instantáneas históricas, pero estas se marcan como cobertura incompleta; el sistema no transforma automáticamente una justificación antigua en una hipótesis que nunca fue declarada. Esta decisión preserva compatibilidad sin falsear la procedencia.

Los campos de memoria forman parte del contrato de los roles que actualmente reciben RAG. Una decisión debe declarar si utilizó el contexto, qué identificadores de recuerdo cita y qué relación atribuye a cada uno. No se permite declarar identificadores sin afirmar uso, ni afirmar uso sin referirse a un contexto recuperado.

La validación distingue tres problemas:

- una **salida sintácticamente inválida**, que no puede interpretarse como el objeto esperado;
- una **violación del contrato**, donde existe JSON pero sus campos o valores no cumplen las reglas;
- una **decisión no ejecutable**, válida como objeto, pero incompatible con las capacidades o restricciones de la ejecución.

Esta separación evita considerar correcta una decisión solo porque pueda parsearse. También permite medir por separado las reparaciones de formato, las correcciones de guardarrail y las restricciones metodológicas.

5.4.2. Eventos observables

Durante la ejecución se emiten eventos secuenciales para agentes, ejecutores, recuperación de memoria, decisiones, errores y cambios de etapa. Los eventos pueden incluir el identificador de decisión, una justificación comunicable, la confianza, el siguiente nodo y los recuerdos asociados. Se emplean para observación en tiempo real y para reconstruir después la cronología.

El registro no pretende exponer razonamiento interno oculto. Conserva los elementos necesarios para evaluar la conducta declarada: hipótesis, evidencia, acción, confianza y resultado. Esta decisión metodológica evita equiparar una traza extensa de texto con una explicación fiel del proceso generativo.

La hipótesis se conserva como una declaración previa al resultado. La finalización técnica de un ejecutor se enlaza con la decisión que originó la acción, pero no se convierte automáticamente en apoyo empírico. Hasta que una evaluación posterior

contraste la observación esperada y el criterio de refutación, la interfaz presenta su valoración como pendiente.

5.4.3. Propuesta del agente y decisión del protocolo

En una comparación controlada, el protocolo puede fijar la estructuración o la familia de modelo para que las réplicas sean comparables. En ese caso no sería correcto presentar la configuración ejecutada como una elección del agente. La implementación conserva por separado:

- la propuesta completa emitida por el agente;
- los campos sustituidos por el protocolo;
- la razón de la restricción;
- si la memoria influyó en la propuesta;
- si la memoria influyó realmente en la configuración ejecutada.

La traza permite estudiar el criterio del agente aunque el experimento no le conceda control sobre esa réplica. Por ejemplo, una propuesta modeladora puede haber cambiado al recibir memoria, mientras que la batería ejecuta una familia prefijada. En ese caso se registra influencia conductual sobre la propuesta, pero no influencia operacional sobre el resultado del modelo.

Esta distinción evita una atribución causal errónea y es especialmente importante en las futuras ablaciones. Sin ella, un recuerdo citado por el agente podría aparecer asociado a una mejora numérica aun cuando el protocolo hubiera ignorado por completo su recomendación.

5.5. Adaptadores de datos y procedencia

5.5.1. Frontera común de entrada

La ingestión se articula mediante un registro de adaptadores de dataset y una interfaz común para señales. El adaptador describe el origen, valida que pueda leerlo y produce un manifiesto normalizado. A partir de esa frontera, el resto del pipeline consume registros comunes y no necesita conocer la distribución particular de cada colección.

La capa de señal admite fuentes matriciales, tabulares y comprimidas. En CWRU reconoce los canales de vibración y los metadatos codificados por el dataset. En NASA IMS interpreta cada adquisición como un snapshot tabular con marca temporal, activo, ensayo y canales. Existe además un adaptador tabular genérico para entradas que no cuentan con una política específica.

El manifiesto común conserva, cuando están disponibles:

- identificador del registro y origen;
- dataset, activo, ensayo y canal;
- frecuencia de muestreo y marca temporal;

- etiqueta, detalle y fuente de la etiqueta;
- grupo temporal y metadatos de final del ensayo;
- procedencia de los datos y evidencia usada para determinarla.

La normalización no homogeneiza artificialmente la semántica. Los campos no verificados permanecen ausentes o desconocidos, y un adaptador genérico no convierte por sí solo una carpeta en un dataset oficial.

5.5.2. Procedencia oficial, sintética y desconocida

La procedencia se representa mediante tres estados: *oficial*, *sintética* y *desconocida*. Se registra además el método de detección y, cuando existe, una referencia de evidencia con su huella. Esta clasificación se propaga al estado, los artefactos, los episodios de decisión, los candidatos, los registros de memoria, las consultas y los informes.

El adaptador confiable de CWRU puede declarar la colección oficial porque su preparación está controlada. El generador de pilotos NASA-like produce una especificación explícita que permite detectar su carácter sintético y verificar la evidencia asociada. En cambio, una carpeta con estructura NASA IMS pero sin esa especificación no se declara automáticamente oficial: se marca como desconocida.

Los contratos representan una fuente NASA oficial. Para Set 2 se ha validado una evidencia canónica que vincula la URL admitida, el nombre, tamaño y huella del archivo descargado con el inventario y la huella completa del árbol extraído. El adaptador vuelve a verificar esa cadena antes de declarar la procedencia oficial y falla de forma explícita si la evidencia existe pero es incoherente. En ausencia de evidencia, el conjunto permanece como desconocido: el nombre de una carpeta o el formato de los ficheros no se utilizan como prueba de autenticidad.

La procedencia de los datos no se confunde con la fuente de las etiquetas. Una señal oficial puede utilizar una política temporal proxy, y una señal sintética puede incluir etiquetas exactas del generador. Ambos casos deben describirse de forma distinta. El verificador de informes comprueba esta separación y señala como problema cualquier atribución de mediciones o *ground truth* oficiales que la evidencia no respalde.

5.6. Pipeline determinista de señal

5.6.1. Manifiesto y perfilado

El primer ejecutor construye el inventario normalizado de registros. No necesita cargar todas las señales en memoria: identifica ficheros, canales, frecuencias, etiquetas, grupos y metadatos temporales. En los datasets que lo requieren, aplica una política declarada para completar la semántica del manifiesto.

El perfilador recorre ese inventario y obtiene resúmenes por canal. Incluye conteos, valores no finitos y estadísticos de amplitud, dispersión, energía y forma. El resultado sirve como expediente del agente limpiador y como evidencia para detectar canales ausentes o señales incompatibles. Las muestras completas no se incorporan al estado del grafo.

5.6.2. Limpieza y estructuración

El ejecutor de limpieza selecciona el canal configurado, controla valores no finitos, aplica remuestreo cuando corresponde y normaliza de acuerdo con el contrato. Cada señal limpia conserva metadatos que permiten relacionarla con el registro original.

El estructurador divide la señal en ventanas y genera dos representaciones complementarias: variables estadísticas para modelos clásicos y tensores crudos para modelos que consumen la forma de onda. También materializa las particiones y mantiene los identificadores de fichero, activo, ensayo, snapshot, orden temporal y etiqueta.

En el escenario etiquetado, la partición se realiza a nivel de unidad de origen para evitar que ventanas del mismo fichero aparezcan en entrenamiento y prueba. En el escenario temporal, la política disponible ordena los snapshots de cada ensayo y reserva un tramo inicial como referencia nominal. Las etiquetas que produce esa política se identifican explícitamente como proxy.

5.6.3. Modelado y evaluación

El modelado ofrece un catálogo cerrado de familias: Isolation Forest, PCA por error de reconstrucción, One-Class SVM y autoencoder denso. Los ejecutores entrenan sobre la partición permitida, calibran el umbral según una política declarada, guardan el modelo y producen una tabla de scores y alertas por ventana. El agente puede proponer una familia o una comparación, pero no introducir una implementación nueva durante la ejecución.

La evaluación binaria calcula métricas de clasificación cuando existen objetivos defendibles. De forma separada, el evaluador temporal calcula indicadores de alerta, persistencia, tendencia, tasa de alertas previa a monitorización y evolución de un indicador de salud cuando las predicciones contienen los metadatos requeridos.

El sistema conserva las políticas de alerta y de salud junto con las métricas. De esta forma, dos resultados que usan distinta persistencia o distinta definición de tramo nominal no se presentan como directamente comparables.

5.6.4. Flujo *run-to-failure* implementado

La implementación actual transporta identificadores de ensayo, captura, marcas temporales, partición y orden desde el manifiesto hasta las predicciones. Antes de calcular el indicador de salud, la persistencia y la primera alerta algorítmica, agrupa las ventanas por ensayo y snapshot. La política versionada emplea la mediana como score principal, conserva el percentil 90, la media y la dispersión, y declara una captura en alerta cuando al menos la mitad de sus ventanas están alertadas. La trayectoria agregada se persiste como evidencia independiente.

Esta agregación evita que varias ventanas solapadas de una misma adquisición simulen una racha longitudinal. Las métricas binarias continúan calculándose por ventana y las métricas de degradación pasan a declarar el snapshot como unidad temporal. La validación incluye el caso frontera de varias ventanas alertadas dentro de una única captura: producen una sola alerta temporal y no confirman por sí mismas una racha persistente.

La vista online ciega, la partición causal y el tratamiento explícito de gaps están integrados. En Set 2 oficial, el umbral se calibró con el bloque de calibración y la evaluación produjo 984 snapshots sin intervalos ausentes. Esta evidencia verifica el

protocolo sobre la trayectoria, aunque no valida un onset físico ni generaliza a otros activos.

Tampoco se estima RUL. La información de tiempo hasta el final puede utilizarse retrospectivamente para evaluar una alerta, pero no debe formar parte de la evidencia entregada al agente durante una decisión online.

5.7. Agentes locales y herramientas seguras

5.7.1. Proveedor local

Los agentes se ejecutan mediante Ollama y utilizan actualmente Qwen 3.5 como modelo de chat. El cliente solicita objetos JSON y emplea una configuración conservadora para reducir variabilidad de formato. El esquema de la decisión se incluye como restricción de salida.

Cuando la primera respuesta no puede interpretarse, el cliente permite una reparación controlada que solicita únicamente el objeto válido. Si el objeto resultante incumple reglas semánticas, el agente puede realizar una reparación de contrato. Si el proveedor falla o la salida sigue siendo inválida, se activa la política determinista de respaldo y se registra la causa.

Cada decisión nueva incorpora además una traza de generación estructurada con el origen efectivo —LLM, decisión determinista, respaldo de guardarrail o restricción del protocolo—, un identificador y orden de intento, y el estado de validación. Cuando se activa el respaldo se enlazan el intento previo y la causa. Estos campos los añade la aplicación después de validar la respuesta: cualquier valor homónimo incluido por el modelo se descarta, evitando que el propio agente certifique su procedencia. Las decisiones históricas siguen siendo compatibles, pero la ausencia de esta traza se presenta como evidencia desconocida.

Este mecanismo favorece la continuidad operativa, pero no oculta el fallo del modelo. Las evaluaciones de comportamiento deberán distinguir respuestas válidas al primer intento, respuestas reparadas, correcciones de guardarrail y mecanismos técnicos de respaldo.

La comparación con Qwen 3 no forma parte de la implementación experimental cerrada. El proveedor permite seleccionar otro modelo, pero una comparación válida requiere congelar antes prompts, contratos, herramientas, memoria y dataset, tal como establece el capítulo de metodología.

5.7.2. Herramientas de observación

Los agentes no reciben acceso general a Python ni a una consola. Pueden solicitar herramientas declaradas en un catálogo cerrado. La solicitud incluye agente, ejecución, propósito y argumentos; el servicio valida que el rol esté autorizado y que la observación pertenezca a la ejecución activa.

Las herramientas implementadas permiten:

- consultar un catálogo de evidencias del estado;
- recuperar series resumidas de salud temporal;
- leer métricas de degradación ya calculadas;

- evaluar si los datos son suficientes para una familia temporal;
- comparar el efecto de alternativas de umbral soportadas.

Cada herramienta devuelve una observación estructurada, referencias citables, un resumen y, en caso de fallo, errores explícitos. Sus operaciones son de lectura o cálculo acotado; no modifican la señal ni crean una vía paralela al pipeline determinista.

El catálogo y el contrato de observación están implementados, pero su presencia no demuestra que el grafo haya ejecutado una herramienta. En el estado auditado, los nombres incluidos por los agentes se conservan como herramientas declaradas o propuestas; todavía no se generan observaciones de herramienta dentro del flujo principal. La interfaz las rotula de este modo y solo contabiliza uso cuando existe una observación estructurada persistida. Por tanto, los resultados actuales no atribuyen a los agentes consultas que no han ocurrido.

Las referencias disponibles forman un catálogo cerrado. El agente puede interpretarlas o declarar que son insuficientes, pero no inventar un identificador de evidencia. La misma política se reutiliza en la verificación del informe final.

5.8. Implementación del ciclo de memoria RAG

5.8.1. Evidencia canónica y representaciones

La memoria se orienta a episodios de decisión, no a fragmentos genéricos de documentación. Un episodio reúne el contexto, alternativas, acción elegida, efecto esperado, evidencia, recuerdos recuperados, resultado, métricas, limitaciones y lección aprendida. A partir del episodio se destila un candidato más compacto con condiciones de reutilización y riesgos.

Los episodios, candidatos y decisiones de gobierno se persisten como objetos JSON validados. Constituyen la fuente auditable. El registro vectorial añade la información necesaria para la búsqueda, pero no reemplaza el objeto de origen. Por ello, el índice puede eliminarse y reconstruirse sin perder la historia de la decisión.

Cada registro de memoria conserva:

- agente destinatario y colección lógica;
- tipo de fuente y referencias a ejecución y decisión;
- dataset y procedencia de los datos;
- resultado y veredicto humano, cuando existen;
- rol del recuerdo;
- indicadores de reutilización y exclusión;
- resumen, contenido, métricas y etiquetas;
- modelo, versión y dimensión del embedding.

Los roles distinguen ejemplos positivos, ejemplos negativos, casos frontera, advertencias, metodología y evidencia. Un recuerdo negativo no se transforma en recomendación positiva por tener una similitud alta. Su rol determina cómo puede presentarse al agente.

5.8.2. Captura y candidato pendiente

La captura automática está implementada para las decisiones del estructurador, modelador y evaluador. Tras la acción relevante se construye un episodio y un candidato, vinculados a la configuración y al resultado disponible. La procedencia de la ejecución se copia en ambos objetos.

El candidato generado nace, por defecto, como no reutilizable. Esta propiedad es deliberada: observar una decisión no equivale a validarla. La generación automática evita perder experiencia, mientras que el estado pendiente impide que el sistema convierta su propia salida en una regla sin supervisión.

El candidato incluye cuándo podría reutilizarse, cuándo no debería trasladarse y qué riesgo tendría un uso fuera de contexto. Las advertencias y ejemplos negativos requieren orientación de evitación. Un ejemplo positivo exige una validación compatible y no puede derivarse de un resultado inseguro o contradictorio.

5.8.3. Cola de revisión y gobierno

Los candidatos persistidos se reúnen en una cola de revisión. La aplicación puede mostrar su estado y registrar una decisión manual de promoción o exclusión. Toda decisión de este tipo exige una razón y la identidad del revisor.

La promoción y la exclusión se conservan en un registro de gobierno separado. No se reescribe el candidato original, lo que preserva la evidencia capturada. La vista efectiva combina el objeto inmutable con la decisión de gobierno más reciente.

La curación también permite excluir o restaurar un registro ya indexado. La eliminación crea primero una marca persistente de baja auditable y después retira el registro del backend. Durante una reconstrucción, esa marca vuelve a aplicarse y evita que un recuerdo borrado reaparezca al recorrer los artefactos históricos.

Existen restricciones de coherencia. Un objeto cuyo rol es excluido no puede promoverse como contexto positivo, y una restauración no elimina esa incompatibilidad semántica. La promoción automática permanece desactivada. El criterio futuro de promoción deberá combinar revisión, repetición independiente y evidencia del resultado.

5.8.4. Backends e índice vectorial

La memoria expone una interfaz común de alta, reconstrucción, listado, eliminación y consulta. Se han implementado dos backends:

- un almacenamiento JSON local con similitud coseno exacta, utilizado como baseline sencillo y reproducible;
- Qdrant, disponible como índice opcional para combinar búsqueda vectorial y filtros de metadatos.

Qdrant se elige por adecuación a las necesidades actuales, no porque el trabajo demuestre que sea universalmente superior o el estado del arte frente a pgvector [18, 17]. La lógica científica permanece fuera del backend. Pgvector no forma parte de la implementación presente, pero la interfaz evita acoplar los agentes a una tecnología concreta y permitiría evaluar otro almacenamiento sin cambiar los contratos de decisión.

El servicio Qdrant crea índices de metadatos para agente, dataset, procedencia, rol, veredicto, reutilización, exclusión y versión del embedding. La consulta aplica estos filtros en servidor y repite después comprobaciones defensivas sobre los objetos recibidos. La doble validación protege frente a registros antiguos o metadatos incompletos.

5.8.5. Compatibilidad de embeddings

Un vector solo es comparable con otros producidos bajo el mismo espacio de representación. Por ello, cada colección conserva proveedor, identificador, versión y dimensión del embedding. Tanto el backend local como Qdrant validan esa información antes de insertar o recuperar registros.

Un cambio de modelo o dimensión no mezcla silenciosamente vectores incompatibles. Requiere una reconstrucción o migración explícita del índice a partir de los objetos canónicos. Esta política también permite congelar el embedding durante una familia experimental y registrar su versión en los resultados.

El sistema admite embeddings de Ollama y un embedding determinista de referencia. Este último sirve para pruebas funcionales, pero no sustituye la evaluación semántica con el modelo elegido para los experimentos.

5.8.6. Consulta, filtros y sobre-recuperación

La inyección de memoria se aplica al estructurador, modelador y evaluador. Cada rol construye una consulta a partir del estado y de su decisión pendiente. La consulta declara agente, dataset, procedencia, roles permitidos, veredictos excluidos, similitud mínima y presupuesto final de recuerdos.

Antes de calcular similitud se aplican restricciones de reutilización:

- el registro debe estar promovido o marcado como reutilizable;
- no puede estar excluido ni afectado por una marca persistente de baja;
- debe pertenecer al agente destinatario o a metodología compartida;
- su rol debe estar permitido y su veredicto no puede ser inseguro;
- el dataset debe ser compatible o el recuerdo debe ser metodológicamente compartido;
- no puede existir conflicto entre procedencia oficial y sintética;
- el embedding debe ser compatible con la colección consultada.

La procedencia desconocida no se convierte en coincidencia positiva. Puede mantenerse como evidencia incierta cuando no existe un conflicto explícito, pero conserva su etiqueta de desconocida. Además, el control inspecciona las señales de perfil presentes en tags y métricas: un recuerdo basado solo en precision, recall, F1 o tasa de falsos positivos se excluye de una consulta *run-to-failure* oficial sin etiquetas si no contiene evidencia temporal compatible. Una política experimental más restrictiva puede excluir toda procedencia desconocida al congelar el corpus.

El recuperador solicita un conjunto candidato mayor que el contexto final. Esta sobre-recuperación compensa los elementos que pueda retirar el control de calidad. Qdrant utiliza además un margen interno antes de aplicar las comprobaciones defensivas. Tras ordenar y deduplicar, solo el presupuesto final puede llegar al agente.

5.8.7. Control de calidad previo al prompt

La similitud vectorial no decide por sí sola la utilidad de un recuerdo. Un control determinista clasifica cada candidato como apto, cautela o excluible. La decisión considera:

- similitud y agente destinatario;
- coincidencia de dataset;
- compatibilidad del perfil de supervisión, fuente y granularidad de las etiquetas;
- frecuencia de muestreo objetivo y alcance permitido de transferencia;
- separación entre trayectorias y grupos de evaluación durante un benchmark;
- tipo de evidencia implícito en tags y métricas persistidas;
- rol del recuerdo y tipo de fuente;
- veredicto humano;
- etiquetas de exclusión manual o contaminación experimental.

Los ejemplos negativos, advertencias y casos frontera pueden mantenerse como cauteles, con un uso explícitamente preventivo. Los recuerdos incorrectos, inseguros, incompatibles o marcados para exclusión no pasan al contexto efectivo.

La aplicabilidad se persiste como un contrato tipado desde el contexto del proyecto hasta el episodio, el candidato y el registro recuperable. En modo benchmark, compartir trayectoria o grupo de evaluación se trata como fuga y provoca exclusión. Una frecuencia incompatible se excluye o queda como cautela según la política congelada. Los registros históricos sin estos campos no se completan mediante suposiciones: utilizan el análisis heredado de tags y métricas y quedan, como mínimo, señalados por incertidumbre.

La implementación persiste tres objetos diferentes: recuperación en bruto, informe del control de calidad y contexto efectivo. Esta separación permite medir qué encontró el buscador, qué rechazó la política y qué recibió realmente el agente. Sin ella sería imposible saber si una ausencia se debe al índice, al filtrado o al uso posterior.

En la vista online ciega de una trayectoria *run-to-failure*, el contexto efectivo aplica además una proyección causal. No se trasladan al prompt textos libres, métricas finales, resultados ni referencias que puedan revelar el futuro. Solo se conservan metadatos de aplicabilidad y orientaciones generales derivadas de un vocabulario cerrado y revisable. Los recuerdos de la misma trayectoria o grupo de evaluación, de perfil incompatible o con incertidumbre no resoluble se excluyen antes de la decisión. Por tanto, el backend vectorial ordena candidatos, pero no decide por sí solo qué experiencia es segura para el agente.

5.8.8. Uso declarado y auditoría

El agente recibe únicamente el contexto efectivo y debe referirse a sus recuerdos mediante identificadores. Para cada uso puede declarar si siguió, adaptó, contradijo o ignoró el contenido, acompañado de un resumen de influencia y una mitigación del riesgo cuando corresponda.

El identificador del contexto observado se conserva aunque ningún recuerdo influya en la decisión. En ese caso, el indicador de uso permanece falso y no se permiten citas, resúmenes de influencia ni relaciones con registros individuales. Esta regla diferencia memoria desactivada, contexto vacío, recuperación ignorada y uso efectivo sin forzar un mecanismo de respaldo por haber rechazado correctamente un contexto irrelevante.

La auditoría compara los identificadores recuperados con los citados. Detecta recuerdos ignorados, citas no recuperadas, contradicciones y repetición de un fallo frontera. También puede relacionar el uso con métricas anteriores y posteriores, sin asumir que una cita implica una mejora.

Los episodios creados tras la decisión incorporan esa evidencia, pero sus candidatos vuelven a quedar pendientes. Así se cierra el ciclo de captura sin crear una promoción recursiva automática.

La observabilidad RAG resultante permite responder preguntas distintas:

- qué registros eran elegibles para la consulta;
- cuáles recuperó el backend;
- cuáles descartó el control de calidad;
- cuáles llegaron al prompt;
- cuáles declaró usar el agente;
- qué propuesta produjo y qué acción se ejecutó;
- qué resultado se observó después.

Esta secuencia constituye el núcleo original de la implementación. Su existencia hace posible la futura ablación, pero no anticipa su resultado.

5.9. Generación y verificación de informes

El informe generado por el sistema es un artefacto técnico de una ejecución y no la memoria académica del TFM. El redactor recibe el estado validado y decide la estructura del documento. Un ejecutor determinista materializa las secciones y enlaza métricas, configuraciones, artefactos y limitaciones.

Antes de aceptar el informe, un verificador consulta un catálogo cerrado de evidencias. Revisa afirmaciones sin soporte, descripciones engañosas, limitaciones ausentes y violaciones de política. Entre sus guardarraíles se encuentra la comprobación de procedencia y de la fuente de etiquetas.

La verificación combina la valoración del agente con comprobaciones deterministas. Una redacción puede variar en estilo y orden, pero no puede presentar como oficial un dato sintético o desconocido, declarar validación industrial sin evidencia o ignorar una limitación crítica.

El estado de la verificación también está sujeto a un invariante. Una aprobación no puede contener incidencias graves ni correcciones; una petición de revisión debe enumerar al menos una incidencia y su corrección; y un bloqueo requiere una incidencia crítica. Así se evita recomendar revisión humana sin explicar qué debe revisarse.

Si el verificador solicita cambios, el redactor produce una revisión estructurada que declara qué objeciones acepta, cuáles rechaza y qué modificaciones aplica. La implementación limita el intercambio automático y, si quedan cuestiones sin resolver, recomienda revisión humana. Se conservan el borrador inicial, la revisión, las verificaciones y un resumen del debate.

Este mecanismo reduce el riesgo de que el último agente del pipeline convierta un resultado preliminar en una conclusión excesiva. No reemplaza la revisión académica del documento final ni la evaluación humana de las hipótesis.

5.10. Persistencia y aplicación local

5.10.1. Instantáneas y paquetes de evidencia

Al finalizar una ejecución se guarda una instantánea con el estado, las decisiones, los artefactos, las métricas, la evaluación y los errores. Un índice ligero permite localizar y comparar ejecuciones sin cargar todos sus objetos.

El paquete de evidencia normaliza la cronología de decisiones y registra los artefactos relevantes. Cuando el artefacto es un fichero accesible, se calcula una huella para detectar cambios posteriores. También se genera una vista de auditoría legible que reúne solicitud, plan aplicado, agentes, verificación, resultado técnico, evidencias e incidencias.

La persistencia permite reconstruir la relación:

$$\begin{aligned} \text{entrada} &\longrightarrow \text{expediente} \longrightarrow \text{decisión} \\ &\longrightarrow \text{ejecución} \longrightarrow \text{resultado.} \end{aligned}$$

Los episodios de memoria añaden a esa relación las condiciones de reutilización y el gobierno posterior. La base vectorial no es necesaria para leer la auditoría histórica.

5.10.2. API

La aplicación expone una API FastAPI para describir datasets, preparar planes, ejecutar el pipeline, consultar trabajos en segundo plano y recuperar instantáneas, artefactos, informes y visualizaciones. La planificación previa permite comprobar capacidades y requisitos antes de lanzar una tarea costosa.

La API también ofrece acceso a colecciones y registros de memoria, búsqueda filtrada, cola de candidatos y operaciones de promoción, exclusión, restauración y eliminación auditada. Todas estas operaciones utilizan el mismo backend configurado que la ejecución del pipeline; no existe una memoria separada para la interfaz.

Los trabajos en segundo plano publican eventos de agentes y ejecutores y constituyen la fuente de runtime exacta. Para ejecuciones síncronas e históricas, la API reconstruye una secuencia parcial a partir de decisiones y artefactos; esta vista se identifica como reconstruida para no confundirla con eventos observados en directo. La revisión humana puede configurarse como desactivada, pasiva o requerida en puntos

declarados. El servicio valida las entradas y limita el acceso a raíces de datos y artefactos permitidas.

5.10.3. Primer replay causal de monitorización

Se ha implementado una primera vertical del bucle determinista sobre NASA IMS Set 2. El servicio acepta únicamente un escenario registrado; la API no recibe rutas de ficheros. Antes de cargar el modelo verifica las huellas del manifiesto, las características y el bundle PCA, y solo entonces deserializa este último. La entrada de cada tick se limita mediante una lista positiva a los identificadores temporales y a las diez características usadas por el modelo. Los campos retrospectivos y los artefactos de resultados históricos no forman parte del runtime: se reservan como oráculo de pruebas.

El arranque procesa causalmente los 295 snapshots de baseline y calibración para reconstruir el estado mínimo de suavizado y continuidad. Después, cada orden **step** consume exactamente uno de los 689 snapshots de monitorización. Sus 19 ventanas se puntúan con el escalador, el PCA y el umbral congelados, se agregan a nivel de adquisición y producen un tick inmutable. El cursor de ejecución es local al bloque de monitorización y se distingue del ordinal administrativo de la trayectoria.

Cada adquisición contiene cuatro canales sincronizados. Solo el canal del rodamiento incluido en el bundle produce score, umbral e indicador de salud. Los otros tres muestran RMS, pico absoluto y número de muestras como telemetría sin diagnóstico; no heredan el estado del canal modelado. Los commits se escriben antes de actualizar el checkpoint de sesión. Una revisión esperada y un identificador de comando proporcionan control de concurrencia e idempotencia, y el último commit permite recuperar una sesión tras una interrupción entre ambas escrituras.

La API permite listar fuentes, crear o consultar una sesión, avanzar un tick y leer ticks posteriores a una secuencia. La creación ofrece únicamente las políticas registradas por el backend. P0 mantiene el observador determinista sin eventos; P3 añade activación dirigida por eventos sin cambiar el scorer ni el estado de salud. Ambas pertenecen por ahora al modo congelado y consultivo.

El motor P3 es una función pura que recibe un tick completo, el checkpoint anterior y el bundle de activación. Mantiene la identidad del episodio, el inicio de la racha, la confirmación persistente, el rearme, los cooldowns y las reservas de presupuesto. Primero resuelve precedencia, supresión y coalescencia; después co-persiste tick, triggers, checkpoint y estado en un único commit encadenado por SHA-256. Los identificadores se derivan de claves canónicas acotadas. La reapertura reconstruye toda transición desde el seed y las políticas registradas, por lo que no basta con recalcular el hash de un ledger manipulado para cambiar una regla o un evento.

El primer corte del motor P3 terminaba en eventos emitidos, suprimidos o coalescidos y todavía no despachaba ejecuciones hijas. Este límite histórico permitió validar primero el reloj, el scoring y la política de activación sin confundir una reserva determinista con razonamiento de un agente. Sobre esa base ya estabilizada se añadió después el puente consultivo descrito a continuación.

5.10.4. Puente causal entre trigger y revisión multiagente

Un trigger primario emitido puede iniciar manualmente una revisión multiagente. Antes del despacho, el sistema construye una vista formada solo por frames ya compro-

metidos hasta el cutoff del trigger. La proyección utiliza una lista positiva de campos: identidades temporales, activo y canal, telemetría compacta, diagnóstico ya calculado y versiones de las políticas. No contiene muestras crudas, rutas a los datos, longitud final, vida relativa, tiempo hasta fallo ni resultados retrospectivos. El manifiesto administrativo reducido y la evidencia visible se conservan por separado y ambos quedan ligados por huellas criptográficas.

La solicitud fija la sesión, el trigger, el tick de origen, el snapshot y el tiempo de corte, las políticas activas y los siete roles. Sus capacidades se restringen a formular propuestas: no puede volver a explorar los datos crudos, ajustar o reentrenar modelos. La memoria está desactivada y el resultado declara que ninguna política fue aplicada. El servidor, no el modelo de lenguaje, establece las identidades, el cutoff, las referencias permitidas y la procedencia de cada intento.

La revisión recorre en orden fijo supervisor, limpiador, estructurador, modelador, evaluador, redactor y verificador. Cada rol devuelve una decisión común con hipótesis falsable, observación, acción recomendada, alternativas, justificación, confianza, evidencia y traza de generación. Las acciones pertenecen a un catálogo cerrado y permanecen consultivas. Este subgrafo no invoca los ejecutores del pipeline, no calcula de nuevo el score y no consulta ni escribe memoria RAG.

El ciclo de vida de la ejecución hija se persiste en un ledger append-only separado del ledger científico del replay. Distingue reserva, ejecución, resolución, fallo e interrupción, y queda anclado al evento emitido, a la vista causal y a la solicitud. Los comandos emplean revisión esperada e idempotencia; solo puede existir una hija activa por sesión y el replay guiado no avanza mientras permanece activa. De este modo, añadir la historia agentiva no reescribe el tick ni el trigger que la originaron.

La recuperación se limita al despliegue local monoproceso. Al reiniciar la API, su ciclo de vida reconcilia el ledger: una ejecución hija reservada o en curso sin trabajo activo ni resultado completo pasa a estado interrumpido, sin volver a invocar Qwen automáticamente. Si una reserva durable carece de recibo, el comando se reconstruye desde el ledger para conservar la trazabilidad idempotente.

Al resolver la revisión se conserva una instantánea consultable con las siete decisiones, sus hipótesis, los eventos de runtime, el informe y la auditoría. La persistencia vuelve a comprobar las huellas de solicitud, vista, decisiones, eventos y resultado. La interfaz ofrece el despacho únicamente como acción explícita sobre un trigger elegible, muestra su ciclo de vida y permite abrir la ejecución en la sala de agentes y regresar al mismo cursor sin avanzar el replay.

La validación del puente combina clientes de lenguaje simulados, un modo protocolario determinista y una ejecución real acotada con Qwen 3.5. Comprueba el orden de los siete roles, las ramas de reparación y respaldo, la ausencia de accesos a datos crudos, ejecutores y RAG, la persistencia y la navegación web. El gate relevante cerró con 140 pruebas backend y tres subpruebas correctas, con una advertencia de una dependencia externa, y 22 de 22 casos de navegador correctos. Son controles de software, no observaciones científicas independientes ni el recuento total del repositorio.

La ejecución nominal sobre NASA IMS Set 2 partió de una transición de estado confirmada en el cursor 353. Los siete roles produjeron decisiones con origen LLM válidas al primer intento, sin reparación ni respaldo; la memoria permaneció desactivada y ninguna recomendación se aplicó como política. Un intento técnico anterior sufrió dos timeouts y activó dos respaldos. Se excluyó del resultado y se utilizó únicamente para introducir un timeout específico de la revisión de monitorización. Por tratarse de

una sola ejecución retrospectiva, el cierre acredita funcionamiento y trazabilidad, no fiabilidad general ni corrección de las hipótesis.

5.10.5. Gate repetido y publicación de fiabilidad

La revisión nominal se amplió mediante un gate repetido que reutiliza el motor, el store, el revisor y el registro común existentes. Antes de cada batería se inmoviliza un plan con los cuatro contextos primarios de P3, tres sesiones nuevas, los siete roles y las huellas de las fuentes críticas, el modelo, el prompt, el esquema y el catálogo de acciones. La ejecución es secuencial y *single-flight*: cada hija debe cerrar antes de avanzar el replay. Así se obtienen 12 runs hijas y 84 decisiones de rol sin confundirlas con trayectorias físicas independientes.

La instrumentación registra cada intento real contra Ollama mediante hashes del prompt, esquema y respuesta, duración, tokens y causa de parada. No replica el texto de respuesta en el agregado y distingue una reparación JSON interna de la segunda llamada contractual del revisor. El guardarraíl de alcance se aplica en el runtime antes de aceptar la salida a los nueve campos de texto libre. Las referencias se contrastan, asimismo, con el catálogo de evidencia visible en el corte. Si ambos intentos fallan, se conserva una decisión de respaldo segura, pero el gate de fiabilidad queda bloqueado aunque la ejecución pueda continuar.

Cada plan persiste prerregistro, manifiesto, observaciones, resumen, resultado e informe. El puntero explícito `current.json` incluye el hash del resultado y de todos los artefactos publicados; no se selecciona automáticamente el último resultado favorable. La API devuelve ausencia si no existe publicación e inconsistencia si una huella no coincide. La web consume únicamente esa proyección verificada y presenta una banda compacta con veredicto, bloqueos, resultados por rol, matriz de cuatro contextos por tres repeticiones y coberturas contractuales. El detalle permanece enlazado a las runs de la sala de agentes, sin añadir un score global ni resumir de nuevo los textos con otro modelo.

Las dos baterías completas quedaron publicadas como resultados negativos. V2 resolvió las 12 hijas y validó las 84 decisiones al primer intento, pero tres campos formularon claims físicos o de RUL fuera del alcance permitido. Tras mover el mismo clasificador canónico al runtime se prerregistró y ejecutó V3 desde cero, sin reutilizar sesiones o respuestas. V3 acotó los 84 textos, pero dos roles de una hija citaron dos veces referencias fuera de su vista causal y terminaron en respaldo: 11/12 hijas resueltas, 82/84 decisiones de origen LLM y 86 llamadas físicas. Esta evidencia confirma el funcionamiento del instrumento de auditoría y revela dos fragilidades distintas; no autoriza RAG, adaptación de políticas ni una repetición selectiva del caso adverso.

Tras ese diagnóstico se reforzó la frontera sin ejecutar otra batería. La vista actual contiene un único artefacto causal, por lo que exigir al modelo que copie su identificador largo no representa una selección de soporte. El esquema generativo V2 admite únicamente el alias `causal_view` en la decisión y la hipótesis; el backend valida ambos valores de forma exacta y los materializa como referencia canónica antes de hashear y persistir. La traza declara el modo `server_singleton`. Además, el handoff de registros se contrasta con el SHA-256, el recuento, la whitelist y el cutoff del artefacto, y las decisiones previas solo pueden proceder de la misma vista. No existe resolución difusa ni normalización silenciosa.

El siguiente incremento descendió ese binding desde el artefacto hasta cada registro

visible. El backend deriva un catálogo inmutable y hasheado con handles contiguos E01..EN; cada entrada enlaza el índice, el identificador interno y el hash del registro con una referencia canónica de soporte. Se mantienen separados el alcance completo de la vista (`causal_scope_refs`), la selección corta devuelta por el modelo y las referencias `causal-record` que el servidor materializa en la decisión. El esquema generativo enumera únicamente los handles de la vista y exige que decisión e hipótesis seleccionen la misma lista ordenada, sin normalización, coerción ni completado silencioso.

El prompt y el esquema se versionaron como `monitoring_review_prompt_v3` y `monitoring_review_llm_response_v3`. El request fija la huella del esquema dinámico concreto; la traza registra el modo `server_record_catalog`, el hash del catálogo, los handles elegidos y su resolución. La persistencia añade el artefacto de catálogo causal al evidence pack y comprueba que catálogo, eventos, hipótesis y decisiones coincidan antes de escribir. Los contratos finales de request, decisión y resultado conservan su versión histórica, por lo que esta extensión no reescribe las baterías publicadas.

5.10.6. Síntesis consultiva de recomendaciones de política

Sobre las siete decisiones ya cerradas se añadió una proyección estrictamente consultiva. El objeto `MonitoringPolicyProposal` no procede de una octava llamada agéntica: lo construye un servicio puro del servidor y el propio contrato fija `proposal_origin=deterministic_server`, además de conservar el `trace_origin` equivalente en el evento runtime. Su función es reunir sin reinterpretación libre las recomendaciones de supervisor, limpiador, estructurador, modelador, evaluador, redactor y verificador. Por ello contiene exactamente siete `PolicyProposalContribution`, en el orden canónico y enlazadas a sus decisiones fuente.

Cada contribución conserva la acción original, su categoría consultiva, el fundamento y los riesgos declarados, la recomendación de revisión humana y el soporte que seleccionó ese rol. El fundamento no se presenta como impacto verificado. Las referencias canónicas se resuelven de nuevo contra el catálogo causal sellado y se proyectan como handles E01..EN; el servidor no añade evidencias ni acepta referencias ajenas. La propuesta liga request, run, vista y catálogo mediante identidades y huellas verificables; el paquete de evidencia la enlaza además con el resultado persistido.

El mapeo semántico es cerrado:

- `maintain_policy` se representa como `no_change`;
- `intensify_observation`, como `observation`;
- `request_human_review` y `pause_replay`, como `workflow`;
- `insufficient_evidence`, como `abstain`.

Las decisiones actuales no contienen valores numéricos ni un tipo de política objetivo, de modo que la proyección no inventa umbrales, frecuencias, versiones o cursores de aplicación. Una categoría expresa la clase de recomendación, no un cambio ejecutable ni un impacto estimado.

Cada categoría se acompaña de un sujeto y dos estados semánticos cerrados. Por ejemplo, intensificar observación proyecta la cadencia actual hacia una intensificación solicitada, mientras que solicitar revisión humana transforma el estado consultivo de

no solicitado a solicitado. Son estados de intención: el valor `requested` no acredita que el workflow humano haya sido invocado.

La síntesis tampoco usa mayoría, ponderación por confianza ni otro modelo. Solo expone una acción agregada cuando las siete acciones válidas son unánimes; en otro caso registra `disagreement` y conserva todas las contribuciones. La propuesta solo se construye si existen las siete decisiones. Cuando alguna contribución declara un `generation_origin` distinto de `llm` —incluido `fallback`, protocolo o determinismo— se registra `invalid_review`; un rol `failed` o `not_run` sin decisión impide construir el objeto. Así, la continuidad segura del sistema no se atribuye como consenso agentivo. La revisión humana agregada es únicamente el OR de `requires_human_review`: indica que algún rol la recomienda, no que se haya solicitado, realizado o aprobado.

El artefacto se persiste junto a la run y su lectura vuelve a contrastar hash, roles, decisiones y evidencias. En todos los caminos declara que es consultivo, que no fue aplicado y que no es elegible para validación de política. Este incremento no incorpora un `ValidationRecord`. Tampoco incorpora aprobación humana, `ApplicationRecord`, una versión candidata ni mutación de scoring, activación o replay.

5.10.7. Interfaz de usuario

La interfaz web permite configurar una ejecución, realizar la verificación previa, consultar su progreso, revisar el historial y explorar el detalle técnico. Incluye vistas de métricas, informes, artefactos, señales temporales, comparaciones y estado del proveedor local.

La navegación incorpora una vista específica de *Monitorización*. La cabecera la identifica de forma permanente como replay histórico y no como tiempo real. Tras preparar una sesión, el usuario puede avanzar manualmente o reproducir una secuencia de órdenes causales; la velocidad solo modifica el ritmo visual del cliente. Cuatro tarjetas mantienen visibles los canales y diferencian diagnóstico modelado, telemetría y dato no disponible. Las tres subvistas responden a preguntas concretas: *Estado* resume la observación seleccionada; *Replay 2D* representa score, umbral y estados del prefijo ya ejecutado; y *Eventos* reserva el espacio para los triggers y sus runs hijas. El cursor de inspección puede retroceder por lo ya observado, pero no adelantar la ejecución ni revelar el sufijo.

La fuente declara si admite P0, P3 o ambas y el selector propone P3 sin ocultar P0. Un trigger aparece como marcador agrupado en su cursor, como señal discreta en el activo afectado y como una única fila de ledger. El estado, el tipo y la existencia o ausencia de run hija son visibles sin desplegar texto; razón, historial e identificadores quedan bajo demanda. Seleccionar un marcador solo mueve el cursor de inspección y no ejecuta otro step.

La Figura 5.1 muestra la ejecución web real de los 689 ticks de monitorización de esta trayectoria. La gráfica solo contiene el prefijo ya procesado; el rodamiento 1 presenta el diagnóstico del PCA congelado y los otros tres se mantienen explícitamente como telemetría sin diagnóstico. La captura corresponde al observador P0, por lo que no atribuye todavía eventos, decisiones ni cambios de política a los agentes.

La observabilidad de agentes adopta una divulgación progresiva para separar la comprensión rápida de la auditoría exhaustiva. La primera lectura resume el estado de la ejecución, la participación de los siete roles, la procedencia de las decisiones, las excepciones, la recuperación y el uso de memoria, y el veredicto. A continuación, un




Figura 5.1: Vista web del replay histórico NASA IMS Set 2 una vez procesados los 689 ticks de monitorización. El panel separa el canal modelado de los canales de telemetría, conserva la evolución temporal y declara el alcance P0 sin Qwen, RAG ni activación agéntiva.

mapa bidimensional mantiene visibles los siete agentes con una frase de hipótesis, la decisión efectiva, la señal RAG y el resultado relacionado. Al seleccionar un rol aparece una ficha estable con cuatro preguntas: qué cree, qué elige, qué recuerda y qué ocurre.

La observación esperada y el criterio de refutación se muestran bajo demanda. El ámbito, el corte de evidencia, los riesgos, las referencias, la justificación completa y los objetos técnicos permanecen en la vista de auditoría o en el informe. Esta jerarquía reduce la lectura inicial sin eliminar evidencia. Los textos compactos se derivan de campos estructurados; no se emplea otro modelo de lenguaje para resumir o reinterpretar la traza.

En las revisiones ligadas al catálogo causal, el inspector añade una lectura visual del soporte sin duplicar el artefacto: indica cuántos registros se utilizaron sobre el total disponible, representa los handles E01..EN en un rail y abre tarjetas únicamente para las filas seleccionadas. Los identificadores canónicos permanecen en el payload técnico. La proyección compacta mostrada —tiempo, activo, canal, estado y relación score—umbral— queda hasheada con la entrada del catálogo y se verifica de nuevo al cargar los eventos persistidos.

La misma sala muestra la síntesis multirol como una pieza separada de las decisiones: los rótulos *Consultiva* y *No aplicada* permanecen visibles, y el detalle distingue unanimidad, desacuerdo o revisión inválida. Las siete contribuciones conservan autor, acción y handles de soporte, además de indicar si algún rol recomienda revisión humana. No se ofrecen controles de aprobar, rechazar, activar o aplicar, porque esa superficie explicaría un ciclo de gobierno que todavía no está implementado.

El recorrido temporal vuelve a proyectar el mapa, la ficha y la escena espacial con el prefijo de eventos disponible en la posición seleccionada. Por tanto, al retroceder a una decisión no se muestran recuerdos o resultados futuros. La vista bidimensional y la tridimensional consumen el mismo modelo semántico. La segunda aporta una lectura espacial opcional de roles y transiciones, mientras que el inspector conserva el detalle necesario para auditar cada afirmación. La Figura 5.2 muestra esta correspondencia sobre una traza persistida.




Figura 5.2: Oficina tridimensional sobre el runtime persistido de una ejecución CWRU. Al seleccionar el estructurador se muestra su hipótesis, la observación esperada, el criterio de refutación y las evidencias declaradas. El estado permanece pendiente de contraste y las líneas se identifican como rutas del supervisor, no como relaciones causales inferidas.

La representación evita varios atajos visuales que producirían conclusiones engaño-

sas. Una decisión histórica sin bloque común aparece como ausente y no se deduce de su justificación. El microflujo de memoria distingue consulta, recuperación, uso y no uso; además, separa los descartes del control de calidad previo de una decisión de rechazo del agente. Una herramienta declarada solo se cuenta como utilizada cuando existe su observación. Un resultado de ejecutor se atribuye mediante el identificador exacto de la decisión y su éxito no cambia automáticamente el contraste de la hipótesis. Asimismo, las conexiones de la escena corresponden a transiciones registradas y no a la simple sucesión temporal de dos eventos. El panel de memoria permite explorar colecciones y registros por agente. Estas vistas facilitan la inspección humana, pero no alteran el objeto canónico ni sustituyen los contratos de la API.

Estas reglas de presentación se protegen mediante una suite de navegador versionada. La prueba construye la aplicación de producción y sustituye la API por ejecuciones sintéticas congeladas; por ello no necesita lanzar el pipeline, consultar el índice vectorial ni realizar inferencias con el modelo de lenguaje. Un escenario reúne los siete roles con decisiones validadas al primer intento y otros tres aíslan memoria citada, memoria filtrada y no usada, y memoria no disponible. El corpus simulado permanece idéntico entre casos y solo cambia la traza de la ejecución, de modo que la prueba no puede convertir la mera existencia de un recuerdo en evidencia de uso.

La verificación se ejecutó en Chromium para escritorio y móvil y superó los dieciséis casos de interacción, semántica y accesibilidad. Incluye la escena tridimensional con movimiento reducido y un caso que fuerza su alternativa accesible, además de la transferencia de foco al abrir la auditoría con teclado. Se verificaron asimismo la ausencia de llamadas no declaradas, errores de página o consola y desbordamiento horizontal. La primera ejecución detectó un doble conteo de una consulta que conservaba dos identificadores técnicos; la proyección se corrigió para contar un único ciclo de recuperación. También se rechazan como inconsistentes una cita nunca recuperada y un recuerdo que figure a la vez como filtrado y entregado al agente.

La interfaz es una herramienta de investigación y operación local, no un sistema multiusuario, una consola de planta ni una solución de monitorización en streaming.

5.10.8. Despliegue reproducible

El despliegue local separa backend y frontend en contenedores. Qdrant puede activarse como servicio de memoria y los artefactos persistentes se montan en volúmenes explícitos. Ollama se mantiene como proveedor local externo, lo que permite compartir los modelos instalados sin incorporarlos a las imágenes.

El backend puede operar con la memoria JSON cuando Qdrant no está activo. Cada experimento RAG debe seleccionar el motor de forma explícita, comprobar su disponibilidad sin un mecanismo de respaldo silencioso y registrar la configuración. El despliegue actual busca reproducibilidad mínima; alta disponibilidad, autenticación avanzada y orquestación distribuida quedan fuera del alcance.

5.11. Seguridad y reproducibilidad

La seguridad se aborda mediante reducción de capacidades. Los agentes eligen entre configuraciones soportadas y herramientas declaradas. Los ejecutores validan sus entradas, la API comprueba el alcance de las rutas y el registro de candidatos rechaza objetos que resuelvan fuera del área de artefactos autorizada.

Los datos crudos se tratan como entradas inmutables. Cada transformación produce un artefacto nuevo y conserva la referencia al origen. Los errores se serializan, las políticas temporales se identifican y las decisiones incluyen el contexto necesario para su auditoría.

Las respuestas de los agentes se solicitan con el esquema JSON completo del contrato esperado. Tras la validación sintáctica se aplican invariantes semánticas dependientes del rol. Si una propuesta ordinaria los incumple, el mismo modelo recibe los errores concretos y dispone de una única regeneración; el respaldo determinista solo se activa cuando también falla ese intento o el proveedor no responde. Cada intento conserva origen, estado, causa y enlace al intento anterior. Los identificadores, rutas de artefactos, límites de protocolo y demás campos administrativos son añadidos por el sistema, mientras que el contenido semántico de hipótesis, alternativas, evidencias y configuraciones continúa siendo decisión del agente. El servidor puede normalizar alias de la taxonomía, completar campos administrativos de la envoltura e imponer coherencia entre campos ya emitidos por el modelo. Esta última operación puede endurecer un estado si contradice incidencias críticas declaradas en la misma salida, pero no introduce evidencia nueva y queda reconstruible desde la respuesta registrada. En la repetición final observada, la normalización de seis verificadores no cambió ningún veredicto ni añadió incidencias. Así, una errata de forma no provoca por sí sola un respaldo y no se permite que el modelo falsifique la trazabilidad.

En la verificación de informes, las comprobaciones deterministas pueden endurecer el veredicto por seguridad. Esta superposición queda declarada con sus causas y se muestra separada: el informe puede quedar protegido, pero la decisión no se presenta como éxito autónomo del verificador.

La reproducibilidad se apoya en:

- configuraciones estructuradas y serializables;
- separación entre propuesta generativa y cálculo determinista;
- particiones y políticas explícitas;
- modelos predictivos y embeddings identificados por versión y dimensión, y modelo de chat cuando la ejecución conserva su manifiesto de inferencia;
- huellas de fuentes y artefactos cuando están disponibles;
- instantáneas completas de estado y decisiones;
- reconstrucción del índice desde evidencia canónica;
- registro separado de mecanismos de respaldo, revisiones y gobierno de memoria.

Estas medidas permiten repetir el flujo y explicar diferencias. No garantizan identidad numérica entre cualquier hardware o versión de librería, ni eliminan la variabilidad del modelo de lenguaje. Los experimentos deberán fijar el entorno, las semillas y los parámetros admitidos por el proveedor.

5.12. Cobertura funcional

La implementación integra el grafo jerárquico, los agentes especializados, los ejecutores deterministas y el tratamiento estructurado de errores. Los adaptadores comparten contratos y propagan procedencia; NASA IMS Set 2 puede recorrerse como trayectoria causal con agregación por snapshot, separación 20/10/70, control de discontinuidades y vista online ciega. Las decisiones de los agentes se validan, distinguen propuesta de configuración efectiva y conservan el origen de generación, los intentos y los mecanismos de respaldo. El contrato actual exige además la hipótesis común en las nuevas decisiones de los siete roles. La integración con `qwen3.5:4b` se comprobó en un banco cerrado de 45 decisiones efectivas, todas válidas en el primer intento lógico tras normalización conservadora. Por separado, una ejecución CWRU completa conservó 18 decisiones registradas como LLM sin respaldo, aunque su artefacto no permite atribuirlos a una versión exacta del modelo de chat. Estas verificaciones acreditan la implementación, pero no estiman robustez general ni valoran la corrección científica de las hipótesis.

El ciclo RAG comprende episodios, candidatos pendientes, gobierno persistente, búsqueda exacta o vectorial intercambiable, control determinista de calidad y auditoría de citas e influencia. Los informes utilizan un catálogo cerrado de evidencias y la aplicación reúne persistencia, API, interfaz web y despliegue local reproducible. Esta cobertura proporciona el instrumento necesario para el estudio; las limitaciones experimentales y el trabajo futuro se concentran en los capítulos de resultados y conclusiones.

Capítulo 6

Diseño experimental y pruebas realizadas

6.1. Propósito y alcance

Este capítulo transforma la metodología del capítulo anterior en un conjunto de experimentos verificables. Su función no es narrar el desarrollo de la aplicación ni adelantar las conclusiones, sino declarar qué pruebas se han realizado, qué evidencia pueden aportar y qué protocolo queda fijado para la evaluación principal. Esta distinción es necesaria porque el sistema está más avanzado como infraestructura que como estudio empírico sobre datos *run-to-failure* reales.

Se consideran tres estados experimentales. Las **pruebas de ingeniería** verifican contratos, trazas y conexión entre componentes. El **baseline causal oficial** recorre NASA IMS Set 2 con partición, calibración y vistas versionadas; aporta una referencia descriptiva reproducible sobre la trayectoria real. Por último, el **contraste agéntico** comprende las comparaciones con y sin memoria, las réplicas y la rúbrica externa que aún deben completarse para atribuir efectos al razonamiento o al RAG.

En consecuencia, una ejecución completa del software no se equipara a la validación de una hipótesis. Del mismo modo, una recuperación correcta desde la memoria no demuestra que el agente la haya interpretado bien, y una mejora en una señal sintética no constituye evidencia sobre la trayectoria oficial. El alcance inferencial de cada familia experimental se resume en la Tabla 6.1.

6.2. Pruebas de ingeniería ya ejecutadas

6.2.1. CWRU como baseline secundario

CWRU se utilizó para comprobar el flujo binario etiquetado y para detectar regresiones tras modificar la arquitectura. Se ejecutaron comparaciones controladas de umbral, tamaño de ventana y familia de detector, manteniendo en cada comparación el resto de la configuración. En parte de estas pruebas, los agentes propusieron las alternativas y los ejecutores materializaron únicamente configuraciones soportadas.

Estas ejecuciones permiten comprobar cuatro capacidades. En primer lugar, un agente puede formular una hipótesis y expresarla mediante un contrato válido. En segundo lugar, la propuesta puede convertirse en una configuración reproducible sin ejecutar código generado por el modelo de lenguaje. En tercer lugar, los artefactos

Tabla 6.1: Estado y alcance de las familias experimentales.

Familia	Procedencia	Estado	Evidencia admisible
CWRU etiquetado	Oficial CWRU	Ejecutada	Regresión del pipeline, ejecución de alternativas y compatibilidad con clasificación binaria
NASA IMS-like	Sintética por construcción	Ejecutada	Integración temporal, reintentos, trazabilidad agéntica y fallos controlados
Memoria RAG	Corpus de episodios gobernados	Pruebas técnicas y piloto pareado ejecutados	Captura, recuperación y filtrado; el piloto produjo <i>retrieval</i> sin uso y no demuestra un efecto beneficioso
NASA IMS Set 2	Oficial NASA	Baseline PCA causal, piloto PCA–Isolation Forest y gate repetido P3 sin memoria ejecutados	Estudio descriptivo longitudinal y evidencia contractual, incluida evidencia negativa, del puente trigger–run; no validación supervisada ni efecto de memoria o política
Benchmark por snapshot	Oficial NASA	Mecánica, baseline y una pasada pareada ejecutados; réplicas pendientes	Evidencia parcial de H4 y banco común para contrastar H1–H3
Comparación Qwen	Misma evidencia congelada	Posterior	Diferencias conductuales entre Qwen 3.5 y Qwen 3

permiten relacionar la propuesta, la configuración efectiva y las métricas calculadas. Finalmente, el pipeline común conserva el comportamiento esperado al cambiar la forma de invocarlo.

Los valores obtenidos en estas pruebas se reservan para el capítulo de resultados. En este capítulo solo se establece su función experimental. CWRU no representa una trayectoria longitudinal hasta fallo: sus ventanas etiquetadas no deben utilizarse para inferir onset, persistencia o lead time. Por ello actúa como benchmark secundario de clasificación y como prueba de regresión, de acuerdo con la taxonomía de la Tabla 4.1.

6.2.2. Pilotos NASA IMS-like sintéticos

Los pilotos sintéticos reproducen la organización temporal y el formato de entrada esperado para NASA IMS, pero sus señales y etiquetas se generan por construcción. Se han empleado para recorrer el pipeline completo, comprobar el perfil *run-to-failure*, ensayar políticas proxy y producir casos de éxito parcial, rechazo y sobrecorrección. También han permitido verificar que un evaluador no aprueba automáticamente una ejecución por haber completado el procesamiento.

Sobre estos pilotos se ejecutaron reintentos acotados. El modelador recibió un resumen estructurado del error y pudo mantener, modificar o abandonar su estrategia. Esta prueba es relevante para la observación conductual: permite registrar si el agente identifica el problema dominante, si el cambio propuesto actúa en la dirección esperada y si reconoce los efectos adversos. El límite de intentos impide interpretar una búsqueda indefinida como capacidad autónoma de optimización.

También se ensayaron varias familias deterministas de detección y reconstrucción. Su propósito fue validar compatibilidad, disponibilidad de artefactos y tratamiento uniforme de las métricas, no establecer qué modelo es mejor para NASA IMS oficial. Algunas políticas antiguas asignaban clases temporales proxy a partes de la trayectoria sintética. Esas etiquetas se mantienen identificadas como sintéticas o proxy y no se reutilizan como *ground truth* del caso real.

La principal limitación de esta familia es su construcción conocida. La frontera de degradación, la intensidad del cambio y el número de trayectorias no reproducen la incertidumbre del banco real. En consecuencia, estos pilotos aportan evidencia de integración y ejemplos para auditar decisiones, pero no evidencia científica sobre la degradación de los rodamientos NASA.

6.2.3. Verificación del replay determinista

Antes de incorporar triggers o llamadas a Qwen se verifica de forma aislada el bucle determinista. Una fixture saneada y versionada contiene baseline, calibración y dos ticks de monitorización, cuatro canales y columnas señuelo con información futura. Las pruebas exigen que el servicio lea únicamente la lista positiva de campos, que un cambio en el sufijo no altere el primer tick, que los canales de telemetría no reciban diagnóstico y que un gap abra un nuevo segmento.

La persistencia se somete a reintentos y fallos simulados. Repetir el mismo identificador de comando debe devolver el tick original; una revisión obsoleta no puede avanzar el cursor; y, si el proceso se interrumpe tras escribir el commit pero antes de actualizar el estado resumido, la reapertura debe recuperar una única observación. La API se prueba además para impedir que el body sustituya la identidad de sesión contenida en

la ruta.

La paridad completa se ejecuta localmente sobre los artefactos oficiales ignorados por el control de versiones. Recalcula las 18.696 ventanas y los 984 snapshots a partir del bundle congelado y compara únicamente outputs seguros con la trayectoria retrospectiva. Esta prueba está separada de la suite portable: requiere comprobar previamente la presencia y las huellas de los artefactos NASA, y estos no se incorporan a una fixture de repositorio.

6.2.4. Gate determinista de activación P3

El protocolo NASA-RTF-HYB-P3-01 reutiliza los 689 ticks del mismo replay y mantiene invariables modelo, escalador, umbral y política de salud. Set 2 ya había sido inspeccionado, por lo que se trata de un estudio retrospectivo descriptivo y no de un holdout. La política se congela con $B = 7$, $K = 3$, $R = 1$ y cooldown de 51.600 segundos. Estos parámetros y la versión del bundle no dependen de la longitud efectiva del sufijo.

P3 considera, por orden, pérdida de continuidad, escalada a crítico, confirmación persistente y cierre. Las tres primeras solicitudes son variables y todas piden el mismo conjunto de siete roles para no introducir todavía un confusor de routing; el cierre queda fuera de presupuesto. En el corte estrictamente determinista de este gate no se ejecutaron los roles: Qwen, memoria y runs hijas permanecieron desactivados. La revisión causal posterior se trata como un experimento separado para no confundir la activación del trigger con la calidad generativa. En este corte se midieron eventos emitidos, suprimidos y coalescidos, utilización de B , cobertura de episodios persistentes, deduplicación y reconstrucción tras reinicio.

Las pruebas sintéticas recorren las fronteras $K - 1/K/K + 1$, recuperación, reen-trada sin rearme, gap, cooldown, colisión de candidatos, agotamiento de presupuesto e identificadores máximos. También manipulan políticas, seed, eventos y commits recalculando sus hashes; la sesión debe rechazarlos si dejan de corresponderse con el scorer, el bundle registrado o la transición causal. El golden local añade el recorrido completo NASA y fija una proyección semántica del ledger para detectar cambios posteriores.

6.2.5. Protocolo de revisión causal de un trigger P3

Una vez cerrado el motor determinista, se seleccionó un trigger emitido de transición a estado crítico y se congeló una vista causal en su corte. La revisión pidió, en orden fijo, supervisor, limpiador, estructurador, modelador, evaluador, redactor y verificador. Todos operaron en modo exclusivamente propositivo, sin lectura de señal cruda, ajuste, reentrenamiento ni ejecución de recomendaciones; la memoria permaneció desactivada y la política activa no podía modificarse.

La unidad observada fue la decisión por rol. Se registraron origen, estado de validación, intento lógico, reparación y respaldo. El criterio de aceptación exigió siete decisiones de origen LLM, validadas en el primer intento, sin reparación ni respaldo. Una ejecución que terminase gracias a un mecanismo determinista podía acreditar continuidad segura, pero quedaba excluida del resultado de fiabilidad agéntica.

Un primer intento técnico alcanzó dos timeouts y activó dos respaldos. Se conservó solo como diagnóstico de integración y motivó un timeout específico para la revisión de monitorización; no se incorporó al resultado nominal. Tras ese ajuste se realizó una

nueva ejecución completa. La unidad experimental es una única revisión ligada a un único trigger: sus siete decisiones son medidas internas de la misma ejecución, no siete réplicas independientes. El diseño comprueba viabilidad y trazabilidad del puente, pero no estima una tasa poblacional de éxito ni compara memoria OFF frente a RAG.

6.2.6. Gate repetido sobre los cuatro contextos P3

Tras validar el puente nominal se prerregistró una batería cerrada sobre los cuatro triggers primarios emitidos por P3: transición de estado en el cursor 353, alerta persistente con corte 498 e inicio 496, transición de estado en el cursor 499 y cierre de sesión en el cursor 688. Cada contexto se reprodujo en tres sesiones nuevas y convocó los siete roles en orden fijo. La batería contiene, por tanto, 12 runs hijas y 84 decisiones. Las tres repeticiones miden estabilidad generativa bajo los mismos cortes; no son trayectorias físicas ni activos independientes.

El plan inmovilizó Qwen 3.5:4b por su digest, `think=false`, temperatura cero, contexto de 8.192 tokens, máximo de 4.096 tokens de salida, timeout de 180 segundos y cero reparaciones JSON internas. La memoria permaneció off y toda recomendación tuvo estado `not_applied`. También se sellaron los hashes de las fuentes críticas, prompt, esquema, catálogo de acciones y manifiesto. Cada llamada física conservó su propia traza; una segunda llamada de corrección contractual no se ocultó como primer intento.

El gate exigió 12 hijas resueltas, 84 observaciones no duplicadas, origen LLM del 100 %, al menos 90 % de respuestas válidas al primer intento y cero fallbacks, errores o decisiones no agénticas. Claims prudentes, hipótesis estructural, grounding, binding, trazas lógica y física, catálogo de acciones, memoria desactivada y política no aplicada debían alcanzar el 100 %. La consistencia de acción se mantuvo como descriptor, no como umbral, porque más de una acción consultiva puede ser razonable ante el mismo corte.

La primera batería completa, V2, quedó bloqueada por tres textos fuera de alcance. Después de introducir el control canónico en el runtime se creó un plan V3 nuevo y se repitieron los 12 casos completos con nuevas identidades; no se reutilizó ni sustituyó ninguna salida. V3 eliminó los sobrealcances, pero una hija produjo dos respaldos al agotar supervisor y limpiador sus dos intentos por referencias ajenas a la vista causal. Ambos planes son resultados publicables y negativos. Una V1 cancelada antes de un resultado calificable solo sirvió para corregir el instrumento y no entra en la comparación. No se autoriza una repetición selectiva, una ablación RAG ni aplicación adaptativa de políticas a partir de este gate bloqueado.

6.2.7. Verificación focal de la síntesis consultiva multirol

Después del catálogo por registro se verificó una proyección determinista de las siete decisiones de cada revisión. La unidad de esta prueba es el objeto de software, no el rol ni la trayectoria física. Fixtures con decisiones cerradas permiten comprobar que cada contribución conserva autor, acción y handles de evidencia, y que la propuesta agregada mantiene su hash y sus enlaces con resultado, vista y catálogo.

La batería focal recorre las cinco acciones admitidas y su mapeo a `no_change`, `observation`, `workflow` o `abstain`. También provoca unanimidad, desacuerdo, fallback, recomendación de revisión humana y manipulación de identidades o eviden-

cias. Los criterios exigen siete contribuciones en orden, ausencia de mayoría fabricada, `invalid_review` ante el origen no LLM ejercitado y cálculo de revisión humana como OR de las decisiones fuente. El constructor exige las siete decisiones; una revisión sin ese conjunto no genera propuesta.

Este protocolo verifica trazabilidad y ausencia de efectos laterales. No consulta Qwen, no ejecuta un replay NASA, no evalúa la verdad de una recomendación y no crea, valida o aplica una política. Los recuentos de tests no se incorporan a las 84 decisiones de V2/V3 ni modifican el gate publicado.

6.2.8. Integración de agentes y memoria RAG

Las pruebas técnicas de memoria han recorrido el ciclo desde un episodio de decisión hasta su recuperación posterior. Se ha comprobado la separación por rol, la persistencia de citas, el registro del uso declarado y la generación de auditorías. Existen casos en los que un recuerdo de advertencia fue recuperado pero el agente repitió la acción desaconsejada, así como casos en los que la memoria provocó una alternativa distinta sin producir por ello una mejora operacional suficiente.

Estas observaciones justifican medir por separado recuperación, fidelidad, cambio conductual y resultado. Demuestran que la infraestructura puede mostrar la diferencia entre *leer* un recuerdo y *aplicarlo* correctamente. No demuestran todavía H2 o H3, porque los casos disponibles no forman una batería factorial con corpus, prompts, entradas y réplicas congelados.

El piloto se ejecutó con búsqueda densa exacta sobre el almacenamiento local. En esta batería no se compararon Qdrant y pgvector, por lo que no se extraen conclusiones sobre su interoperabilidad, relevancia relativa o superioridad tecnológica. El motor de recuperación no constituye una variable científica principal ni una aportación del trabajo. La evidencia canónica sigue formada por episodios, candidatos, decisiones y revisiones persistidos.

6.2.9. Piloto pareado sobre la trayectoria oficial

Se ejecutó una primera pasada de diagnóstico con la configuración local de Qwen 3.5, usando dos familias deterministas: PCA por error de reconstrucción e Isolation Forest. Para cada familia se emparejó una condición sin memoria con otra que activaba recuperación, manteniendo iguales datos, particiones, ventanas, características, hiperparámetros y semilla del ejecutor. Cada celda contiene una sola generación, por lo que esta pasada sirve para detectar fallos del protocolo y no para estimar variabilidad del modelo de lenguaje.

En las dos condiciones con recuperación, estructurador y evaluador recibieron un contexto efectivo vacío. El modelador recuperó el mismo único recuerdo, con similitud aproximada de 0,558. Era un caso frontera basado en precisión, recall y tasa de falsos positivos de un piloto etiquetado, con procedencia y perfil desconocidos. El control de calidad vigente durante la ejecución lo entregó con cautela; la auditoría posterior mostró que esas métricas eran incompatibles con una consulta oficial sin etiquetas por snapshot. La regla general se reforzó para excluir recuerdos cuyo perfil se deduzca de métricas binarias cuando no exista evidencia temporal compatible.

Ningún agente citó ni declaró haber usado el recuerdo. El benchmark clasificó ambas condiciones activadas como *retrieval only*; las configuraciones efectivas y todas las

métricas temporales fueron idénticas a sus pares sin memoria. El resultado no permite concluir que la memoria ayude ni que perjudique: el corpus gobernado todavía no contiene una lección pertinente que pueda probarse bajo este expediente.

El protocolo distingue recuperación desactivada, contexto vacío y contexto observado sin influencia declarada. En este último caso se conserva el identificador del contexto para mantener la trazabilidad, pero se prohíben las citas y las descripciones de influencia. Esta separación evita confundir la exposición a un recuerdo con su uso efectivo.

El manifiesto de esta pasada no registró la versión exacta del modelo local; por ello, no se utiliza como evidencia reproducible para comparar versiones de Qwen. Una réplica comparable debe fijar el modelo, el modo de razonamiento, los tiempos máximos, el motor de recuperación, el embedding y los valores de k . La captura web de auditoría presenta el embudo recuperado–citado–usado–cambio y permite comprobar visualmente que los dos últimos escalones permanecieron en cero, sin representar una mejora inexistente.

6.3. Preparación del caso NASA IMS real

El escenario empírico principal es NASA IMS Set 2, Bearing 1 y el primer canal, siguiendo la selección metodológica del capítulo anterior [14, 15]. La extracción local ya está completa. El inventario contiene 984 snapshots ordenables por la marca temporal de su nombre, desde el inicio hasta el final documentado del ensayo.

Se realizó una comprobación estructural de la extracción. Cada snapshot contiene 20.480 observaciones y cuatro canales numéricos; el total inventariado no presenta ficheros con una longitud o un número de columnas diferente. La cadena de procedencia vincula además el archivo descargado con la URL admitida, su tamaño y huella, y con el inventario y la huella completa del árbol extraído. Esta validación permitió construir el manifiesto del experimento. La ejecución causal posterior confirmó los 984 snapshots, los 983 intervalos de 600 segundos, la ausencia de gaps bajo la tolerancia declarada y la partición exacta de 197, 98 y 689 snapshots.

El primer canal representa Bearing 1 en este set y permite mantener un caso mono-canal. El evento final documentado es un fallo de pista exterior del mismo rodamiento. Esta información solo estará disponible en la vista retrospectiva. Los agentes que actúen durante la monitorización no recibirán el tipo de fallo, el instante final, la vida relativa ni el tiempo restante.

Se ha ejecutado un baseline PCA determinista sobre estas señales y existen métricas descriptivas por snapshot. También se ha realizado la pasada piloto PCA–Isolation Forest con memoria desactivada y recuperación activada, además de una revisión causal nominal y tres repeticiones completas de los cuatro contextos P3 con memoria desactivada. Esta batería repetida quedó bloqueada y no constituye una estimación poblacional: todavía faltan trayectorias o contextos independientes, la ablación con un corpus pertinente y el contraste Qwen 3.5–Qwen 3 sobre el caso oficial. El baseline, el piloto y las revisiones se utilizan para verificar el protocolo y caracterizar la trayectoria; no se presentan como rendimiento supervisado ni como comparación concluyente de familias.

6.4. Puerta de preparación previa al benchmark pesado con Qwen

Antes de generar nuevas respuestas dentro del benchmark pesado se ejecuta una evaluación determinista de preparación. Su finalidad es evitar que la batería se limite a repetir NASA IMS Set 2 hasta que los agentes se adapten accidentalmente a su estructura. La puerta contiene quince requisitos y solo autoriza ese benchmark cuando todos están disponibles, ejecutados, superados y acompañados por referencias de evidencia.

Los requisitos se agrupan en cuatro bloques:

- trazabilidad del origen, intentos, reparaciones y mecanismos de respaldo, además del vínculo entre decisión, configuración efectiva, ejecutor y artefactos;
- corpus RAG congelado, versionado y separado de los grupos de evaluación, sin información futura ni etiquetas prohibidas;
- cobertura de NASA IMS oficial, CWRU y un tercer formato genérico CSV, TSV o NPZ que recorra el ejecutor común;
- perturbaciones de canales, frecuencia de muestreo, ganancia, offset, polaridad, valores no finitos, dropout, orden temporal, gaps, truncamiento, cebos de futuro y corpus de memoria adversarial.

Cada perturbación declara antes de ejecutarse si espera invariancia, adaptación controlada o aislamiento. Por ejemplo, una permutación con mapeo semántico conservado debería mantener la decisión; una frecuencia distinta debería adaptar la duración física de ventana o bloquearse de forma explícita; y un recuerdo incompatible debe quedar fuera del contexto efectivo sin desaparecer de la traza.

El benchmark pesado con ejecutores y memoria queda **no autorizado**: ninguno de los quince requisitos dispone todavía de un resultado superado con evidencia. Los adaptadores NASA y CWRU existen, pero la batería comparable de perturbaciones no se ha ejecutado; el tercer formato genérico, el corpus congelado y parte de la evidencia end-to-end permanecen pendientes. Esta puerta no impide la batería ligera exclusivamente decisional descrita más adelante: esa batería no transforma datos ni consulta memoria y se utiliza precisamente para cerrar la fiabilidad agéntica antes de autorizar el benchmark costoso.

6.5. Protocolo congelado para el benchmark principal

6.5.1. Caso, vistas y partición temporal

La trayectoria se procesa una sola vez en orden cronológico. La unidad física de monitorización es el snapshot y la unidad de contexto para el agente es un expediente construido a partir de la evidencia disponible hasta ese instante. Las ventanas internas sirven para extraer características y scores, pero no se contabilizan como observaciones longitudinales independientes.

La partición queda fijada antes de examinar los resultados finales. El primer 20 % de snapshots forma el baseline nominal de entrenamiento; el siguiente 10 % se reserva

para calibrar umbrales y políticas de alerta; el 70 % restante se procesa como monitorización fuera del ajuste. Estos límites son una decisión operativa previa, no etiquetas oficiales de normalidad y degradación. Se incluirá un análisis de sensibilidad limitado a particiones alternativas preespecificadas, sin elegir retrospectivamente la que ofrezca mejores resultados.

La vista *online blind* incluye únicamente el historial observado, los scores causales, los estados previos y el catálogo de herramientas permitido. La vista retrospectiva se genera después de cerrar cada decisión e incorpora la distancia al final registrado para situar cuándo aparecen las alertas. Ese intervalo no constituye RUL, tiempo prospectivo restante ni validación de un onset físico. Ningún campo retrospectivo puede formar parte del prompt, del ajuste del modelo, de la calibración ni de la consulta de memoria.

Los snapshots de monitorización no se usan para modificar el umbral durante la misma familia experimental. Tampoco generan recuerdos reutilizables hasta que se cierran todas sus condiciones. Esta regla evita que una condición posterior reciba información derivada del test que no estaba disponible para la condición inicial.

6.5.2. Reducción de ventanas a snapshots

Cada snapshot se divide con una configuración de ventana común a todas las condiciones comparadas. Las características y el score se calculan por ventana y después se reducen a un único registro temporal. La reducción obligatoria conserva, como mínimo, la mediana del score, el percentil 90, la proporción de ventanas en alerta, el número de ventanas y su dispersión. La alerta del snapshot se deriva de una política versionada, no de la repetición de ventanas solapadas.

La política inicial considera alerta de snapshot cuando al menos la mitad de sus ventanas supera el umbral. El análisis conserva también la proporción continua para no perder eventos parciales. La persistencia se calcula después, sobre snapshots consecutivos, y se interrumpe ante un gap temporal que exceda la tolerancia declarada. La secuencia nunca se rellena suponiendo que el activo permaneció en alerta durante una ausencia de medición.

La agregación por snapshot ya está implementada y validada. Agrupa las ventanas por ensayo y captura, calcula mediana, percentil 90, media y desviación del score, y obtiene la fracción de ventanas alertadas. Con el umbral inicial de 0,5, produce una tabla de trayectoria persistida en CSV, con un registro por snapshot. El indicador de salud, la persistencia, la tasa de alertas previa a monitorización y el instante de la primera alerta persistente se calculan sobre esta secuencia agregada. El baseline oficial ya aplica el componente a NASA IMS real con split causal y vista online ciega. La distancia retrospectiva hasta el final registrado se calcula después de cerrar las decisiones y no se interpreta como RUL ni como onset físico confirmado.

La política temporal anterior basada en una frontera binaria fija no se usará como objetivo principal. El tramo de monitorización permanece sin etiqueta de degradación por snapshot. El evento de fallo documentado se utiliza solo para la evaluación retrospectiva, y cualquier punto de cambio estimado se presenta como resultado del método, no como anotación oficial ni como onset físico.

6.5.3. Regímenes de decisión

Se diferencian dos regímenes experimentales. En el régimen de **decisión abierta**, el agente puede elegir entre las familias y los hiperparámetros autorizados. Este régimen permite estudiar cambios de hipótesis, alternativas y configuraciones. En el régimen de **ejecución fijada**, el protocolo recorre las mismas familias deterministas para compararlas bajo una configuración común.

En el segundo régimen se conserva la propuesta original del agente, pero se registra qué campos fueron sustituidos por el protocolo. La influencia de la memoria sobre una propuesta no se atribuye a la ejecución si la configuración efectiva estaba prefijada. Las métricas del detector y las métricas de conducta se analizan entonces como resultados distintos.

Las familias disponibles en la primera batería causal son PCA por error de reconstrucción, Isolation Forest y One-Class SVM. El autoencoder denso se reserva para una extensión posterior, cuando exista evidencia suficiente para justificar su complejidad y su readiness temporal. El presupuesto de entrenamiento y el conjunto de características se mantienen constantes dentro de cada comparación. La predicción de RUL queda fuera de este experimento porque una sola trayectoria no ofrece evidencia suficiente para validarla.

6.6. Factores, controles y réplicas

6.6.1. Factores experimentales

La intervención principal es el modo de memoria. La comparación de modelos de lenguaje constituye un segundo factor, pero se añadirá solo después de cerrar la batería con Qwen 3.5. El backend de retrieval se estudia en una prueba diagnóstica separada para no confundir aproximación del índice con razonamiento.

Tabla 6.2: Factores del diseño experimental congelado.

Factor	Niveles	Uso en el análisis
Modelo de agente	Qwen 3.5; Qwen 3 en la extensión posterior	Comparación conductual pareada con el resto del protocolo fijo
Modo de memoria	Desactivada; solo retrieval; RAG filtrada; RAG completa controlada	Ablación principal de H2 y H3
Régimen de decisión	Abierto; ejecución fijada con propuesta observable	Separar selección agéntica de comparación determinista
Motor de retrieval	Búsqueda exhaustiva; Qdrant con el mismo embedding	Equivalencia de rankings y coste, no calidad del agente
Familia de detector	PCA; Isolation Forest; One-Class SVM; autoencoder denso	Comparación operacional dentro de la batería fijada

La condición sin memoria no realiza consulta ni añade contexto. En *solo retrieval*, se ejecuta y evalúa la búsqueda, pero el agente recibe el mismo prompt que en la condición sin memoria. La condición RAG filtrada inyecta únicamente los recuerdos que superan

el control de calidad. La condición completa controlada retira el filtro experimental objeto de la ablación, aunque mantiene las exclusiones de seguridad, procedencia y contaminación.

La evaluación del buscador se inicia con una colección exhaustiva sobre el corpus congelado. Qdrant recibe los mismos registros, textos, embeddings y filtros. La verificación previa exige cero incompatibles, $\text{hit}@k$ en todas las consultas críticas y $\text{recall}@k$ macro de al menos 0,95 respecto al ranking exacto. Si no se cumple, la batería conductual utilizará el baseline exhaustivo; si se cumple, Qdrant permanecerá fijo en todas las condiciones con retrieval y la latencia se informará como variable operacional.

6.6.2. Variables de control

Antes de lanzar la primera réplica se congelan la extracción y el hash del dataset; el activo, canal y orden temporal; la partición; la configuración de ventanas; la agregación por snapshot; las características; los ejecutores y sus versiones; los contratos; las instrucciones base; el catálogo de herramientas; el presupuesto de contexto y los límites de reintento.

En las condiciones de memoria se mantienen además el corpus y su hash, la versión de cada episodio, el proveedor y versión de embeddings, el valor de k , el tamaño del conjunto de candidatos previo al filtrado, los umbrales del control de calidad y el orden de desempate. Reconstruir el índice no autoriza a modificar el corpus. Una incompatibilidad de dimensión o de modelo de embeddings invalida la consulta en lugar de reindexar silenciosamente.

Para los modelos de lenguaje se registran la versión exacta, los parámetros de muestreo, la semilla cuando sea soportada y el presupuesto de tokens. El orden de las condiciones se contrabalancea para reducir efectos de calentamiento del servicio. El entorno de cómputo y la versión de las dependencias se conservan en el manifiesto experimental, pero no se tratan como factores.

6.6.3. Unidades y número de repeticiones

Las unidades del análisis no se mezclan. La Tabla 6.3 declara qué se repite y qué significado tiene cada repetición.

Las cinco generaciones agénticas se emparejan por expediente y condición. Si el proveedor admite semillas reproducibles, se usa el mismo conjunto de cinco semillas en todas las celdas. Si no lo garantiza, se conserva el orden de generación y se informa esta limitación. Una salida resuelta mediante una decisión determinista de respaldo se registra como fallo técnico y no cuenta como respuesta válida del modelo.

El conjunto de treinta consultas de retrieval se prepara antes de obtener los rankings. Incluye consultas del estructurador, modelador y evaluador, con casos relevantes, advertencias, incompatibilidades de procedencia y recuerdos que no deberían reutilizarse. Los juicios distinguen relevancia, cautela e incompatibilidad. Cuando sea posible, el revisor asigna estos juicios sin ver la posición devuelta por cada backend.

Las repeticiones del LLM caracterizan su variabilidad bajo un mismo expediente, pero no solucionan la falta de trayectorias independientes. Por esta razón las métricas PHM se presentan como estudio de caso y no se someten a pruebas que supongan independencia entre los 984 snapshots.

Tabla 6.3: Unidades de análisis y política de repeticiones.

Objeto	Unidad	Repetición	Interpretación
Comportamiento del agente	Episodio de decisión por rol y expediente	Cinco generaciones por celda	Variabilidad del modelo, no cinco activos independientes
Retrieval	Consulta con juicio de relevancia	Treinta consultas, diez por rol principal	Calidad media sobre consultas predefinidas
Seguimiento temporal	Snapshot agregado	984 observaciones ordenadas en una trayectoria	Serie dependiente; no réplicas independientes
Resultado del activo	Trayectoria Set 2, Bearing 1	Un estudio de caso	Evidencia descriptiva, sin generalización entre rodamientos
Ejecutor determinista	Configuración efectiva	Una ejecución y repetición de control seleccionada	Comprobar reproducibilidad, no aumentar n

6.7. Variables de respuesta

Las variables de respuesta se agrupan según el nivel causal descrito en la metodología. La Tabla 6.4 relaciona cada hipótesis con su unidad y sus observables principales.

Tabla 6.4: Operacionalización de las hipótesis.

Hipótesis	Unidad	Variables primarias	Evidencia complementaria
H1	Episodio de decisión	Validez al primer intento, ejecutabilidad y decisión respaldada	Correcciones, decisiones de respaldo, hipótesis, alternativas, coherencia y confianza
H2	Consulta y contexto	Precision@ k , recall@ k , MRR y tasa de incompatibles excluidos	Latencia, coste de contexto y distribución de cautelas
H3	Par de decisiones	Cambio de hipótesis o acción, ayuda y perjuicio	Citas válidas, uso declarado, confianza y revisión humana
H4	Snapshot y trayectoria	Primera alerta algorítmica persistente, intervalo retrospectivo hasta el final registrado y tasa de alertas premonitorización	Tendencia, episodios, picos aislados, monotonidad y volatilidad

6.7.1. Conducta de los agentes

Para cada rol se calcula la proporción de contratos válidos al primer intento, reparaciones producidas por el propio LLM, decisiones de respaldo, superposiciones de

política, decisiones ejecutables y decisiones respaldadas por el resultado. Una superposición puede proteger el resultado efectivo, pero no se contabiliza como autonomía del agente. Se codifican además los cambios de hipótesis, alternativas, configuración, confianza, reconocimiento de límites y decisión de continuar o detenerse.

La coherencia numérica se evalúa contra los valores disponibles en el expediente. Una explicación que invierta la dirección de un umbral o atribuya una métrica a una configuración distinta se marca como inconsistente aunque el JSON sea válido. El uso de una herramienta solo se contabiliza cuando existe evidencia del resultado consultado y una referencia permitida.

Antes de ejecutar modelos de anomalías se aplica una batería ligera de fiabilidad exclusivamente decisonal. Contiene 15 escenarios pequeños sobre CWRU y NASA y recorre las nueve entradas generativas del flujo: supervisión, limpieza, estructuración, modelado inicial y revisión, evaluación, redacción, revisión del informe y verificación. La memoria permanece desactivada y no se cargan señales ni se invocan ejecutores, de modo que un fallo se atribuye al contrato, al prompt, al proveedor o al propio razonamiento y no al coste del pipeline.

Cada escenario se repite inicialmente tres veces, para un total de 45 decisiones. La batería se detiene y se considera fallida ante cualquier respaldo, salida no agéntica, error, traza incompleta o superposición determinista del verificador; también exige al menos un 90 % de validez al primer intento. Este umbral funciona como filtro de desarrollo, no como estimación estadística del 99 %. Solo después de superarlo se amplían las réplicas y se habilitan, por orden, los ejecutores, la memoria y las comparaciones de modelos de lenguaje.

6.7.2. Recuperación y uso de memoria

La recuperación se evalúa antes de observar las respuestas del agente. Sobre las consultas con relevancia conocida se calculan $\text{hit}@k$, $\text{precision}@k$, $\text{recall}@k$ y MRR por rol. También se informa cuántos recuerdos retira el control de calidad y por qué: procedencia incompatible, rol incorrecto, exclusión de gobierno, veredicto inseguro, perfil distinto o similitud insuficiente.

La fidelidad se mide mediante la proporción de citas que pertenecen al contexto efectivo, citas inexistentes, recuerdos recibidos pero ignorados y consistencia entre la influencia declarada y el cambio observado. Citar un recuerdo no se considera por sí solo un uso correcto.

El efecto conductual se expresa como diferencia pareada entre la condición sin memoria y cada condición con memoria. Se registran cambios de hipótesis, alternativas, acción, confianza y decisión de parada. Después, la auditoría clasifica el resultado como ayuda, perjuicio, uso neutro, repetición de fallo o evidencia insuficiente. Esta clasificación requiere el resultado posterior y no puede ser emitida por el propio agente como autoevaluación final.

6.7.3. Resultados *run-to-failure*

Las variables primarias se calculan sobre snapshots agregados: instante del primer aviso algorítmico persistente, distancia retrospectiva hasta el final documentado, proporción de snapshots alertados durante baseline y calibración, número de episodios y trayectorias sin alerta persistente. La persistencia exige snapshots consecutivos según

la política congelada.

El indicador de salud se describe mediante tendencia de Spearman, caída, monotonidad, robustez y volatilidad nominal. Estas medidas se interpretan en conjunto: una tendencia favorable con una tasa elevada de alertas antes de monitorización no constituye un resultado operacionalmente aceptable. Esa tasa incluye calibración y, por tanto, no es una estimación independiente de falsos positivos.

Precision, recall, F1, ROC-AUC y PR-AUC solo se incluyen si existe una fuente de etiquetas defendible y siempre como métricas auxiliares. NASA IMS Set 2 no proporciona una etiqueta oficial de degradación para cada snapshot. Por tanto, no se creará una clase positiva retrospectiva únicamente para obtener estas métricas.

6.8. Prevención de contaminación experimental

El corpus de memoria se congela antes de procesar el bloque de monitorización. Los episodios producidos por una condición permanecen pendientes y no se promueven durante la misma batería. Excluir o restaurar un recuerdo deja un evento de gobierno; reconstruir el índice debe respetar esa decisión y no puede resucitar registros excluidos.

Los recuerdos específicos de datos sintéticos no se presentan como experiencia directa sobre señales oficiales. Solo pueden atravesar la frontera de procedencia aquellas lecciones generales cuya función metodológica haya sido revisada y marcada como tal. Los recuerdos con procedencia desconocida llegan, como máximo, con cautela si el perfil metodológico es compatible. Si sus etiquetas, tags o métricas revelan un perfil binario incompatible con una consulta oficial sin etiquetas, se excluyen. El filtro se aplica tanto en la consulta del backend como de forma defensiva antes de construir el prompt.

El conjunto de consultas y sus juicios de relevancia se cierra antes de comparar rankings. Los revisores no ven la condición de memoria ni el modelo de agente cuando la anonimización es posible. Los prompts, herramientas o guías no se modifican entre celdas. Si una corrección de implementación resulta necesaria, se invalida y repite la batería completa afectada en lugar de mezclar ejecuciones anteriores y posteriores.

La vista online se inspecciona mediante una lista de campos prohibidos. Una aparición de tiempo hasta fallo, vida relativa, fallo final o métricas calculadas con datos futuros invalida la réplica. La misma regla se aplica a los textos de memoria: un recuerdo creado con monitorización futura no puede llegar a una decisión anterior.

6.9. Artefactos y criterios de validez

Cada celda experimental debe producir un paquete de evidencia suficiente para reconstruir la secuencia entrada $\rightarrow$ decisión $\rightarrow$ acción $\rightarrow$ resultado. Los elementos mínimos se recogen en la Tabla 6.5.

Una réplica es **válida** si declara procedencia, respeta la partición, utiliza el corpus congelado, conserva la propuesta y la acción efectiva, no expone futuro al agente y calcula las métricas sobre la unidad correcta. Una réplica puede ser válida aunque el modelo falle o el agente tome una decisión perjudicial; ese desenlace es evidencia negativa. En cambio, una fuga temporal, una cita fuera del contexto efectivo o una agregación por ventana presentada como snapshot invalidan la comparación.

Antes de admitir el benchmark oficial se comprueba que el número de registros agregados coincide con el número de snapshots procesados, que ninguna ventana apa-

Tabla 6.5: Contenido mínimo del paquete de evidencia experimental.

Bloque	Evidencia requerida
Datos	Procedencia, inventario, hashes, orden temporal, canal, gaps y partición
Protocolo	Factores, controles, semillas, versiones y criterios de parada
Agente	Expediente recibido, hipótesis, alternativas, propuesta, confianza y limitaciones
Ejecución	Configuración efectiva, sustituciones del protocolo, artefactos y errores
Memoria	Consulta, candidatos brutos, control de calidad, contexto efectivo, citas y auditoría de uso
Temporal	Tabla por snapshot, política de agregación, alertas, indicador de salud y métricas
Revisión	Verificación de afirmaciones, juicio humano cuando exista y exclusiones

rece en dos particiones y que todos los modelos se ajustan solo con el bloque permitido. También se verifica que las colecciones de memoria usan el embedding y la dimensión declarados y que el informe final no atribuye procedencia oficial a señales sintéticas o desconocidas.

6.10. Plan de análisis

Las comparaciones de memoria se realizan de forma pareada por expediente y réplica. Para variables binarias se informa la tabla de cambios entre condiciones; para puntuaciones continuas se presentan la mediana de la diferencia, el intervalo intercuartílico y cada par individual. Las proporciones de contratos, citas o decisiones de respaldo se acompañan de intervalos compatibles con el tamaño muestral, sin reducir todas las dimensiones a un único score.

Las métricas de retrieval se resumen por consulta y por rol. Los intervalos se obtienen remuestreando consultas, no recuerdos individuales de una misma consulta. La comparación entre búsqueda exhaustiva y Qdrant informa recall del ranking de referencia, solapamiento del top- k y latencia; una diferencia de latencia no se interpreta como mejora del razonamiento.

El efecto de la memoria se considera beneficioso únicamente cuando existe un cambio atribuible a la condición, la auditoría lo juzga coherente y no empeoran los criterios de seguridad definidos. También se informan resultados neutros y perjudiciales. H3 no se acepta porque una condición con memoria produzca más texto, más citas o una mejora aislada de F1.

La trayectoria NASA se analiza descriptivamente mediante series por snapshot, primera alerta persistente, tiempo retrospectivo hasta el final, tasa de alerta premonitorización, persistencia y evolución del indicador de salud. No se calculan pruebas clásicas sobre las ventanas ni se usan las cinco generaciones del agente como si fueran cinco rodamientos. Las conclusiones se limitan al estudio de caso analizado.

La comparación Qwen 3.5–Qwen 3 repetirá las mismas celdas, expedientes, consultas, corpus y criterios. El contraste se realizará sobre diferencias pareadas de conducta y fidelidad. Los resultados de Qwen 3.5 se cerrarán antes de iniciar esta extensión para

evitar ajustar el protocolo en favor de uno de los modelos.

Capítulo 7

Resultados

7.1. Alcance de la evidencia disponible

Este capítulo presenta los resultados que pueden sostenerse con la evidencia disponible en el momento de redactar la memoria. Se distinguen expresamente dos clases de resultado. La primera corresponde a la **verificación de ingeniería**: demuestra que los contratos, el grafo, los ejecutores, la memoria y las políticas temporales realizan la función prevista. La segunda corresponde a la **evaluación científica**: exige comparaciones experimentales congeladas, réplicas y unidades de análisis independientes.

La verificación de ingeniería permite utilizar el sistema como instrumento experimental. Además, se dispone de una primera ejecución causal completa sobre NASA IMS Set 2 real. Esta ejecución describe una trayectoria y verifica el protocolo, pero no sustituye las comparaciones con réplicas ni permite inferir superioridad o generalización.

La lectura de resultados se organiza en cuatro bloques de evidencia. Esta presentación evita condensar en una tabla fuentes que responden a preguntas distintas:

Trayectoria oficial NASA IMS Set 2.

Se ha verificado la procedencia y ejecutado un baseline PCA causal sobre 984 snapshots. Permite una caracterización longitudinal descriptiva, pero no afirmar un onset físico, un diagnóstico ni rendimiento supervisado.

Pilotos NASA IMS-like sintéticos.

Permiten provocar degradación conocida y observar decisiones, revisiones y guardarraíles. Son evidencia de integración y conducta, no evidencia sobre el dataset oficial.

CWRU.

Actúa como regresión funcional del procesamiento y de la detección binaria. Acredita compatibilidad secundaria, no una evaluación longitudinal *run-to-failure*.

Pruebas deterministas.

Verifican contratos, gobierno de memoria, procedencia y agregación temporal bajo casos controlados. Demuestran el comportamiento de los mecanismos probados, no generalización externa.

7.2. Resultado previo: preparación del caso NASA IMS real

El subconjunto Set 2 de NASA IMS ha sido extraído y validado estructuralmente como fuente oficial [14, 15]. La verificación comprueba la identidad del archivo de origen, su huella, el inventario íntegro del subconjunto, la secuencia de capturas y el número esperado de canales. La procedencia queda separada de la fuente de las etiquetas, de modo que disponer de datos oficiales no convierte una política temporal construida en anotación oficial.

Este avance elimina una ambigüedad presente en pilotos anteriores: el sistema puede distinguir datos NASA reales, señales sintéticas con formato NASA y fuentes no verificadas. La distinción se conserva en los manifiestos, las decisiones, los informes y los recuerdos candidatos. Una descripción que atribuya carácter oficial a evidencia sintética se considera incompatible con la procedencia registrada.

La extracción no constituye por sí sola un resultado de diagnóstico. Sobre ella se ha ejecutado ya la trayectoria completa con partición temporal versionada y vista online ciega. Se presentan scores, alertas algorítmicas e indicador de salud como resultados descriptivos. El corpus inmovilizado, las réplicas y las ablaciones agénticas completas continúan pendientes, aunque ya se ha ejecutado una pasada pareada de diagnóstico; tampoco existe una anotación oficial continua con la que validar un onset físico.

7.3. H1: decisiones de los agentes válidas, ejecutables y auditables

7.3.1. Resultado de verificación

La primera hipótesis plantea que los agentes pueden convertir un expediente técnico en una decisión válida y ejecutable, acompañada de hipótesis, justificación y evidencia auditable. La infraestructura necesaria para observar este comportamiento está operativa.

Las salidas de los agentes se validan mediante contratos cerrados. En el contrato actual, una decisión nueva conserva una hipótesis contrastable con ámbito, corte de evidencia, observación esperada, criterio de refutación, riesgos y referencias; también conserva las alternativas consideradas, la opción elegida y la confianza. Queda registrada además la diferencia entre la propuesta del modelo y la configuración realmente ejecutada. Cuando una restricción experimental obliga a sustituir un campo, la sustitución y su motivo permanecen visibles.

Este último resultado evita una atribución incorrecta. La configuración final no se presenta como decisión libre del agente cuando procede de una política fija, un guardarraíl o un mecanismo de respaldo. Del mismo modo, una propuesta textual no se confunde con una acción materializada. La cadena observable conserva expediente, propuesta, restricciones, configuración ejecutada, métricas deterministas y los elementos necesarios para una evaluación posterior de la hipótesis.

El contrato vigente añade a las decisiones futuras el origen de generación, el identificador y orden de intento, el estado de validación y, cuando aplica, la causa y el intento anterior del respaldo. También exige el bloque común de hipótesis en los siete roles y diferencia el reintento del modelador y la revisión del informe como clases de decisión.

Estas mejoras evitan inferir origen o hipótesis desde la justificación textual. No completan retrospectivamente las ejecuciones mostradas: su traza reconstruida continúa correctamente etiquetada como evidencia histórica parcial.

Los pilotos con agentes locales confirman que los roles pueden proponer configuraciones pertenecientes al espacio permitido y justificar alternativas. También han mostrado respuestas incoherentes o decisiones que no mejoran el resultado. Estas observaciones negativas son relevantes: el sistema no equipara una explicación plausible con una decisión técnicamente respaldada. Las correcciones de contrato, los mecanismos técnicos de respaldo y los rechazos del evaluador se registran como desenlaces diferentes.

La pasada de diagnóstico sobre Set 2 permite concretar estas categorías. Se analiza una generación de referencia configurada con Qwen 3.5, sin utilizarla para estimar frecuencias. El supervisor requirió reparaciones de la transición del grafo; el limpiador produjo una propuesta ejecutable; el estructurador comparó tamaños de ventana aunque la batería experimental fijó la configuración final; y el modelador formuló alternativas antes de que un guardarraíl retirase evidencia retrospectiva. El evaluador limitó su aceptación a controles operativos internos y el ciclo de redacción necesitó una regeneración determinista. La versión exacta del modelo no quedó persistida en el manifiesto de esa ejecución, por lo que el caso no se utiliza para comparar modelos de lenguaje.

Una captura histórica previa de la vista web separaba 12 decisiones de enrutamiento del supervisor de ocho decisiones de roles técnicos. En aquella pasada no existían procedencia estructurada ni eventos de ejecutor: la interfaz presentaba los 20 orígenes como desconocidos, rotulaba cuatro caídas como inferencias textuales y señalaba dos configuraciones fijadas por el protocolo. Ese caso permitió evitar que una finalización correcta del pipeline se usase como prueba de autonomía agéntica, pero ya no representa la instrumentación actual.

La revisión transversal del repositorio refuerza esta cautela. Se localizaron 77 ejecuciones y 1.140 decisiones persistidas; 40 recorrían los siete roles y disponían de paquete de evidencia. De estas últimas, 32 terminaron con el informe aprobado por el verificador, mientras que siete conservaron el estado `needs_revision` y una el estado `blocked`, aunque el pipeline figurase como completado. El corte de 75 ejecuciones anterior a la nueva instrumentación no conservaba eventos de runtime ni la traza estructurada de generación; las dos ejecuciones añadidas después sí registran 30 eventos y traza para sus 18 decisiones. Esta diferencia temporal impide mezclar ambos bloques para estimar la tasa actual de fallos del modelo.

La primera invocación del banco decisonal produjo 45 respaldos, pero no se considera una observación del modelo. Todas las llamadas terminaron en milisegundos con un error de permisos al abrir la conexión local y no hubo una respuesta de Qwen. El artefacto se conserva como incidencia de infraestructura, pero se excluye íntegramente de la medida de fiabilidad generativa.

Una vez restablecido el acceso a Ollama, se ejecutaron con `qwen3.5:4b` tres repeticiones de los 15 escenarios, para un total de 45 decisiones. Treinta y ocho fueron válidas al primer intento, un 84,44 %, y siete terminaron en respaldo determinista. La cobertura de la traza de generación fue del 100 %; no se observaron decisiones no agénticas, errores de ejecución ni fallos frente al oráculo semántico en las decisiones que llegaron a ser efectivas. Supervisor, limpiador, estructurador, modelador, reintento del modelador, evaluador y revisión del informe resolvieron todos sus escenarios al primer intento.

Los siete respaldos se concentraron en el verificador, con seis de seis, y el redactor, con uno de tres. Por tanto, la puerta quedó bloqueada y este resultado no autoriza aún la ablación de memoria.

El diagnóstico mostró defectos de integración concretos. El verificador sí generaba incidencias útiles, pero empleaba una variante compacta del contrato que el normalizador descartaba antes de validar. En el caso NASA, el control de afirmaciones del redactor podía confundir una limitación negada con una afirmación física positiva. Tras corregir ambos puntos, una batería focal de nueve decisiones eliminó los respaldos: el redactor resolvió dos casos al primer intento y uno mediante reparación del propio LLM; el verificador aprobó los tres informes seguros al primer intento. En los tres informes adversariales una política determinista aún tuvo que completar incidencias, por lo que se registraron como fallos semánticos y no como éxitos autónomos del agente.

La inspección de las respuestas rechazadas confirmó que Qwen había identificado la afirmación industrial no respaldada y la limitación ausente, pero había elegido identificadores libres. Estos identificadores son metadatos de trazabilidad, no parte del juicio semántico, y su normalización pasa a ser responsabilidad del servidor. Desde las repeticiones focales, cada llamada lógica conserva la respuesta estructurada recibida y las huellas del prompt y del esquema. Así puede reconstruirse qué recibió el validador sin almacenar el prompt completo ni una cadena de pensamiento privada.

La contabilidad mantiene cuatro desenlaces separados: validez al primer intento; reparación por el propio LLM de una respuesta rechazada; sustitución por el respaldo determinista; y superposición de una política que endurece o completa la decisión. Los dos últimos protegen la operación, pero no acreditan autonomía agéntica.

La repetición completa posterior a aquellas correcciones superó la puerta histórica. De las 45 decisiones, 42 fueron válidas al primer intento, un 93,33 %, y tres fueron reparadas por el propio LLM. No hubo respaldos deterministas, decisiones no agénticas, superposiciones de política, fallos semánticos ni errores. Este resultado precedía al bloque común de hipótesis y motivó repetir la medición bajo el contrato vigente.

Tras exigir ese bloque se realizaron dos iteraciones completas de diagnóstico sobre el mismo banco. La primera produjo 35 decisiones en el intento lógico 1, tres reparadas y siete respaldos; la siguiente produjo 39 en el intento lógico 1, cinco reparadas y un respaldo. Ambas quedaron bloqueadas y se utilizaron para ajustar la integración. La repetición final se ejecutó con `qwen3.5:4b`, memoria desactivada y tres vueltas. Sus 45 decisiones efectivas fueron válidas en el primer intento lógico: no hubo una segunda llamada LLM, respaldos, decisiones no agénticas, superposiciones, fallos semánticos ni errores. La cobertura de traza fue completa, las tres repeticiones terminaron correctamente y las 45 llamadas lógicas se correspondieron con 45 llamadas físicas. Los nueve puntos de entrada —incluidos el reintento del modelador y la revisión del informe— alcanzaron el 100 % dentro de esa repetición final.


El calificador *primer intento* no implica coincidencia literal del JSON bruto con todo el contrato persistente. En las seis salidas del verificador, el servidor normalizó tipos no canónicos a `report_fidelity` y completó campos de envoltura que no alteraban el veredicto ni añadían incidencias. Se considera primer intento porque una sola llamada LLM produjo la decisión efectiva tras una normalización conservadora sin cambio de juicio. El uso del mismo banco para ajustar la integración impide tratar esta repetición como holdout.

La Figura 7.1 muestra la distribución por punto de entrada. La ausencia de segmentos de reparación o respaldo permite detectar visualmente que el resultado no se

concentra en un único rol.

Fiabilidad por punto de decisión agéntico

Banco cerrado decision-only · 45 observaciones · 9 entrypoints



Alcance: banco cerrado decision-only; compara únicamente estas decisiones y esta configuración.
No es una tasa universal ni confirma o refuta las hipótesis científicas de los agentes.

Figura 7.1: Fiabilidad por punto de entrada con el contrato común de hipótesis. Las 45 observaciones de la repetición final fueron válidas en el primer intento lógico tras normalización conservadora. La figura no representa una tasa universal ni una valoración de la corrección científica de las hipótesis.

La visualización de fiabilidad se organiza por entrada generativa y separa mediante categorías visibles las respuestas al primer intento, las reparaciones del LLM y los desenlaces no agénticos. El resumen agregado se complementa con un inspector de la decisión que muestra la hipótesis cuando estaba disponible, las alternativas, las evidencias y la diferencia entre propuesta y configuración efectiva, como ejemplifica la vista histórica de la Figura 7.2. Esta representación evita que un porcentaje global oculte un problema concentrado en un rol; el objeto estructurado persistido sigue siendo la fuente canónica.

La versión actual de la interfaz usa una representación común para los siete roles. En las vistas bidimensional y tridimensional muestra enunciado, observación esperada, criterio de refutación, ámbito, corte de evidencia, riesgos y estado de contraste. La ejecución completa descrita a continuación permite comprobar esta representación con decisiones generativas reales. No existen todavía valoraciones independientes que clasifiquen las hipótesis como apoyadas o refutadas; por ello, la interfaz las mantiene como pendientes de contraste.

El resultado es una puerta de ingeniería sobre 15 escenarios repetidos tres veces. No constituye una prueba estadística de una tasa general del 99 % ni demuestra robustez

ante distribuciones, datasets o perturbaciones no incluidos. Sí demuestra que, bajo el banco definido, todas las decisiones efectivas permanecieron en el flujo LLM y permite avanzar a una ejecución completa sin memoria.

Tras superar la puerta vigente se ejecutó en segundo plano una pasada completa sobre CWRU, con memoria desactivada, para comprobar la instrumentación dentro del grafo real. Se persistieron 30 eventos: 18 decisiones —12 del supervisor y seis de los roles técnicos—, siete resultados de ejecutor y los eventos de estado restantes. Las 18 decisiones conservaron origen `llm`, estado `validated` e intento lógico 1, sin segunda llamada LLM registrada, respaldo ni superposición. Participaron los siete roles y todas sus decisiones conservaron la hipótesis común efectiva completa. El artefacto de esta run no incluye el nombre exacto del modelo ni una traza de llamadas físicas; por ello no se usa para atribuir reproduciblemente las respuestas a una versión concreta de Qwen ni para descartar una reparación JSON interna no expuesta por el runtime.

Los ejecutores de limpieza, estructuración, modelado y redacción quedaron enlazados a la decisión que los originó; no se inventó ese vínculo para las otras tres operaciones deterministas. El modelador eligió Isolation Forest y conservó tres alternativas. Los tres eventos de consulta de memoria no recuperaron identificadores de recuerdos y ninguna decisión declaró haberlos usado, como corresponde a una ejecución con memoria desactivada. El verificador aprobó el informe y el supervisor respetó ese veredicto antes del cierre.

La separación entre agentes y ejecutores se mantuvo en todos los casos verificados. Los agentes no transforman directamente las señales ni generan código arbitrario para ejecutarlo. Por tanto, la variación atribuible al modelo se localiza en la propuesta y la interpretación, mientras que la operación numérica permanece reproducible.

Los nombres de herramientas que aparecen en una decisión son, por ahora, herramientas declaradas o propuestas. No demuestran una consulta: el uso solo puede afirmarse cuando existe una observación estructurada de herramienta, y la batería descrita no produjo tales observaciones. De forma análoga, la captura exacta de eventos se obtiene en los trabajos en segundo plano; las ejecuciones síncronas y las históricas se muestran mediante una reconstrucción parcial que la interfaz identifica como tal.

7.3.2. Estado de H1

H1 queda **apoyada provisionalmente como resultado de fiabilidad de ingeniería**. Se ha demostrado que las entradas generativas evaluadas pueden producir decisiones válidas y trazables sin sustitución determinista, y que el sistema distingue primer intento, reparación, propuesta y ejecución bajo el contrato común. La ejecución completa CWRU y la revisión causal P3 confirman además que los siete roles pueden persistir y exponer ese bloque dentro del grafo real. El gate repetido añadió 84 decisiones por batería y conservó tanto los resultados favorables como los bloqueos: V2 detectó tres sobrealcances y V3 dos fallbacks por referencias ajenas a la vista causal. El resultado no evalúa si las hipótesis son correctas, suficientes o útiles en una muestra amplia. Faltan trayectorias y contextos independientes, escenarios holdout, perturbaciones y una rúbrica externa. Por ello, H1 no se considera confirmada de forma general.




Figura 7.2: Captura directa de la auditoría de una ejecución completa CWRU bajo el contrato común. La vista separa las 18 decisiones registradas en el intento lógico 1 de segundas llamadas, respaldos y superposiciones, y presenta para los siete roles su hipótesis, decisión observable, procedencia y enlace causal al ejecutor cuando existe. También mantiene visibles los límites de la evidencia y que las hipótesis continúan pendientes de contraste independiente.

7.4. H2: relevancia y fidelidad del ciclo de memoria RAG

7.4.1. Resultado de verificación

El ciclo de memoria distingue evidencia canónica e índice de recuperación. Los episodios y candidatos conservan la decisión y su resultado; el índice puede reconstruirse a partir de ellos. Esta separación permite excluir, restaurar o eliminar un recuerdo sin convertir el estado accidental del índice en fuente de verdad.

Los candidatos nacen pendientes y no reutilizables. La captura automática de una experiencia no implica su promoción automática a conocimiento. Las decisiones de gobierno quedan en un registro persistente y prevalecen al reconstruir el índice. En particular, un recuerdo excluido no reaparece por una reindexación posterior, y las operaciones de promoción o exclusión conservan el motivo y la identidad del revisor.

La Figura 7.3 muestra el estado del corpus canónico usado en esta verificación. De los 23 registros indexados, uno había sido revisado y era reutilizable como contexto, 13 permanecían como candidatos en cuarentena y nueve correspondían a auditorías de uso deliberadamente no recuperables. Las categorías son disjuntas y cubren el corpus completo. Este resultado acredita la aplicación del gobierno y, en particular, que capturar una experiencia no basta para inyectarla de nuevo en un agente. No mide todavía la relevancia del ranking ni el efecto causal de la memoria; esas dos cuestiones requieren las pruebas declaradas para H2 y H3.



Figura 7.3: Captura directa del diagnóstico de preparación del corpus RAG. El backend configurado puede estar operativo y, simultáneamente, el benchmark permanecer bloqueado por falta de recuerdos oficiales, cobertura entre datasets y agentes, revisión de candidatos y manifiesto congelado.

El diagnóstico separa dos preguntas que antes aparecían mezcladas. La búsqueda JSON exacta responde correctamente con el embedding configurado, pero la preparación científica es negativa: no hay recuerdos reutilizables con procedencia oficial, la cobertura se limita a un dataset y un agente, quedan 13 candidatos pendientes y toda-

vía no existe un manifiesto congelado. La huella SHA-256 del corpus permite detectar cambios de inventario o gobierno entre lecturas, aunque no sustituye ese manifiesto. Estos resultados no comparan Qdrant con pgvector; cambiar de motor no resolvería ninguno de los bloqueos semánticos observados.

La recuperación se ha verificado como una secuencia de tres contextos diferentes:

Recuperación bruta. Conjunto de candidatos devuelto antes del control local de calidad.

Resultado del control. Candidatos aceptados o retirados, junto con las razones deterministas de cada exclusión.

Contexto efectivo. Único conjunto que recibe el agente y del que puede declarar citas válidas.

El control considera rol destinatario, dataset, procedencia, perfil experimental, reutilización, veredicto y marcas de gobierno. La recuperación solicita un conjunto inicial mayor que el contexto final; así, los primeros resultados incompatibles no consumen todo el presupuesto ni ocultan un recuerdo válido situado después en el ranking. La misma compatibilidad se vuelve a comprobar antes de la inyección, aunque el backend ya haya aplicado filtros.

La procedencia forma parte del contrato de memoria. Un episodio sintético no se utiliza como evidencia directa de una trayectoria NASA oficial. Los recuerdos de procedencia desconocida solo pueden tratarse con cautela o como conocimiento general cuando el contexto y el perfil de supervisión lo permiten. La auditoría del piloto mostró que la procedencia desconocida no basta como única cautela: si las métricas de un recuerdo revelan clasificación binaria y la consulta oficial no tiene etiquetas por snapshot, el recuerdo se considera incompatible y se excluye. Esta política reduce el riesgo de contaminación cruzada entre fuentes que comparten forma, pero no validez empírica.

En los dos pares PCA e Isolation Forest, la recuperación activada devolvió al modelador ese mismo caso frontera con similitud 0,558. Estructurador y evaluador recibieron contextos efectivos vacíos. Ningún rol citó ni declaró uso de memoria y el benchmark clasificó ambas ejecuciones como *retrieval only*. La reevaluación con la regla reforzada asignó al recuerdo una exclusión por conflicto de perfil. El resultado demuestra que el ciclo distingue recuperación, filtrado y uso; no mide todavía $\text{precision}@k$ o $\text{recall}@k$ sobre un conjunto de relevancia independiente.

También se comprueba la compatibilidad entre el índice y el modelo de embeddings. Una diferencia de identificador, versión o dimensión interrumpe la consulta en lugar de mezclar vectores no comparables. El almacenamiento local permite reproducir una búsqueda densa exacta. La integración Qdrant y sus filtros no formó parte de esta batería, ni se implementó una condición pgvector. Por tanto, el capítulo no atribuye los resultados a esos motores ni afirma superioridad científica de uno frente al otro.

7.4.2. Estado de H2

H2 está **no contrastada todavía**. Se ha validado que el control elimina casos incompatibles conocidos, conserva sus motivos y evita que una exclusión sea revertida accidentalmente. Falta construir un conjunto de consultas con juicios de relevancia

independientes y comparar, sobre el mismo corpus, recuperación sin control frente a recuperación filtrada. Sin hit@k, precision@k, recall@k, MRR y auditoría ciega de citas no puede afirmarse que el control aumente la relevancia media ni la fidelidad de forma general.

7.5. H3: influencia observable y utilidad de la memoria

7.5.1. Resultado de verificación

La observabilidad implementada permite comprobar si la memoria estuvo disponible y qué relación declaró el agente con cada recuerdo. Una decisión puede indicar que siguió, adaptó, contradijo, rechazó o ignoró el contexto. La traza conserva por separado la influencia declarada sobre la propuesta y la influencia sobre la configuración ejecutada.

Esta distinción ha resultado necesaria en los pilotos. Se observaron casos en los que la explicación del agente cambió al recibir un recuerdo, pero la configuración efectiva permaneció fijada por el protocolo. También aparecieron casos en los que un recuerdo de advertencia fue citado sin evitar una decisión posteriormente rechazada. Por ello, citar memoria no se considera sinónimo de haber aprendido de ella, y modificar una propuesta no se considera mejora hasta examinar el resultado.

El sistema puede generar un episodio posterior que relacione la hipótesis con la evidencia observada. Ese episodio vuelve a entrar como candidato pendiente, no como recuerdo aprobado. El diseño evita así que una única decisión se refuerce a sí misma durante la misma familia experimental.

Los pilotos NASA IMS-like sintéticos proporcionan ejemplos cualitativos de revisión, sobrecorrección y rechazo. CWRU permite comprobar que la memoria puede atravesar distintos roles sin romper el flujo. Ninguna de estas observaciones permite atribuir una mejora causal a la memoria: no proceden todavía de una ablación pareada con corpus, prompt, modelo, semillas y presupuesto de contexto congelados.

La pasada oficial añade un primer control pareado, pero su resultado es nulo en el sentido más estricto: hubo recuperación, no influencia. En PCA e Isolation Forest se recuperó un recuerdo, se citaron cero, se usaron cero y no cambió ninguna configuración ni métrica respecto al brazo sin memoria. Puesto que el único candidato era incompatible, esta igualdad no estima el efecto de una memoria pertinente. Sí evita una conclusión engañosa: activar el recuperador no equivale a ejecutar una condición RAG efectiva.

7.5.2. Estado de H3

H3 está **no contrastada todavía**. Existe el mecanismo para medir el cambio y se ha ejecutado un piloto pareado, pero sus brazos con recuperación no contuvieron memoria pertinente ni declararon uso. No se dispone de réplicas controladas suficientes para separar el efecto de una memoria efectiva de la variabilidad del modelo. Tampoco puede establecerse una tasa de ayuda o perjuicio. La conclusión actual se limita a que la influencia es observable y auditable cuando ocurre, y a que su ausencia también se registra sin convertir *retrieval* en uso.

7.6. H4: evaluación temporal a nivel de snapshot

7.6.1. Agregación jerárquica verificada

La agregación por snapshot ya está integrada en la evaluación temporal. Las ventanas que comparten una misma captura se agrupan antes de calcular rachas, primera alerta y persistencia. Para cada snapshot se conservan la mediana del score, un percentil superior, la media, la dispersión, el número de ventanas y la proporción de ventanas en alerta. Esta combinación mantiene información sobre picos internos sin multiplicar artificialmente las observaciones temporales.

La alerta del snapshot se deriva de una fracción explícita de ventanas en alerta. Después, y solo después, la política de persistencia opera sobre la secuencia cronológica de snapshots. La unidad utilizada en las métricas longitudinales queda registrada junto a la política de agregación.

El caso crítico de pseudorreplicación se ha verificado de forma específica. Se construyó una entrada con tres ventanas en alerta procedentes de una única captura. La evaluación produjo un solo snapshot, una racha temporal de longitud uno y ningún aviso persistente bajo una política que exige tres observaciones temporales consecutivas. Por tanto, tres ventanas solapadas de una adquisición no se convierten en tres instantes de degradación.

También se comprobó que un valor extremo aislado no domina necesariamente el score agregado: la mediana conserva el nivel central, mientras el percentil superior y la dispersión permiten mantener visible el pico. La decisión binaria del snapshot utiliza la proporción de alertas y no la mera existencia de una ventana positiva.

7.6.2. Baseline causal sobre NASA IMS Set 2 oficial

La ejecución de referencia utiliza el primer canal de Bearing 1, ventanas de 2.048 muestras con un 50 % de solapamiento y PCA por error de reconstrucción. Cada una de las 984 adquisiciones produce 19 ventanas, hasta un total de 18.696. La política causal asigna 197 snapshots al baseline, 98 a calibración y 689 a monitorización. El umbral 0,2186 corresponde al cuantil 0,99 de las 1.862 ventanas de calibración; ninguna observación de monitorización interviene en su ajuste.

La auditoría temporal encontró 983 intervalos consecutivos de 600 segundos, todos compatibles con la cadencia esperada y sin gaps. Tras agregar por snapshot, ninguno de los 295 snapshots de baseline y calibración alcanza la fracción de alerta de 0,5. Este valor es una tasa descriptiva previa a la monitorización, no una estimación independiente de falsos positivos: la propia calibración participa en la elección del umbral.

En monitorización, 331 de los 689 snapshots quedan en alerta y forman cinco episodios. La primera racha persistente comienza el 16 de febrero de 2004 a las 22:22:39, en el 65,8 % de la trayectoria, y se sitúa retrospectivamente a unas 56 horas del final registrado. El episodio terminal más largo contiene 193 snapshots. Estos son eventos producidos por la política algorítmica; no equivalen a un onset físico anotado ni demuestran que el método haya diagnosticado el fallo documentado.

La Figura 7.4 representa esta evidencia sin convertir las ventanas en observaciones longitudinales. El panel superior usa $\log_{10}(\text{score}/\text{umbral})$ para hacer legible un score que abarca varios órdenes de magnitud; el panel inferior combina el indicador de salud y la fracción de ventanas alertadas. Los fondos delimitan particiones fijadas antes del modelado.



Figura 7.4: Captura directa de la ejecución causal PCA sobre NASA IMS Set 2. El eje superior representa $\log_{10}(\text{score}/\text{umbral})$ para conservar visibles las fases iniciales ante los valores extremos terminales; el panel inferior muestra el indicador de salud y los episodios agregados por snapshot. La primera alerta persistente no es un onset físico confirmado.

El score normalizado presenta una correlación de Spearman de 0,794 con el avance de la trayectoria. El indicador de salud suavizado pasa de 93,02 a 1,90, con caída de 91,11, monotonidad 0,529 y robustez 0,982. La combinación muestra una separación final intensa, aunque no una degradación estrictamente monótona. Al no existir etiquetas de estado para calibración y monitorización, no se publican precisión, recall, F1, ROC-AUC ni PR-AUC.

7.6.3. Paridad entre cálculo batch y replay incremental

El replay volvió a puntuar las 18.696 ventanas con el escalador y el PCA congelados, sin leer las predicciones ni la trayectoria de resultados. Al comparar después ambos recorridos no apareció ninguna discrepancia en la decisión binaria por ventana. La diferencia absoluta máxima de score fue menor que 10^{-10} , compatible con redondeo numérico.

Tras agregar las ventanas, los 984 snapshots coincidieron en identificador, alerta, segmento temporal, detección de gaps y estado de salud. La diferencia máxima tanto del score agregado como del indicador suavizado permaneció por debajo de 10^{-10} . El bloque de monitorización conservó 689 ticks y el bootstrap previo 295. Esto acredita que el nuevo servicio reproduce el cálculo causal de referencia mediante pasos incrementales; no añade evidencia sobre la corrección física del detector ni sobre su rendimiento en tiempo real.

Las pruebas de contrato observaron además cuatro frames por tick. El primer canal presentó el diagnóstico PCA y los restantes conservaron únicamente telemetría. Un cambio deliberado en un snapshot futuro no modificó el primer tick de monitorización, y la recuperación tras simular una interrupción entre commit y checkpoint mantuvo un solo avance. Estas comprobaciones respaldan la frontera técnica necesaria antes de conectar la activación multiagente, pero no constituyen todavía una comparación entre políticas P2 y P3.

7.6.4. Activación determinista P3 sobre el replay NASA

El recorrido P3 completó los 689 ticks y volvió a cargarse desde un proceso nuevo con el mismo estado final. El ledger contiene 14 eventos: once candidatos de transición a crítico, dos confirmaciones persistentes y un cierre de sesión. De las transiciones, dos se emitieron y nueve se suprimieron por cooldown; una confirmación persistente se emitió y la otra quedó enlazada como episodio ya cubierto por una transición crítica. El cierre se emitió fuera del presupuesto. No hubo gaps en este bloque de monitorización.

En conjunto se emitieron cuatro eventos, pero solo tres reservaron una revisión variable. La utilización fue, por tanto, $3/7$. Los dos episodios que alcanzaron $K = 3$ quedaron cubiertos: uno por revisión persistente y otro por la escalada crítica previa. Frente al baseline contrafactual P1 de una solicitud potencial por cada uno de los 331 snapshots alertados, P3 redujo la demanda a tres solicitudes variables, un 99,1 % en esta trayectoria. La comparación mide carga algorítmica, no ahorro industrial ni calidad de razonamiento.

La proyección semántica ordenada del ledger, excluyendo identidades derivadas del nombre de sesión, produjo una huella cuya forma abreviada es `84fe3c6b...f8d2b0c1`; el manifiesto de ejecución conserva el valor SHA-256 completo. El gate focal de contratos, motor, store y API completó 67 pruebas, y la interfaz aislada completó 18

escenarios E2E en escritorio y móvil. La regresión Python completa alcanzó 625 pruebas correctas, dos omitidas y 13 subpruebas correctas. Estos recuentos son controles de regresión, no muestras científicas independientes.

El resultado cierra la generación causal y auditable de solicitudes. En este corte determinista ningún evento lanzó Qwen, consultó RAG o produjo una decisión; el puente posterior se evaluó por separado para no atribuir al motor de triggers el comportamiento de los agentes.

7.6.5. Revisión causal multiagente de un trigger P3

Se despachó manualmente el trigger de transición de *warning* a *critical* emitido en el corte del 16 de febrero de 2004 a las 22:32:39, correspondiente al cursor 353. La vista entregada a los agentes quedó limitada a la evidencia disponible hasta ese snapshot. Los siete roles operaron en modo exclusivamente propositivo, con memoria desactivada y sin ejecutar ni aplicar sus recomendaciones. La sesión y la ejecución hija quedan identificadas en el registro técnico del cierre para permitir su auditoría sin trasladar al cuerpo de la memoria una relación extensa de identificadores internos.

La ejecución aceptada completó los siete roles. Las siete decisiones registraron origen `llm`, estado `validated` e intento lógico 1; no hubo reparaciones ni respaldos deterministas. La revisión terminó con memoria `off` y aplicación de política `not_applied`. Por tanto, el resultado demuestra que el puente causal trigger-run puede conservar un flujo íntegramente generativo bajo este expediente, no que las recomendaciones sean correctas ni que mejoren el detector.

Una ejecución técnica anterior sobre el mismo corte se conserva únicamente como diagnóstico rechazado. Cinco roles validaron una respuesta del LLM, pero dos llamadas agotaron el tiempo y fueron sustituidas por el respaldo seguro. Aunque la ejecución terminó contractualmente, esos dos fallos impiden contabilizarla como éxito agéntico. El diagnóstico motivó un timeout específico para la revisión de monitorización y evita presentar como razonamiento del modelo una continuidad obtenida por el colchón determinista.

El gate relevante de software completó 140 pruebas backend y tres subpruebas, con una advertencia de una dependencia externa. La suite de navegador, ratificada localmente tras el typecheck y el build, completó 22 de 22 casos en escritorio y móvil. Estos recuentos verifican contratos e integración; no son muestras experimentales independientes.

Se trata de una única revisión retrospectiva sobre un trigger y una trayectoria ya inspeccionada. La memoria estuvo desactivada, no se aplicó ninguna política y las hipótesis no recibieron una valoración independiente. El resultado respalda integración y trazabilidad de H1, pero no contrasta H2 o H3 ni permite estimar una tasa general de fiabilidad.

7.6.6. Gate repetido de fiabilidad sobre los triggers P3

La revisión nominal se amplió a los cuatro contextos primarios de P3 y tres sesiones completas, con siete roles por contexto. La Tabla 7.1 compara las dos baterías completas publicadas. Ambas usaron Qwen 3.5:4b con memoria desactivada, recomendaciones no aplicadas y las mismas 84 unidades de observación. El dictamen exigía cero fallback y origen LLM del 100%; por ello no se transforma la tasa de V3 en un porcentaje

general de fiabilidad.

Tabla 7.1: Resultados de las baterías completas del gate repetido P3.

Métrica	V2	V3
Runs hijas resueltas	12/12	11/12
Decisiones válidas al primer intento	84/84	82/84
Decisiones de origen LLM	84/84	82/84
Fallbacks de guardarraíl	0	2
Llamadas físicas	84	86
Claims dentro de alcance	81/84	84/84
Hipótesis, grounding y binding	84/84	84/84
Dictamen	bloqueado	bloqueado

V2 resolvió las 12 hijas y aceptó las 84 respuestas al primer intento, pero el control agregado detectó tres claims prohibidos. En la repetición 1 del contexto de persistencia 496–498, el campo `hypothesis.expected_observation` del supervisor afirmó un `detected_physical_failure`. En la repetición 2 de la transición 499, el mismo campo del limpiador incurrió en ese claim y `hypothesis.statement` del modelador afirmó `lead_time_to_failure`. Por tanto, 81/84 decisiones, un 96,4286 %, cumplieron el alcance exigido del 100 %. El caso muestra que validez de esquema y primera respuesta no implican prudencia semántica.

La corrección aplicó el clasificador canónico a los nueve campos libres dentro del runtime y V3 se prerregistró con el plan nuevo `nasa-p3-monitoring-review-qwen35-v3`; no se recalcularon solo los tres casos fallidos. V3 obtuvo 84/84 en claims acotados y en las coberturas contractuales, pero la hija de la repetición 1 en la transición del cursor 353 terminó en fallo. Supervisor y limpiador citaron dos veces referencias fuera de la vista causal. Cada rol consumió una llamada inicial y otra de corrección antes de que el guardarraíl generase un respaldo seguro. Los otros cinco roles de la hija validaron al primer intento. El total fue 86 llamadas físicas, 82/84 primeras respuestas aceptadas, dos fallbacks y 11/12 hijas resueltas.

El grounding agregado de V3 permanece en 84/84 porque contabiliza las decisiones efectivas de respaldo, cuyas referencias sí son válidas; las dos respuestas LLM inseguras fueron rechazadas. Esta distinción evita describir las salidas persistidas como no fundamentadas y, a la vez, impide ocultar que la generación falló. V2 reveló fragilidad de alcance semántico y V3 fragilidad en la generación de referencias. El gate funcionó como instrumento de falsación en ambos casos y no autoriza RAG, adaptación de políticas ni una V4 selectiva.

El refuerzo posterior del binding se verificó únicamente mediante pruebas focales con clientes simulados: 36 casos correctos y una advertencia externa de LangGraph. No se consultó Qwen, no se reprodujo NASA y no se publicó otra batería. Por tanto, estos controles prueban que el alias singleton se resuelve a la referencia canónica, que los registros entregados coinciden con el artefacto sellado y que entradas hostiles activan reparación o respaldo; no modifican el dictamen V3 ni acreditan una mejora del comportamiento generativo.

Después se implementó el catálogo causal por registro. Las comprobaciones focales ejercitaron su proyección determinista E01. .EN, el rechazo de catálogos o handles alterados, la selección parcial sin autocompletar el resto, la resolución a referencias canónicas, la traza, la persistencia y el cálculo del grounding contractual sobre las filas

disponibles. No se ejecutó Qwen, no se repitió el replay completo y no se publicó un gate nuevo. En consecuencia, este resultado acredita únicamente el cableado y las invariantes de software; no permite comparar tasas con V2/V3 ni afirmar una mejora agentiva. La tabla, la figura y el puntero publicado continúan describiendo exclusivamente V3, cuyo dictamen permanece bloqueado.

Como incremento de ingeniería ulterior, las siete recomendaciones pueden proyectarse ahora en una `MonitoringPolicyProposal` creada por el servidor, con `proposal_origin=deterministic_server` dentro del propio artefacto. Las comprobaciones focales verificaron las siete contribuciones, el mapeo semántico cerrado, la conservación de handles, la unanimidad estricta, el desacuerdo y `invalid_review` ante fallback. El constructor exige exactamente siete decisiones: un rol fallido o no ejecutado sin decisión no produce una propuesta. El estado fue siempre `advisory_not_applied` y `application_status=not_applied`. No se consultó Qwen ni se repitió el replay: el resultado demuestra que el instrumento puede representar y auditar recomendaciones ya estructuradas, no que el modelo haya usado el nuevo contrato ni que esas recomendaciones sean correctas, ejecutables o beneficiosas. Por tanto, no modifica el estado de H1 o H4.

La Figura 7.5 se generó desde el puntero publicado y su resultado verificado. Resume el bloqueo sin convertirlo en un score compuesto: muestra resultados por rol, la matriz contexto-repetición y las coberturas contractuales. Estas coberturas miden cumplimiento del contrato, no verdad física de las hipótesis.




Figura 7.5: Gate repetido V3 de revisión multiagente sobre los cuatro contextos P3 y tres sesiones. Las barras, la matriz y las coberturas representan resultados contractuales publicados; no constituyen una medida de veracidad física ni de rendimiento industrial.

7.6.7. Estado de H4

H4 queda **parcialmente respaldada por el mecanismo y por un estudio de caso real**. Se ha demostrado que la persistencia se calcula sobre snapshots y que el protocolo causal produce una trayectoria auditable sin utilizar el tramo de monitorización para calibrar. La hipótesis comparativa no está cerrada: falta contrastar agregación por snapshot frente al tratamiento incorrecto por ventana bajo condiciones pareadas y validar la política con referencias físicas independientes. No se infiere rendimiento PHM general a partir de una única trayectoria.

7.7. Resultados secundarios por fuente de datos

7.7.1. Pilotos NASA IMS-like sintéticos

Las señales sintéticas con estructura semejante a NASA IMS han permitido recorrer el flujo completo en condiciones conocidas por construcción. Sobre ellas se ha observado que los agentes pueden formular una propuesta, recibir una evaluación, revisar una alternativa y dejar un episodio reutilizable. Los guardarraíles también han identificado sobrecorrecciones y explicaciones que no coincidían con el resultado numérico.

El valor de estos pilotos es metodológico. Sirven para provocar desenlaces difíciles de controlar con datos reales y verificar que la auditoría los distingue. Sus etiquetas proceden del generador o de una política temporal proxy; no son anotaciones de NASA. Por ello no se trasladan sus métricas al caso industrial ni se emplean para afirmar detección temprana sobre rodamientos reales.

7.7.2. CWRU como referencia secundaria

CWRU ha permitido comprobar la compatibilidad del pipeline con un benchmark etiquetado y contrastar que distintas propuestas de ventana o familia de modelo pueden materializarse bajo ejecutores comunes [3, 4, 2]. La clasificación binaria resultante se conserva como prueba de regresión del sistema.

Sin embargo, CWRU no representa una trayectoria completa de degradación hasta fallo. Sus ventanas no deben reinterpretarse como snapshots sucesivos de un mismo activo. En consecuencia, los resultados históricos de clasificación no validan persistencia, onset, lead time ni generalización industrial. Tampoco permiten concluir que la memoria mejore un problema que ya resulta separable bajo el procesamiento utilizado.

7.8. Síntesis de las hipótesis

La síntesis separa capacidad técnica de contraste experimental para evitar que la madurez de la aplicación se confunda con evidencia científica suficiente:

H1 — **apoyada provisionalmente en ingeniería.**

El gate decisional mantuvo las 45 decisiones efectivas en el LLM y todas validaron en el primer intento lógico bajo el contrato común, tras normalización sin cambio de juicio. Una ejecución CWRU posterior conservó 18 decisiones LLM de los siete roles en intento lógico 1. Una revisión causal P3 posterior añadió siete decisiones LLM validadas al primer intento. Dos baterías de 84 decisiones ampliaron esa

observación: V2 quedó bloqueada por tres claims fuera de alcance y V3 por dos fallbacks de referencia. Faltan trayectorias y contextos independientes, escenarios holdout y una rúbrica externa para valorar la calidad técnica de las hipótesis.

H2 — no contrastada todavía.

El filtrado, la procedencia y el gobierno son funcionales, y el piloto reveló un conflicto de perfil. Faltan juicios independientes de relevancia y una ablación del control de calidad.

H3 — no contrastada todavía.

La influencia declarada y la acción efectiva son observables; los dos pares disponibles fueron *retrieval only*, sin citas ni cambios. Faltan réplicas con un corpus pertinente en condiciones con y sin memoria.

H4 — parcialmente respaldada.

Se ha verificado la agregación por snapshot, el control causal y un baseline oficial sobre 984 snapshots. Falta la comparación pareada de unidades y la validación externa sobre más trayectorias.

7.9. Resultados que no pueden afirmarse

La evidencia disponible no permite sostener las siguientes conclusiones:

- que el baseline descriptivo sobre NASA IMS Set 2 equivalga a rendimiento supervisado, detección validada o generalización;
- que haya detectado de forma temprana el fallo del rodamiento o estimado su vida útil remanente;
- que la memoria RAG mejore por término medio las decisiones o las métricas del detector;
- que el filtrado actual sea superior a una recuperación sin control en métricas de relevancia;
- que Qdrant sea superior a pgvector u otro backend vectorial;
- que Qwen 3.5 sea superior o inferior a Qwen 3, puesto que Qwen 3 no se ha probado todavía bajo el protocolo común;
- que la síntesis consultiva constituya consenso cuando los roles discrepan, o que sus categorías equivalgan a parámetros elegidos por los agentes;
- que una recomendación haya sido validada, revisada por una persona, aprobada o aplicada, o que haya mejorado el detector;
- que CWRU o los pilotos sintéticos representen el comportamiento de una planta industrial;
- que una única trayectoria permita generalizar entre activos, rodamientos o regímenes de operación.

Estas exclusiones no anulan los resultados de ingeniería. Delimitan su alcance y determinan qué experimentos son necesarios antes de formular conclusiones sobre el comportamiento de los agentes y su memoria.

7.10. Amenazas observadas en la evidencia actual

La principal amenaza es la **dependencia entre observaciones**. Las ventanas de una misma captura comparten señal y no pueden tratarse como réplicas temporales. La agregación implementada corrige el denominador longitudinal, pero una única trayectoria sigue sin proporcionar independencia entre activos.

La segunda amenaza es la **procedencia de las etiquetas**. Una división temporal proxy puede ser útil para depurar el sistema, pero no identifica por sí misma el onset físico del fallo. Presentar métricas binarias sin declarar esta procedencia produciría una interpretación excesiva.

La tercera amenaza es la **fuga temporal**. El tiempo restante hasta el final, la vida relativa calculada retrospectivamente y los recuerdos derivados del tramo evaluado no deben estar disponibles para el agente en la vista ciega. En la ejecución oficial se verificó que limpiador, estructurador y modelador no reciben esas claves y que el umbral se obtiene solo de calibración. Aún debe evitarse contaminación entre condiciones cuando se ejecuten las ablaciones de memoria.

La cuarta amenaza es la **contaminación de memoria**. Un recuerdo puede compartir origen con la consulta, proceder de datos sintéticos o haber sido promovido con evidencia insuficiente. La procedencia, el corpus congelado y el registro de gobierno reducen este riesgo, pero su efectividad comparativa aún debe medirse.

Por último, la **variabilidad del modelo de lenguaje** impide interpretar una respuesta aislada como comportamiento estable. Los casos cualitativos demuestran que el sistema puede observar una conducta, no su frecuencia ni su reproducibilidad general. Las tres repeticiones sobre cuatro cortes fijos ya documentan variación generativa, pero comparten trayectoria y contextos; se requieren trayectorias independientes, un holdout, réplicas pareadas y una configuración de inferencia documentada.

7.11. Alcance de los resultados

La conclusión defendible es que existe un instrumento multiagente trazable, con memoria gobernada, separación causal y un baseline real evaluado por snapshot. La contribución demostrada es la capacidad de observar y auditar el ciclo decisión → memoria → acción y de materializarlo sobre una trayectoria oficial. El gate repetido añade evidencia negativa reproducible sobre alcance semántico y grounding: ninguna de sus dos baterías superó la puerta. El efecto cuantitativo de la memoria y la calidad media de las hipótesis permanecen abiertos a contraste; las condiciones necesarias se recogen una única vez en el trabajo futuro del capítulo de conclusiones.

Capítulo 8

Conclusiones

8.1. Síntesis del trabajo

Este trabajo ha construido un sistema multiagente para estudiar el análisis de degradación de maquinaria rotativa desde una perspectiva distinta a la de un detector convencional. El objeto principal de observación no es únicamente la predicción final, sino el proceso mediante el cual los agentes formulan hipótesis, seleccionan alternativas, utilizan evidencia previa, revisan sus decisiones y reconocen sus limitaciones. La metodología *run-to-failure* proporciona el contexto temporal en el que estas conductas adquieren sentido: una alerta aislada no equivale a degradación persistente y una explicación plausible no equivale a un diagnóstico respaldado.

La arquitectura desarrollada separa las decisiones generativas de las operaciones numéricas. Los agentes producen propuestas estructuradas y los ejecutores deterministas aplican transformaciones, entrenan modelos y calculan métricas. De este modo, el sistema puede atribuir al agente una hipótesis o una elección sin atribuirle cálculos que realmente proceden de componentes reproducibles. La traza conserva además la diferencia entre lo propuesto y lo ejecutado, incluidas las correcciones introducidas por restricciones experimentales, guardarraíles o mecanismos de respaldo.

NASA IMS Set 2 constituye el escenario empírico principal del estudio. El subconjunto seleccionado se ha extraído y su procedencia oficial se ha verificado. Un baseline PCA ha procesado sus 984 snapshots bajo una partición causal 20/10/70, calibración separada, vista online ciega y evaluación agregada por adquisición. Los pilotos NASA IMS-like y CWRU siguen cumpliendo funciones de integración y regresión. El resultado oficial caracteriza una trayectoria real, pero no aporta ground truth continuo ni permite afirmar detección temprana validada en planta.

Sobre esa misma trayectoria se ha cerrado además un replay incremental y una política P3 de activación dirigida por eventos. Sin modificar el detector, P3 redujo 331 solicitudes potenciales por snapshot alertado a tres revisiones variables, cubrió los dos episodios persistentes observados y consumió 3/7 del presupuesto fijado. Este resultado acredita el motor de scheduling y su ledger causal en el caso retrospectivo. En ese corte determinista Qwen y RAG permanecieron desactivados. Posteriormente se ejecutó el puente con Qwen 3.5 y memoria desactivada sobre 12 revisiones y 84 decisiones por batería. V2 quedó bloqueada por tres claims fuera de alcance; tras corregir el runtime y repetir todo el protocolo, V3 quedó bloqueada por dos fallbacks causados por referencias ajenas a la vista causal. Ninguna recomendación se aplicó a la política.

Dos refuerzos posteriores, comprobados solo mediante pruebas focales, cerraron el

catálogo causal por registro y la síntesis consultiva multirol. Esta última reúne siete contribuciones bajo el origen autocontenido `proposal_origin=deterministic_server`, mantiene visibles desacuerdo y orígenes no LLM y declara siempre que no hubo aplicación. Una revisión sin las siete decisiones no produce este objeto. En estos refuerzos no se ejecutó Qwen, no se repitió NASA y no se publicó un gate nuevo, por lo que no aportan evidencia empírica de mejora agentiva.

Por tanto, la conclusión global debe formularse en dos niveles. Como resultado de ingeniería, existe un instrumento experimental funcional, reproducible y auditable, aplicado ya de extremo a extremo al caso oficial. Como resultado empírico, existe un estudio descriptivo causal de Set 2. Todavía no hay evidencia suficiente para cuantificar la calidad media de las decisiones de los agentes, el beneficio de la memoria RAG ni la generalización temporal. Esta separación delimita qué se ha demostrado y qué queda por contrastar.

El resultado repetido es deliberadamente negativo y aporta información útil. V2 mostró que una respuesta válida al primer intento puede exceder el alcance semántico; V3 eliminó esos sobrealcances, pero expuso inestabilidad al seleccionar referencias. El gate publicó ambos bloqueos y no convierte el 97,6190 % de origen LLM de V3 en una tasa general de fiabilidad. Tampoco autoriza una ablación RAG, una adaptación de políticas o una repetición selectiva del caso adverso.

La auditoría base obliga además a distinguir éxito operativo y éxito agéntico. El primero puede alcanzarse gracias a contratos, ejecutores y mecanismos de respaldo aunque una salida generativa sea inválida. El segundo requiere conocer el origen de cada decisión, sus intentos, la hipótesis pertinente, las alternativas, la evidencia y la configuración que llegó realmente al ejecutor. El inventario histórico contiene ejecuciones completadas con verificaciones finales todavía pendientes y no conserva la nueva procedencia estructurada. Por ello, ese inventario no demuestra fiabilidad actual. El gate decisional previo sí aporta una evidencia acotada: sus 45 decisiones permanecieron en el flujo LLM, las 45 en el primer intento lógico bajo el contrato común de hipótesis, tras normalización conservadora sin cambio de juicio y sin respaldo, superposición ni fallo semántico. Una ejecución CWRU posterior conservó otras 18 decisiones LLM en intento lógico 1 y mostró hipótesis efectivas completas de los siete roles. Se concluye que la base supera la puerta de ingeniería definida y que la instrumentación funciona dentro del grafo real, no que todos los agentes sean correctos ante cualquier entrada ni que las hipótesis estén confirmadas.

8.2. Contribuciones alcanzadas

8.2.1. Instrumento multiagente trazable

La primera contribución es una arquitectura capaz de observar el ciclo completo entre evidencia, decisión y resultado. Los contratos estructurados permiten comprobar si una respuesta es válida y ejecutable; la separación entre propuesta y ejecución permite identificar la autoría efectiva de cada cambio; y la persistencia de hipótesis, alternativas, confianza, citas, métricas y limitaciones permite reconstruir posteriormente la decisión.

La versión actual hace comparable esta observación entre roles mediante un bloque común de hipótesis. Supervisor, limpiador, estructurador, modelador, evaluador, redactor y verificador declaran una afirmación acotada, la evidencia disponible al decidir, la observación esperada, un criterio de refutación, riesgos y supuestos. La revisión del

informe se conserva como una clase de decisión del redactor con una hipótesis propia de eficacia correctiva. El mismo objeto alimenta las vistas bidimensional y tridimensional, de modo que el recurso visual no sustituye ni reinterpreta la evidencia canónica.

La misma separación de autoría se mantiene al resumir una revisión de monitorización. La `MonitoringPolicyProposal` conserva una contribución por rol, pero su síntesis pertenece al servidor y no a un octavo agente. El mapeo cerrado clasifica las acciones sin inventar parámetros o versiones, solo declara unanimidad cuando las siete acciones coinciden y conserva el desacuerdo en los demás casos. Esta representación amplía la auditabilidad del instrumento; no acredita que la recomendación sea ejecutable ni eficaz.

Esta contribución mejora la capacidad de auditoría, pero no equivale a haber evaluado las hipótesis. La finalización de un ejecutor no se trata como confirmación científica y, mientras no exista un contraste independiente, el estado mostrado es pendiente. Tampoco se reconstruyen hipótesis ausentes en el histórico a partir de justificaciones libres.

Esta trazabilidad resulta especialmente importante al evaluar modelos de lenguaje. Un agente puede generar una justificación convincente y, sin embargo, seleccionar una alternativa inadecuada. También puede proponer una modificación que no llegue a ejecutarse porque el protocolo mantiene fija una variable. El sistema evita considerar ambos casos como éxitos y distingue respuestas válidas al primer intento, reparaciones de contrato, correcciones de guardarraíl, mecanismos técnicos de respaldo y decisiones rechazadas tras la evaluación.

8.2.2. Memoria RAG gobernada y auditable

La segunda contribución es un ciclo de memoria RAG diseñado como evidencia supervisada y no como acumulación automática de texto. Cada experiencia genera un episodio trazable y, cuando procede, un candidato que nace pendiente y no reutilizable. Su promoción, exclusión, restauración o eliminación requiere una decisión de gobierno persistente. Así se evita que una ejecución aislada se convierta en conocimiento y se refuerce a sí misma en consultas posteriores.

La recuperación distingue el conjunto bruto devuelto por el buscador, el resultado del control de calidad y el contexto efectivo que recibe el agente. Los filtros consideran, entre otros factores, el rol destinatario, el dataset, la procedencia, el perfil experimental, el veredicto y el estado de reutilización. Las citas y la influencia declarada se auditan después frente a la propuesta y a la acción realmente ejecutada. Por ello, recuperar o citar un recuerdo no se interpreta automáticamente como un uso correcto ni como una mejora.

Los episodios y candidatos constituyen la evidencia canónica, mientras que el índice vectorial es una representación derivada y reconstruible. El almacenamiento local proporciona el baseline denso exacto y Qdrant permanece como implementación filtrable opcional. La elección facilita el trabajo experimental, pero no demuestra superioridad frente a pgvector ni forma parte de las conclusiones científicas del TFM.

El piloto oficial aportó una validación negativa especialmente útil. El único recuerdo recuperado era un caso binario de procedencia desconocida y ningún agente lo utilizó. El control identifica la incompatibilidad también a partir de las métricas del recuerdo, y el contrato permite registrar un contexto observado pero no influyente sin convertirlo en una cita. Así, el sistema puede documentar de forma distinta *no retrieval*, *retrieval*

only y uso efectivo de memoria. Esta distinción es una contribución de trazabilidad, no evidencia de mejora causal.

8.2.3. Procedencia explícita de datos y recuerdos

La tercera contribución es la propagación de la procedencia a lo largo del flujo. El sistema diferencia una fuente oficial, una señal sintética y una fuente no verificada, y mantiene separada esta condición del origen de las etiquetas. Esta distinción evita que una política temporal proxy se presente como anotación oficial o que un episodio sintético se reutilice como evidencia directa de una trayectoria NASA real.

La verificación estructural de NASA IMS Set 2 y su ejecución causal permiten trabajar sobre una fuente oficial sin basarse únicamente en el nombre o el formato de una carpeta. No obstante, verificar la procedencia y observar una alerta persistente no validan un modelo de diagnóstico. El onset físico, la tasa de error supervisada y la generalización requieren referencias y trayectorias independientes.

8.2.4. Evaluación jerárquica *run-to-failure*

La cuarta contribución es una evaluación longitudinal que respeta la jerarquía entre ventanas y snapshots. Las ventanas de una misma adquisición se agregan antes de calcular persistencia, primera alerta algorítmica o rachas. El score central, la dispersión, un percentil superior y la proporción de ventanas en alerta se conservan a nivel de snapshot, de modo que un evento interno puede permanecer visible sin multiplicar artificialmente las observaciones temporales.

El caso límite verificado muestra la importancia de esta decisión: tres ventanas en alerta pertenecientes a una sola captura producen una única observación temporal y no una racha de tres instantes. Se corrige así una forma concreta de pseudorreplicación. En Set 2, la política produjo exactamente 984 observaciones longitudinales a partir de 18.696 ventanas, verificó una cadencia completa sin gaps y mantuvo el ajuste del umbral fuera de monitorización. La comparación pareada entre unidades y la validación física siguen pendientes.

8.3. Estado de las hipótesis

Las hipótesis no se consideran confirmadas por el mero hecho de que exista una implementación capaz de medirlas. El alcance defendible se resume de forma directa: H1 está apoyada provisionalmente y H4 parcialmente respaldada como resultados de ingeniería; H2 y H3 continúan no contrastadas. Para H1 faltan escenarios holdout, trayectorias y contextos independientes y una rúbrica externa por rol; para H2, juicios congelados de relevancia; para H3, un corpus pertinente y réplicas con y sin memoria; y para H4, más trayectorias y referencias físicas independientes.

H1 dispone de la evidencia más directa, aunque limitada al funcionamiento del instrumento. En la repetición final del gate vigente, las 45 decisiones efectivas fueron válidas en el primer intento lógico tras normalización sin cambio de juicio; no hubo una segunda llamada LLM, respaldos, superposiciones, fallos semánticos ni decisiones no agénticas. La ejecución completa CWRU posterior mantuvo sus 18 decisiones en el flujo LLM y conservó el bloque común de los siete roles. Sobre NASA, las baterías V2 y V3 añadieron 84 decisiones cada una bajo cuatro cortes causales y tres sesiones: la primera

reveló tres sobrealcances y la segunda dos fallbacks de referencia. Se ha verificado así que el instrumento puede producir, rechazar y publicar decisiones auditables dentro del banco cerrado. Los cortes pertenecen a una única trayectoria ya conocida y no son un holdout; tampoco se conoce aún la frecuencia con la que las hipótesis son técnicamente correctas, suficientes o útiles fuera de esos escenarios.

H2 y H3 permanecen abiertas. El control de calidad de la memoria funciona para los casos incompatibles conocidos y el sistema puede observar si un recuerdo cambia una hipótesis, una alternativa o una configuración. La pasada pareada PCA–Isolation Forest recuperó un único caso frontera, pero ningún agente lo citó o utilizó y no cambió ninguna métrica. Este resultado es una prueba de *retrieval*, no una condición RAG efectiva. Sin una colección de consultas juzgada de forma independiente y un corpus pertinente no puede afirmarse que la recuperación sea más relevante en promedio ni que la memoria mejore las decisiones o las métricas del detector.

H4 está respaldada en el mecanismo concreto de agregación y en su aplicación a Set 2 oficial. Se ha demostrado que la persistencia se calcula sobre snapshots, que la calibración no consume monitorización y que los gaps reiniciarían el estado causal. La parte comparativa continúa pendiente porque no se han medido ambas unidades bajo una condición pareada ni existe una referencia oficial de onset continuo.

La comparación entre Qwen 3.5 y Qwen 3 no constituye una hipótesis resuelta. El sistema utiliza actualmente Qwen 3.5, pero no existe una batería común ejecutada con ambos modelos. Cualquier afirmación sobre su comportamiento relativo sería prematura hasta mantener constantes datos, prompts, contratos, herramientas, corpus de memoria y configuración de inferencia.

8.4. Limitaciones

La principal limitación empírica es que el escenario real preparado contiene una trayectoria longitudinal principal. Sus 984 snapshots son observaciones ordenadas y dependientes, no 984 activos independientes. Aunque la agregación evita contar las ventanas como réplicas temporales, una sola trayectoria no permite estimar generalización entre rodamientos, regímenes de operación o plantas industriales.

La segunda limitación es la ausencia de anotaciones oficiales continuas sobre el estado de degradación. El evento final está documentado, pero una frontera temporal construida o una etiqueta binaria proxy no identifica por sí misma el onset físico. En consecuencia, las métricas de clasificación solo pueden ser auxiliares y deben acompañarse de análisis longitudinal, sensibilidad a umbrales y declaración explícita del origen de las etiquetas.

La tercera limitación es el riesgo de fuga temporal. El tiempo restante hasta el final, la vida relativa calculada retrospectivamente, la recalibración sobre monitorización y los recuerdos producidos por la propia evaluación podrían mejorar artificialmente el resultado. En la ejecución oficial se verificó la separación de la vista *online blind* y el origen del umbral. El riesgo permanece entre condiciones futuras si el corpus no se congela antes de las ablaciones.

La cuarta limitación afecta a la memoria RAG. Su utilidad depende de la calidad y diversidad del corpus, de las decisiones de promoción y de los juicios de relevancia. El gobierno reduce contaminación y autorrefuerzo, pero también puede introducir criterios humanos inconsistentes. Se necesitan una rúbrica previa, revisión independiente y un corpus congelado para medir de forma fiable la recuperación y la influencia.

La quinta limitación procede de la variabilidad de los modelos de lenguaje. Una respuesta aislada demuestra que una conducta puede ocurrir, no su frecuencia ni su estabilidad. Las reparaciones de formato y los mecanismos de respaldo garantizan la continuidad técnica, pero no deben contarse como razonamiento correcto del agente. El piloto tampoco persistió la versión exacta del modelo local en su manifiesto; esta ausencia excluye esa pasada de cualquier comparación entre modelos. El gate repetido posterior sí selló el digest exacto, la configuración de inferencia y tres repeticiones sobre cuatro cortes, pero estas observaciones siguen correlacionadas dentro de una sola trayectoria. Son necesarias réplicas pareadas sobre trayectorias o contextos independientes.

La sexta limitación afecta al contraste de las hipótesis de rol. El contrato común fija de antemano qué observación las apoyaría y qué resultado las refutaría, pero aún no existe una valoración posterior independiente y sistemática para todas las decisiones. Por ello, la interfaz puede mostrar la declaración y enlazar el resultado técnico, pero no debe convertir ese enlace en una etiqueta de confirmación.

El binding singleton reforzado permitió distinguir alcance causal y selección de soporte, y posteriormente se extendió a un catálogo cerrado por registro. Los handles E01..EN permiten conservar bajo autoridad del backend el alcance completo y la identidad canónica, mientras el agente selecciona filas concretas. Esta propiedad acredita pertenencia al catálogo, pero todavía no que un registro sostenga semánticamente cada afirmación. Tampoco existe evidencia empírica nueva de Qwen sobre este contrato: requiere una evaluación prospectiva completa y prerregistrada.

La propuesta consultiva añade una limitación distinta. Sus categorías proceden de acciones ya disponibles y no contienen umbrales, frecuencias ni versiones candidatas. `advisory_not_applied` no equivale a validación, aprobación o aplicación; el OR de revisión humana solo conserva que algún rol la recomienda. Evaluar utilidad requerirá una propuesta paramétrica explícita, un juez independiente y una intervención exclusivamente hacia delante.

Finalmente, el trabajo no compara de forma experimental backends vectoriales, familias avanzadas de modelos PHM ni infraestructura de producción. Tampoco realiza una validación industrial externa. Estos límites son coherentes con la prioridad adoptada: cerrar primero un estudio reproducible sobre comportamiento agéntico, memoria gobernada y degradación temporal.

8.5. Trabajo futuro

El trabajo futuro se prioriza de acuerdo con su contribución a la evidencia científica antes de ampliar la plataforma:

1. ampliar la fiabilidad con escenarios holdout, un tercer formato genérico y una batería determinista de perturbaciones antes de estimar tasas generales;
2. prerregistrar un gate prospectivo completo del catálogo sellado por registro ya implementado, con plan y sesiones nuevos; medir primera respuesta, fallback y pertenencia exacta sin sustituir selectivamente la hija adversa de V3, y añadir una rúbrica independiente si se desea evaluar soporte semántico;
3. ampliar después la síntesis consultiva con un contrato agentivo que proponga valores dentro de rangos predeclarados, una validación determinista separada, revisión

humana real y un `ApplicationRecord` exclusivamente hacia delante; comparar sus efectos sin tratar la activación correcta como prueba de mejora;

4. construir y congelar un corpus revisado, separado por grupos de evaluación, junto con consultas y juicios de relevancia definidos antes de observar los rankings, sin activar RAG hasta superar una puerta prospectiva de fiabilidad sin fallback;
5. repetir con Qwen 3.5 las condiciones sin memoria, solo recuperación y memoria filtrada, manteniendo constantes el resto de factores y registrando el manifiesto de inferencia completo;
6. aplicar, por rol, una valoración independiente que contraste la observación esperada y el criterio de refutación frente al resultado, conservando alternativas, confianza, correcciones, citas y acción efectiva en el paquete auditable;
7. comparar de forma controlada la trayectoria por snapshot con el tratamiento de ventanas como unidades longitudinales, sin convertir este último en protocolo válido;
8. ampliar las tres repeticiones de cortes fijos con trayectorias y contextos independientes para estimar la variabilidad del agente y aplicar una rúbrica externa a hipótesis, evidencia, revisiones y reconocimiento de limitaciones;
9. cerrar los resultados de Qwen 3.5 y repetir después la misma batería con Qwen 3, sin modificar el protocolo entre ambas comparaciones.

Esta secuencia permitirá responder H1–H4 sin confundir cambios simultáneos de modelo, memoria o datos. También permitirá determinar si un recuerdo relevante produce únicamente una explicación distinta o una decisión efectivamente más útil.

8.5.1. Ampliaciones posteriores

Una vez cerrado el contraste principal, la evaluación debería ampliarse a más trayectorias y activos. Otros subconjuntos de NASA IMS y datasets *run-to-failure*, como PRONOSTIA o XJTU-SY, permitirían estudiar la transferencia de recuerdos entre condiciones y separar conocimiento general de experiencias específicas de un activo. Esta ampliación debe mantener la misma disciplina de procedencia, partición causal y unidad temporal.

La estimación de vida útil remanente puede incorporarse como extensión, siempre que incluya incertidumbre y evite comunicar una precisión no respaldada. Los modelos secuenciales o representaciones aprendidas sobre señal cruda también son líneas razonables, pero deben compararse primero con los baselines actuales y justificarse por la cantidad de trayectorias disponibles, no solo por su complejidad.

En la memoria RAG será útil estudiar promoción basada en repetición independiente, vigencia temporal de recuerdos, resolución de contradicciones y transferencia entre datasets. También podrán compararse índices vectoriales si el volumen o los requisitos transaccionales lo justifican. Esta comparación debe medir fidelidad, latencia, reproducibilidad y coste, sin identificar el backend con la calidad del razonamiento.

La industrialización queda como una línea secundaria, posterior al cierre experimental. Incluye persistencia robusta de trabajos, autenticación, observabilidad operacional, ejecución distribuida y despliegue remoto. Estas capacidades mejorarían la operación del sistema, pero no sustituyen las ablaciones ni aportan por sí mismas evidencia sobre las hipótesis científicas.

8.6. Conclusión final

La aportación demostrada de este TFM no es haber encontrado ya el mejor detector ni el mejor modelo de lenguaje. Es haber construido un marco en el que las decisiones de agentes locales pueden observarse, ejecutarse bajo restricciones, relacionarse con memoria recuperada y evaluarse dentro de una trayectoria *run-to-failure* sin perder la procedencia de la evidencia.

El sistema permite estudiar el ciclo entre decisión, memoria y acción con un nivel de trazabilidad que reconoce tanto aciertos como fallos. La memoria RAG gobernada y la evaluación por snapshot son los mecanismos más originales, y el baseline NASA IMS oficial demuestra que pueden situarse en un protocolo causal real sin fabricar etiquetas. El replay P3 añade la separación híbrida entre monitorización determinista frecuente y supervisión periódica o dirigida por eventos. La batería repetida aporta evidencia contractual y negativa: V2 y V3 fueron bloqueadas por fragilidades diferentes que la cadena de auditoría hizo visibles. La síntesis consultiva posterior hace explícitas las siete recomendaciones sin ocultar desacuerdo y sin aplicar ninguna de ellas. Por ello no procede activar RAG ni adaptar políticas todavía. La conclusión defendible es precisa: el instrumento es funcional, auditable y ya está aplicado a una trayectoria oficial; las hipótesis sobre utilidad de la memoria y calidad media del razonamiento permanecen abiertas donde falta evidencia controlada e independiente.

Bibliografía

- [1] Markus M. Breunig, Hans-Peter Kriegel, Raymond T. Ng, and Jörg Sander. LOF: Identifying density-based local outliers. In *Proceedings of the 2000 ACM SIGMOD International Conference on Management of Data*, pages 93–104, 2000.
- [2] Case Western Reserve University Bearing Data Center. 12k drive end bearing fault data, 2026. Disponible en: <https://engineering.case.edu/bearingdatacenter/12k-drive-end-bearing-fault-data>.
- [3] Case Western Reserve University Bearing Data Center. Bearing data center, 2026. Disponible en: <https://engineering.case.edu/bearingdatacenter/welcome>.
- [4] Case Western Reserve University Bearing Data Center. Normal baseline data, 2026. Disponible en: <https://engineering.case.edu/bearingdatacenter/normal-baseline-data>.
- [5] Data.gov. Ims bearings. <https://catalog.data.gov/dataset/ims-bearings>, 2026. Portal oficial de datos.
- [6] IEEE PHM 2012 Data Challenge. Ieee phm 2012 prognostic challenge details, 2012. Disponible en: <https://raw.githubusercontent.com/wkzs111/phm-ieee-2012-data-challenge-dataset/master/IEEEPHM2012-Challenge-Details.pdf>.
- [7] Andrew K. S. Jardine, Daming Lin, and Dragan Banjevic. A review on machinery diagnostics and prognostics implementing condition-based maintenance. *Mechanical Systems and Signal Processing*, 20(7):1483–1510, 2006.
- [8] LangChain. LangGraph overview, 2026. Documentación oficial. Disponible en: <https://docs.langchain.com/oss/python/langgraph/overview>.
- [9] Yaguo Lei, Naipeng Li, Liang Guo, Ningbo Li, Tao Yan, and Jing Lin. Machinery health prognostics: A systematic review from data acquisition to RUL prediction. *Mechanical Systems and Signal Processing*, 104:799–834, 2018.
- [10] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, Sebastian Riedel, and Douwe Kiela. Retrieval-augmented generation for knowledge-intensive NLP tasks. In *Advances in Neural Information Processing Systems*, volume 33, 2020.
- [11] Fei Tony Liu, Kai Ming Ting, and Zhi-Hua Zhou. Isolation forest. In *2008 Eighth IEEE International Conference on Data Mining*, pages 413–422, 2008.

- [12] Xiao Liu, Hao Yu, Hanchen Zhang, Yifan Xu, Xuanyu Lei, Hanyu Lai, Yu Gu, Hangliang Ding, Kaiwen Men, Kejuan Yang, Shudan Zhang, Xiang Deng, Aohan Zeng, Zhengxiao Du, Chenhui Zhang, Sheng Shen, Tianjun Zhang, Yu Su, Huan Sun, Minlie Huang, Yuxiao Dong, and Jie Tang. AgentBench: Evaluating LLMs as agents. In *The Twelfth International Conference on Learning Representations*, 2024.
- [13] NASA. Metrics library for prognostics performance evaluation, 2026. Disponible en: <https://software.nasa.gov/software/ARC-17898-1>.
- [14] NASA Prognostics Center of Excellence. Data set repository, 2026. Disponible en: <https://www.nasa.gov/intelligent-systems-division/discovery-and-systems-health/pcoe/pcoe-data-set-repository/>.
- [15] NASA Prognostics Center of Excellence. Ims bearings dataset, 2026. Disponible en: <https://phm-datasets.s3.amazonaws.com/NASA/4.+Bearings.zip>.
- [16] Cheng Niu, Yuanhao Wu, Juno Zhu, Siliang Xu, KaShun Shum, Randy Zhong, Juntong Song, and Tong Zhang. RAGTruth: A hallucination corpus for developing trustworthy retrieval-augmented language models. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics*, pages 10862–10878, 2024.
- [17] pgvector contributors. pgvector: Open-source vector similarity search for PostgreSQL. <https://github.com/pgvector/pgvector>, 2026. Repositorio y documentación oficial.
- [18] Qdrant. Indexing. <https://qdrant.tech/documentation/manage-data/indexing/>, 2026. Documentación oficial.
- [19] Hai Qiu, Jay Lee, Jing Lin, and Gang Yu. Wavelet filter-based weak signature detection method and its application on rolling element bearing prognostics. *Journal of Sound and Vibration*, 289(4–5):1066–1090, 2006.
- [20] Abhinav Saxena, Jose Celaya, Edward Balaban, Kai Goebel, Bhaskar Saha, Sanjalita Saha, and Mark Schwabacher. Metrics for evaluating performance of prognostic techniques. In *International Conference on Prognostics and Health Management*, 2008.
- [21] Bernhard Schölkopf, John C. Platt, John Shawe-Taylor, Alex J. Smola, and Robert C. Williamson. Estimating the support of a high-dimensional distribution. *Neural Computation*, 13(7):1443–1471, 2001.
- [22] Noah Shinn, Federico Cassano, Ashwin Gopinath, Karthik Narasimhan, and Shunyu Yao. Reflexion: Language agents with verbal reinforcement learning. In *Advances in Neural Information Processing Systems*, volume 36, 2023.
- [23] Nandan Thakur, Nils Reimers, Andreas Rücklé, Abhishek Srivastava, and Iryna Gurevych. BEIR: A heterogeneous benchmark for zero-shot evaluation of information retrieval models. In *Proceedings of the Neural Information Processing Systems Track on Datasets and Benchmarks*, volume 1, 2021.

- [24] Xi'an Jiaotong University. Xjtu-sy bearing datasets, 2026. Disponible en: <https://github.com/WangBiaoXJTU/xjtu-sy-bearing-datasets>.
- [25] Shunyu Yao, Jeffrey Zhao, Dian Yu, Nan Du, Izhak Shafran, Karthik Narasimhan, and Yuan Cao. ReAct: Synergizing reasoning and acting in language models. In *The Eleventh International Conference on Learning Representations*, 2023.